

Metodologias, nível 2 — intuição e uso

Felipe Santana

Sumário

Teste t de Welch	2
Decomposição de Oaxaca-Blinder	6
Decomposição por RIF (Recentered Influence Function)	10
Decomposição de desigualdade (Theil, Gini, quantis ponderados)	14
Índice de dissimilaridade de Duncan	19
Teste de quebra estrutural (tipo Chow)	22
Diferenças-em-diferenças (DiD)	25
Análise de transições em painel rotativo	28
Fundamentos de teste A/B	31
Teste de Sample Ratio Mismatch (SRM)	35
Balanceamento de covariáveis e ajuste por covariáveis	39
Teste de não-inferioridade	43
Teste de heterogeneidade de efeito e decaimento de novidade	47
Poder estatístico e efeito mínimo detectável (MDE)	50
Análise de transbordamento espacial e canibalização	54
Erros-padrão robustos a cluster	58
Inferência por randomização (teste de permutação)	61
Bootstrap wild-cluster	64
Decomposição de coorte e retenção	67
Decomposição de crescimento (total, comparável e preço-volume-mix)	71

Regressão de Poisson com efeitos fixos	75
Tendência por mínimos quadrados ponderados (WLS) com classificação por intervalo de confiança	79
Regressão logística	83

Teste t de Welch

1. Que problema isso resolve?

Você tem dois grupos e observa que a média de alguma variável é diferente entre eles — por exemplo, o tempo médio de espera numa fila é maior que na outra. A pergunta que importa é: essa diferença é real, no sentido de refletir algo que acontece na população, ou pode ter surgido só pelo acaso de quem calhou de cair em cada amostra? E, mais especificamente: dá para responder isso de forma confiável quando os dois grupos não têm o mesmo tamanho de amostra nem a mesma variabilidade interna?

2. Intuição

Mesmo que duas populações tivessem exatamente a mesma média, amostras aleatórias tiradas delas quase nunca produziriam médias amostrais idênticas — sempre existe ruído de amostragem. O teste t de Welch mede o quão incomum é a diferença observada entre as médias, levando em conta o tamanho de cada amostra e a dispersão dentro de cada grupo, sem exigir que essa dispersão seja igual nos dois grupos.

Essa última parte é o que diferencia Welch do teste t clássico de Student: o Student assume que as duas populações têm a mesma variância, uma suposição conveniente matematicamente, mas frequentemente irreal — grupos diferentes costumam ter variabilidades diferentes, principalmente quando também diferem em tamanho de amostra.

3. Explicação simples


O teste calcula uma estatística que resume “quantos erros-padrão de distância” a diferença observada está de zero. Quanto maior essa distância (em valor absoluto), mais incomum seria observar essa diferença se, na população, as médias fossem realmente iguais. Essa estatística é comparada a uma distribuição de referência (uma distribuição t, com graus de liberdade calculados de um jeito específico) para produzir um valor-p.

4. Exemplo conceitual fácil

Imagine duas filas de atendimento num evento. A fila A tem poucos atendentes, mas o tempo de espera é bem previsível. A fila B tem mais atendentes, mas o tempo de espera varia muito — às vezes é rápido, às vezes trava bastante. Mesmo com tamanhos de amostra e variabilidades bem diferentes entre as duas filas, o teste de Welch ainda consegue comparar as médias de forma confiável.

5. Como funciona, em linhas gerais

1. Calcula-se a média e o desvio-padrão de cada grupo separadamente.



Dados ilustrativos, não representam nenhum projeto real.

Figura 1: Duas distribuições amostrais com dispersões diferentes, mostrando as médias de cada grupo

2. Calcula-se o erro-padrão da diferença entre as médias, combinando as duas variâncias sem assumir que são iguais.
3. Divide-se a diferença observada de médias por esse erro-padrão, obtendo a estatística t .
4. Os graus de liberdade não saem de uma fórmula simples como no teste de Student — eles são calculados de um jeito que pondera o quanto cada grupo contribui para a incerteza total (aproximação de Welch-Satterthwaite), resultando tipicamente num número não inteiro.
5. Compara-se a estatística t com a distribuição de referência para obter o valor- p .

6. O que o resultado significa

Um valor- p baixo (tipicamente abaixo de 0,05) indica que uma diferença desse tamanho seria rara se, na população, as médias fossem realmente iguais — isso é evidência a favor de uma diferença real. Um valor- p alto não prova que as médias são iguais; apenas indica que os dados não trazem evidência forte de diferença.

7. Como interpretar

O valor- p mede evidência contra a hipótese de médias iguais, não o tamanho ou a importância prática da diferença. Um gap pequeno pode ser estatisticamente significativo se a amostra for grande, e um gap grande pode não ser significativo se a amostra for pequena ou muito variável. Vale sempre olhar o tamanho do efeito junto com o valor- p — não só um dos dois.

8. Quando é útil

Quando você precisa comparar médias entre dois grupos que provavelmente têm variabilidade diferente — o que é a regra, não a exceção, em dados do mundo real. Um caso comum é acompanhar, ao longo de vários períodos de tempo, se a diferença de renda média entre dois grupos populacionais permanece estatisticamente significativa período a período, sem assumir de antemão que os dois grupos têm a mesma dispersão de renda.

9. Cuidados importantes

- O teste assume amostras razoavelmente independentes; dados com estrutura de cluster (por exemplo, várias observações vindas do mesmo domicílio ou região) exigem ajuste separado no erro-padrão.
- Com amostras muito pequenas e distribuições muito assimétricas, a aproximação usada pelo teste fica menos confiável.
- Significância estatística não é o mesmo que relevância prática — sempre reporte o tamanho da diferença, não só o valor- p .

10. Um exemplo pequeno com números

Suponha duas filas de atendimento, com tempos de espera em minutos:

- Fila A: $n = 40$, média = 8,1 min, desvio-padrão = 1,3 min.
- Fila B: $n = 95$, média = 9,6 min, desvio-padrão = 3,4 min.

A diferença observada de médias é de 1,5 minuto. Como a Fila B tem uma dispersão muito maior, o teste de Welch pondera essa incerteza extra ao calcular o erro-padrão da diferença, produzindo uma estatística t de aproximadamente 3,1, com graus de liberdade efetivos em torno de 61 (um

número não inteiro, resultado da ponderação entre as duas amostras). O valor-p correspondente é bem abaixo de 0,01 — evidência forte de que a Fila B realmente tem tempo médio de espera maior, não apenas por acaso da amostra.

11. Exemplo de código simples

```
import numpy as np
from scipy import stats

fila_a = np.array([7.9, 8.4, 7.5, 9.0, 8.2, 7.8, 8.6, 7.7, 8.3, 8.0]) # ilustrativo
fila_b = np.array([9.1, 12.4, 6.8, 10.2, 9.9, 7.3, 15.0, 8.5, 9.7, 10.8]) # ilustrativo

resultado = stats.ttest_ind(fila_a, fila_b, equal_var=False) # equal_var=False = Welch
print(f"t = {resultado.statistic:.2f}, valor-p = {resultado.pvalue:.4f}")
```

O parâmetro `equal_var=False` é o que diz ao SciPy para usar Welch em vez do teste t clássico de Student — a diferença de uma linha de código evita uma suposição que, na prática, raramente se sustenta.

Decomposição de Oaxaca-Blinder

1. Que problema isso resolve?

Dois grupos ganham salários diferentes, em média. Uma parte dessa diferença pode vir do fato de os grupos terem, em média, características diferentes — mais ou menos anos de estudo, por exemplo. Mas será que isso explica toda a diferença, ou sobra alguma coisa mesmo depois de colocar essas características na mesma régua?

2. Intuição

Imagine que você quer comparar o salário médio de dois grupos, mas sabe que eles também diferem, em média, em escolaridade. Simplesmente comparar as médias de salário mistura duas coisas: a diferença de escolaridade em si, e qualquer diferença na forma como cada grupo é remunerado por unidade de escolaridade. A decomposição de Oaxaca-Blinder separa essas duas fontes, respondendo à pergunta: “se o Grupo B tivesse a mesma escolaridade média do Grupo A, mas continuasse sendo remunerado do seu próprio jeito, qual seria o salário médio esperado do Grupo B?”

3. Explicação simples

O método ajusta um modelo estatístico (tipicamente uma regressão linear) relacionando salário às características observáveis, separadamente para cada grupo. Depois, ele usa esses dois modelos para simular um cenário contrafactual — “e se” — e decompõe a diferença total de médias em duas partes:


- **Componente explicado:** a parte da diferença que vem de os grupos terem, em média, características diferentes.
- **Componente não explicado:** o que sobra — diferenças na forma como cada característica se traduz em salário para cada grupo, mais qualquer coisa não capturada pelas características medidas.

4. Exemplo conceitual fácil

Imagine duas equipes de vendas numa empresa. A Equipe A tem, em média, mais anos de experiência que a Equipe B. Se a Equipe A também ganha mais em média, parte dessa diferença pode simplesmente refletir a diferença de experiência — mais experiência, mais salário, em ambas as equipes igualmente. A decomposição separa quanto do gap vem dessa diferença de experiência, e quanto sobra mesmo comparando pessoas com a mesma experiência nas duas equipes.

5. Como funciona, em linhas gerais

1. Ajusta-se um modelo de regressão separado para cada grupo, relacionando a variável de interesse (salário, por exemplo) às características observáveis (escolaridade, idade, ocupação etc.).
2. Calcula-se a diferença total de médias entre os grupos.
3. Usando os coeficientes de um dos modelos (ou uma combinação ponderada dos dois, dependendo da variante do método), constrói-se o cenário contrafactual: qual seria o salário médio do Grupo B se ele tivesse as características médias do Grupo A, mas mantivesse sua própria estrutura de remuneração.



Dados ilustrativos, não representam nenhum projeto real.

Figura 2: Barra empilhada mostrando o gap salarial total dividido em componente explicado e não explicado

4. A diferença entre o salário observado do Grupo A e esse contrafactual é o componente explicado; a diferença entre o contrafactual e o salário observado do Grupo B é o componente não explicado.

6. O que o resultado significa

O componente explicado mostra quanto da diferença de médias pode ser atribuído a diferenças médias nas características medidas. O componente não explicado mostra o que sobra depois de colocar essas características na mesma régua — ele é frequentemente interpretado como um possível sinal de discriminação ou de outros fatores não observados, mas essa leitura exige suposições muito mais fortes do que o método garante sozinho: pode haver características relevantes para o salário que simplesmente não foram medidas e que, se fossem incluídas, mudariam a divisão entre as duas partes.

7. Como interpretar

O método decompõe uma diferença observada — ele não prova causalidade nem isola discriminação. Dizer “o componente não explicado é discriminação” pressupõe que todas as características relevantes para o salário foram medidas e incluídas no modelo, o que raramente é verdade na prática (viés de variável omitida). O componente não explicado é melhor descrito como “o que não pôde ser atribuído às características observadas” — uma diferença importante entre não conseguir explicar algo e ter certeza da sua causa.

8. Quando é útil

Quando você quer entender a composição de um gap entre grupos — por exemplo, comparar a diferença salarial média entre grupos demográficos, separando quanto vem de diferenças de composição (escolaridade, idade, tipo de ocupação) e quanto permanece mesmo controlando por essas variáveis.

9. Cuidados importantes

- **Viés de variável omitida:** se uma característica relevante não foi medida, ela acaba “escondida” dentro do componente não explicado.
- **Escolha do grupo de referência:** em algumas variantes do método, o resultado pode mudar dependendo de qual grupo é usado como referência para construir o contrafactual — vale checar a especificação usada.
- **A decomposição olha só a média:** se o gap for muito diferente em pontos diferentes da distribuição (por exemplo, maior no topo da renda), a decomposição de médias não captura isso — para essa pergunta, métodos como a decomposição por RIF são mais apropriados.
- **Causalidade:** o método é descritivo/contábil, não causal — ele não determina se as diferenças de características em si têm origem causal.

10. Um exemplo pequeno com números

Suponha um cenário hipotético: duas equipes numa empresa, com salário médio mensal (em unidades monetárias fictícias) e anos médios de experiência:

- Equipe A: salário médio = 5.800, experiência média = 8 anos.
- Equipe B: salário médio = 4.620, experiência média = 5 anos.

O gap total é de 1.180. Suponha que o modelo estimado indique que, mantendo a estrutura de remuneração da Equipe A, cada ano de experiência adicional corresponde a um acréscimo médio de aproximadamente 210 unidades. Se a Equipe B tivesse a experiência média da Equipe A (8 anos em vez de 5), o salário contrafactual dela ficaria em torno de $4.620 + 3 \times 210 = 5.250$. Isso separa o gap total em:

- **Componente explicado** (diferença de experiência): $5.250 - 4.620 = 630$.
- **Componente não explicado**: $5.800 - 5.250 = 550$.

Ou seja, aproximadamente metade do gap vem da diferença de experiência média entre as equipes, e a outra metade permanece mesmo comparando pessoas com a mesma experiência.

11. Exemplo de código simples

```
import pandas as pd
import statsmodels.formula.api as smf

# dados ilustrativos, nível pessoa
df_a = pd.DataFrame({"salario": [...], "experiencia": [...]} # Equipe A
df_b = pd.DataFrame({"salario": [...], "experiencia": [...]} # Equipe B

modelo_a = smf.ols("salario ~ experiencia", data=df_a).fit()
modelo_b = smf.ols("salario ~ experiencia", data=df_b).fit()

exp_media_a = df_a["experiencia"].mean()
exp_media_b = df_b["experiencia"].mean()

# contrafactual: Equipe B com a experiência média da Equipe A,
# remunerada segundo a própria estrutura da Equipe B
salario_contrafactual = modelo_b.params["Intercept"] + modelo_b.params["experiencia"] * exp_media_a

explicado = salario_contrafactual - df_b["salario"].mean()
nao_explicado = df_a["salario"].mean() - salario_contrafactual
```

Bibliotecas dedicadas (como o pacote `oaxaca` em R, ou implementações em Python construídas sobre `statsmodels`) automatizam esse cálculo e também fornecem erros-padrão para cada componente da decomposição.

Decomposição por RIF (Recentered Influence Function)

1. Que problema isso resolve?

A decomposição de Oaxaca-Blinder separa a diferença de médias entre dois grupos em uma parte explicada e uma não explicada — mas e se a diferença entre os grupos não for a mesma em todos os pontos da distribuição? E se o gap for pequeno entre quem ganha pouco, mas grande entre quem ganha muito (ou vice-versa)? A decomposição por RIF responde a essa pergunta, estendendo a lógica de Oaxaca-Blinder para além da média.

2. Intuição

A média é só um resumo entre vários possíveis de uma distribuição. Outros resumos — a mediana, o percentil 10, o percentil 90 — também podem ser comparados entre grupos, e decompostos em “quanto vem de diferença de características” e “quanto sobra”. O desafio técnico é que esses outros resumos (chamados de estatísticas distribucionais) não são médias simples de variáveis observadas, então a maquinaria de regressão usada em Oaxaca-Blinder não se aplica diretamente a eles. A função de influência recentrada é o que resolve esse problema: ela transforma cada observação numa medida de “o quanto ela influencia” aquele resumo específico da distribuição, de um jeito que a média dessa medida transformada recupera o próprio resumo — e, uma vez transformada, a lógica de Oaxaca-Blinder volta a funcionar.

3. Explicação simples


Uma função de influência mede, para uma estatística de interesse (a mediana, por exemplo), o quanto essa estatística mudaria se uma observação específica fosse levemente perturbada. A versão “recentrada” é ajustada para que a média da função de influência, calculada sobre toda a amostra, seja exatamente igual ao valor original da estatística. Isso é o que permite tratar essa medida transformada como se fosse uma variável comum, e aplicar regressão e decomposição de Oaxaca-Blinder em cima dela — só que, em vez de decompor a diferença nas médias da variável original, decompõe-se a diferença na estatística de interesse (mediana, percentil 90 etc.).

4. Exemplo conceitual fácil

Imagine que a diferença salarial entre dois grupos, olhando só a média, seja de 15%. A decomposição por RIF pode revelar que, no percentil 10 (entre quem ganha menos), o gap é de 28%, enquanto no percentil 50 (a mediana) o gap cai para 15%, e volta a subir para 26% no percentil 90 (entre quem ganha mais). Esse padrão — gap maior nas pontas da distribuição do que no meio — é comum o suficiente para ter nomes próprios na literatura: “sticky floor” (piso pegajoso, quando o gap é maior na base) e “glass ceiling” (teto de vidro, quando o gap é maior no topo).

5. Como funciona, em linhas gerais

1. Escolhe-se a estatística distribucional de interesse (mediana, um percentil específico, o índice de Gini etc.).
2. Calcula-se a função de influência recentrada dessa estatística para cada observação da amostra.
3. Usa-se essa medida transformada como variável de resultado numa regressão, separadamente para cada grupo — exatamente como no primeiro passo de Oaxaca-Blinder, mas com a variável transformada no lugar da variável original.



Dados ilustrativos, não representam nenhum projeto real.

Figura 3: Gap não explicado estimado em diferentes percentis da distribuição, mostrando que o gap é maior nas pontas

4. Aplica-se a mesma lógica de decomposição contrafactual de Oaxaca-Blinder sobre essa regressão, obtendo componentes explicado e não explicado para aquele ponto específico da distribuição.
5. Repete-se para vários pontos da distribuição (vários percentis, por exemplo) para construir um perfil completo do gap ao longo da distribuição.

6. O que o resultado significa

Para cada ponto da distribuição escolhido, o resultado mostra quanto do gap naquele ponto vem de diferença de características e quanto sobra — igual a Oaxaca-Blinder, mas ponto a ponto em vez de só na média. Olhando vários pontos juntos, dá para enxergar se o gap é uniforme ao longo da distribuição ou se se concentra em certas regiões.

7. Como interpretar

Assim como em Oaxaca-Blinder, o componente não explicado em cada ponto não deve ser automaticamente lido como discriminação — a mesma ressalva sobre variáveis omitidas se aplica, ponto a ponto. Além disso, a precisão da estimativa costuma variar ao longo da distribuição: pontos nas pontas (percentis muito baixos ou muito altos) geralmente têm menos observações próximas e margens de erro maiores — resultados ali merecem leitura mais cautelosa.

8. Quando é útil

Quando a pergunta não é só “existe um gap médio?”, mas “esse gap é igual em todos os níveis da distribuição, ou existe um padrão de concentração em certas faixas?” Um caso típico: usar essa técnica para revelar que o gap residual entre grupos raciais numa distribuição de renda é maior tanto entre quem ganha pouco quanto entre quem ganha muito, e relativamente menor no meio da distribuição.

9. Cuidados importantes

- Erros-padrão maiores nas pontas da distribuição exigem cautela redobrada ao interpretar diferenças ali.
- A escolha de quais pontos da distribuição reportar (só a mediana? uma grade de percentis?) afeta a narrativa — vale reportar um conjunto representativo, não só o ponto mais “conveniente” para a história.
- Assim como em Oaxaca-Blinder, a decomposição é contábil, não causal.

10. Um exemplo pequeno com números

Suponha, num cenário hipotético, o gap salarial não explicado (residual) entre dois grupos, estimado em cinco percentis da distribuição:

Percentil	Gap não explicado
P10	28%
P25	19%
P50	15%
P75	18%
P90	26%

O padrão em “U” — maior nas pontas, menor no meio — sugere que, mesmo comparando pessoas com características parecidas, o gap não é constante ao longo da distribuição: é mais acentuado tanto na base quanto no topo da distribuição salarial do que na faixa intermediária.

11. Exemplo de código simples

```
import numpy as np
import pandas as pd
import statsmodels.formula.api as smf
from scipy.stats import gaussian_kde

def rif_quantile(y, q):
    """Função de influência recentrada para o quantil q (0 a 1)."""
    valor_quantil = np.quantile(y, q)
    densidade = gaussian_kde(y)(valor_quantil)[0]
    indicador = (y <= valor_quantil).astype(float)
    return valor_quantil + (q - indicador) / densidade

df_a = pd.DataFrame({"salario": [...], "escolaridade": [...]} ) # Grupo A
df_b = pd.DataFrame({"salario": [...], "escolaridade": [...]} ) # Grupo B

df_a["rif_mediana"] = rif_quantile(df_a["salario"].values, 0.5)
df_b["rif_mediana"] = rif_quantile(df_b["salario"].values, 0.5)

modelo_a = smf.ols("rif_mediana ~ escolaridade", data=df_a).fit()
modelo_b = smf.ols("rif_mediana ~ escolaridade", data=df_b).fit()
# a partir daqui, a decomposição segue os mesmos passos de Oaxaca-Blinder
```

Na prática, pacotes dedicados (como `rifreg` em R/Stata) cuidam dos detalhes de estimação da densidade e do cálculo de erros-padrão, que exigem mais cuidado do que a versão simplificada acima.

Decomposição de desigualdade (Theil, Gini, quantis ponderados)

1. Que problema isso resolve?

Quando se fala em “desigualdade de renda”, é fácil pensar só em um número — mas de onde vem essa desigualdade? Quanto dela é porque diferentes grupos (por região, por gênero, por qualquer outro recorte) têm rendas médias diferentes, e quanto é porque, dentro de cada grupo, já existe muita variação entre quem ganha pouco e quem ganha muito? Essa família de ferramentas — o índice de Theil, o índice de Gini, e quantis ponderados — ajuda a responder essas perguntas.

2. Intuição

Pense em duas fontes de desigualdade que podem coexistir. Primeira: grupos diferentes podem ter rendas médias diferentes entre si — isso é desigualdade “entre grupos”. Segunda: mesmo dentro de um único grupo, algumas pessoas ganham muito mais que outras — isso é desigualdade “dentro do grupo”. O índice de Theil tem uma propriedade matemática valiosa: ele consegue separar esses dois componentes de forma exata, sem sobra e sem dupla contagem. Já o índice de Gini mede a concentração de renda dentro de uma única distribuição (um grupo, ou a população toda), numa escala de 0 (igualdade perfeita) a 1 (um indivíduo com tudo, o resto com nada). Quantis ponderados são apenas pontos de corte — “o que caracteriza os 10% mais ricos deste grupo?” — que usam o peso amostral de cada observação para estimar corretamente esses cortes numa pesquisa com amostragem complexa.

3. Explicação simples

O índice de Theil calcula, essencialmente, uma medida de dispersão baseada em entropia — quanto mais desigual a distribuição, maior o índice. Sua propriedade de decomponibilidade exata permite escrever:

$$\text{Desigualdade total} = \text{Desigualdade entre grupos} + \text{Desigualdade dentro dos grupos}$$

Essa soma não é uma aproximação — as duas partes somam exatamente o total. O índice de Gini, por outro lado, não tem essa propriedade de decomponibilidade exata da mesma forma simples — ele é calculado separadamente para cada grupo (ou para a população como um todo), e serve para comparar o quão concentrada é a distribuição dentro de cada recorte.


4. Exemplo conceitual fácil

Imagine uma empresa com dois departamentos. Se todo mundo no Departamento A ganhasse exatamente o mesmo salário, e todo mundo no Departamento B também ganhasse um salário fixo (só que diferente do A), toda a desigualdade da empresa viria da diferença entre os dois salários — 100% “entre grupos”, 0% “dentro dos grupos”. Na prática, dentro de qualquer departamento real também existe variação de salário entre as pessoas — e o índice de Theil separa exatamente quanto da desigualdade total vem de cada uma dessas duas fontes.

5. Como funciona, em linhas gerais

1. Calcula-se o índice de Theil para a população inteira, uma medida de dispersão relativa da renda em relação à média.

Decomposição do índice de Theil



Dados ilustrativos, não representam nenhum projeto real.

Figura 4: Barra empilhada mostrando a divisão da desigualdade total de Theil entre a parcela “entre grupos” e a parcela “dentro dos grupos”

2. Calcula-se o índice de Theil dentro de cada grupo separadamente (usando só as observações daquele grupo).
3. A parcela “entre grupos” é calculada como se cada pessoa dentro de um grupo recebesse a renda média do seu grupo — captura só a variação entre as médias dos grupos.
4. A parcela “dentro dos grupos” é a média ponderada (pela participação de cada grupo na renda total) dos índices de Theil calculados dentro de cada grupo.
5. As duas parcelas somadas reproduzem exatamente o índice de Theil total.
6. Paralelamente, o índice de Gini é calculado dentro de cada grupo para comparar concentração, e quantis ponderados são estimados dentro de cada grupo usando os pesos amostrais de cada observação.

6. O que o resultado significa

Se a parcela “entre grupos” for pequena em relação ao total, isso significa que a maior parte da desigualdade de renda está distribuída dentro de cada grupo, não entre eles — mesmo que a diferença média entre os grupos seja grande e estatisticamente significativa. As duas coisas não se contradizem: um gap entre grupos pode ser real e importante, e ainda assim representar uma fração pequena da desigualdade total, porque a desigualdade dentro de cada grupo também é grande.

7. Como interpretar

É um erro comum concluir que “só 7% da desigualdade vem da raça, então a desigualdade racial não é importante”. Isso confunde duas perguntas diferentes: (1) o gap médio entre grupos é grande e significativo? e (2) que fração da variância total de renda esse gap explica? A resposta à primeira pergunta pode ser “sim, é grande e significativo” mesmo quando a resposta à segunda é “uma fração pequena do total” — porque a desigualdade dentro de cada grupo, por si só, já é enorme. Contextualizar o tamanho da parcela “entre grupos” é importante, mas não anula a importância do gap em si.

Da mesma forma, um Gini mais baixo num grupo não significa necessariamente “situação melhor” — pode simplesmente refletir uma distribuição mais comprimida perto da base, ou seja, todo mundo naquele grupo ganhando pouco de forma relativamente parecida, o que é diferente de “renda alta e bem distribuída”.

8. Quando é útil

Quando você quer contextualizar o tamanho de um gap entre grupos dentro do quadro geral de desigualdade — por exemplo, mostrar que, apesar de a maior parte da desigualdade de renda estar dentro de cada grupo racial (não entre eles), o gap entre grupos ainda é grande e estatisticamente robusto, e merece atenção por si só.

9. Cuidados importantes

- A fração “entre grupos” tende a ser pequena quando os grupos comparados são muito amplos e heterogêneos internamente (como grandes categorias demográficas) — isso é esperado e não deve ser usado para minimizar o gap.
- O índice de Theil exige valores estritamente positivos da variável de interesse (não funciona diretamente com renda zero ou negativa sem ajustes).

- Ao comparar índices de Gini entre grupos, sempre verificar se as distribuições subjacentes são comparáveis (mesma unidade, mesmo período) e lembrar que Gini mais baixo não é sinônimo de “melhor”.
- Quantis ponderados exigem o uso correto dos pesos amostrais da pesquisa — ignorar os pesos produz estimativas enviesadas quando a amostragem não é simples aleatória.

10. Um exemplo pequeno com números

Suponha uma população hipotética dividida em dois grupos:

- Grupo A: renda média = 4.000, Theil interno = 0,25.
- Grupo B: renda média = 2.800, Theil interno = 0,30.
- Grupo A representa 40% da renda total da população; Grupo B, 60%.

O índice de Theil “entre grupos” (calculado a partir da diferença das médias, ponderada pela participação na renda) resulta em aproximadamente 0,04. O índice de Theil “dentro dos grupos” é a média ponderada dos dois Theils internos: $0,4 \times 0,25 + 0,6 \times 0,30 = 0,28$. Somando as duas partes, o Theil total é aproximadamente 0,32.

Isso significa que a parcela “entre grupos” representa cerca de $0,04 / 0,32 = 12,5\%$ da desigualdade total — a maior parte (87,5%) vem da desigualdade que já existe dentro de cada grupo, mesmo com uma diferença de renda média substancial entre os grupos (4.000 vs. 2.800, uma diferença de mais de 40%).

11. Exemplo de código simples

```
import numpy as np

def theil_index(renda):
    renda = np.asarray(renda, dtype=float)
    media = renda.mean()
    return np.mean((renda / media) * np.log(renda / media))

def gini_index(renda):
    renda = np.sort(np.asarray(renda, dtype=float))
    n = len(renda)
    indices = np.arange(1, n + 1)
    return (2 * np.sum(indices * renda) - (n + 1) * np.sum(renda)) / (n * np.sum(renda))

# dados ilustrativos
grupo_a = np.array([...]) # rendas individuais, Grupo A
grupo_b = np.array([...]) # rendas individuais, Grupo B

theil_total = theil_index(np.concatenate([grupo_a, grupo_b]))
theil_a = theil_index(grupo_a)
theil_b = theil_index(grupo_b)

participacao_a = grupo_a.sum() / (grupo_a.sum() + grupo_b.sum())
participacao_b = 1 - participacao_a
```

```
theil_dentro = participacao_a * theil_a + participacao_b * theil_b  
theil_entre = theil_total - theil_dentro
```

```
percentil_90_a = np.average(np.quantile(grupo_a, 0.9)) # com pesos amostrais, usar np.average
```

Para pesquisas com amostragem complexa (pesos, estratos, conglomerados), bibliotecas como `samplics` em Python, ou o pacote `survey` em R, calculam quantis e índices de desigualdade ponderados corretamente, incluindo seus erros-padrão.

Índice de dissimilaridade de Duncan

1. Que problema isso resolve?

Dois grupos trabalham nas mesmas categorias de ocupação — ou um grupo está concentrado em certas funções enquanto o outro domina outras? Se você olhar uma tabela com a distribuição percentual de cada grupo por categoria ocupacional, é difícil dizer, só de bater o olho, o quão desigual é essa distribuição. O índice de dissimilaridade de Duncan (também chamado de índice de segregação) resume essa comparação em um único número entre 0 e 1.

2. Intuição

Imagine reorganizar fisicamente as pessoas de dois grupos entre um conjunto de categorias, com o objetivo de fazer as duas distribuições percentuais ficarem idênticas. O índice de Duncan mede, essencialmente, **qual fração de um dos grupos precisaria mudar de categoria** para que isso acontecesse. Se nenhuma realocação for necessária, os grupos já estão igualmente distribuídos. Se quase todo mundo de um grupo precisasse trocar de categoria, a segregação entre os grupos é praticamente total.

3. Explicação simples

Para cada categoria (por exemplo, cada ocupação), calcule a proporção do Grupo A que está naquela categoria e a proporção do Grupo B que está na mesma categoria. Subtraia uma da outra, ignore o sinal (pegue o valor absoluto) e some essas diferenças em todas as categorias. Divida por dois. O resultado é o índice de Duncan: 0 significa distribuições idênticas entre as categorias; 1 significa segregação completa, ou seja, nenhuma categoria é compartilhada pelos dois grupos.


4. Exemplo conceitual fácil

Suponha duas equipes de vendas, A e B, distribuídas entre quatro filiais. Se em cada filial a proporção de vendedores de A é igual à proporção de vendedores de B, o índice é 0 — não existe segregação por filial. Se, ao contrário, A está inteiramente na filial Norte e B está inteiramente na filial Sul, o índice é 1 — segregação completa. Na prática, o valor quase sempre fica em algum ponto intermediário.

5. Como funciona, em linhas gerais

1. Defina as categorias que importam (ocupação, filial, bairro, o que fizer sentido para a pergunta).
2. Calcule, dentro de cada grupo, a proporção de pessoas em cada categoria — não a contagem bruta, porque os grupos podem ter tamanhos diferentes.
3. Para cada categoria, calcule a diferença absoluta entre as duas proporções.
4. Some todas as diferenças e divida por dois.

O passo de dividir por dois evita contar a mesma “distância” duas vezes — sem ele, o índice variaria de 0 a 2, não de 0 a 1.



Dados ilustrativos, não representam nenhum projeto real.

Figura 5: Distribuição ocupacional de dois grupos, com o índice de Duncan resultante

6. O que o resultado significa

Um índice de 0,25, por exemplo, indica que cerca de 25% de um dos grupos precisaria mudar de categoria para igualar as duas distribuições. Não existe um limiar universal de “alto” ou “baixo” — o valor precisa ser comparado com outros contextos (outro país, outro período, outro par de grupos) para ganhar significado prático.

7. Como interpretar

O índice descreve **quão desigual é a distribuição entre categorias**, não **por que** ela é desigual. Um valor alto é compatível com várias histórias diferentes: diferenças reais de qualificação entre os grupos, barreiras de acesso a certas categorias, escolhas voluntárias de carreira, ou uma combinação de tudo isso. O índice, sozinho, não separa essas explicações.

8. Quando é útil

É a ferramenta padrão para medir segregação ocupacional, residencial ou educacional entre grupos demográficos — raça, gênero, região. No Hub-Racial-Brasil, esse tipo de índice mede o quanto dois grupos raciais estão distribuídos de forma desigual entre categorias ocupacionais, servindo de complemento a análises de diferença de renda: parte do gap salarial pode estar ligada à concentração de um grupo em ocupações piores remuneradas.

9. Cuidados importantes

- O valor do índice depende diretamente de como as categorias foram definidas. Agrupar ocupações de forma mais grossa ou mais fina muda o resultado — sempre compare índices calculados com a mesma classificação.
- Categorias com poucas observações tornam a proporção instável, inflando ou reduzindo o índice de forma artificial.

- O índice não tem sinal — ele não diz qual grupo está “por cima”; só mede a distância entre as duas distribuições.

10. Um exemplo pequeno com números

Categoria	% do Grupo A	% do Grupo B	Diferença absoluta
Operacional	15%	30%	15
Administrativo	25%	25%	0
Técnico	30%	25%	5
Gerência	30%	20%	10

Soma das diferenças absolutas: $15 + 0 + 5 + 10 = 30$. Dividindo por dois: índice de Duncan = 15, ou 0,15 em escala de 0 a 1. Isso significa que 15% de um dos grupos precisaria mudar de categoria para igualar as duas distribuições — uma segregação moderada, concentrada principalmente nas categorias operacional e de gerência.

11. Exemplo de código simples

```
import numpy as np
import pandas as pd

# proporções de cada grupo por categoria (devem somar 1 em cada coluna)
dados = pd.DataFrame({
    "categoria": ["operacional", "administrativo", "tecnico", "gerencia"],
    "grupo_a": [0.15, 0.25, 0.30, 0.30],
    "grupo_b": [0.30, 0.25, 0.25, 0.20],
})

indice_duncan = 0.5 * np.sum(np.abs(dados["grupo_a"] - dados["grupo_b"]))
print(f"Índice de dissimilaridade: {indice_duncan:.3f}")
```

Teste de quebra estrutural (tipo Chow)

1. Que problema isso resolve?

Uma série ao longo do tempo — uma taxa de participação, um preço médio, uma proporção — parece ter mudado de comportamento num momento específico e conhecido de antemão: o início de uma pandemia, a entrada em vigor de uma lei, uma crise econômica documentada. Será que essa mudança é real, ou pode ser apenas flutuação normal da série? O teste de quebra estrutural, na tradição do teste de Chow, responde a essa pergunta especificamente quando a data do possível evento já é conhecida antes de olhar os dados.

2. Intuição

Se nada de especial tivesse acontecido naquele momento, o comportamento da série antes e depois da data escolhida deveria continuar seguindo, aproximadamente, o mesmo padrão — mesma tendência, mesma relação com outras variáveis. O teste ajusta um modelo separado para cada um dos dois pedaços da série (antes e depois da data) e verifica se esses dois modelos são estatisticamente diferentes o suficiente para rejeitar a ideia de que vêm de um único processo contínuo.

3. Explicação simples


Existem três formas de ajustar o mesmo tipo de modelo: uma só para toda a série (ignorando a possível quebra), uma separada para o período antes da data e outra separada para o período depois. Se o ajuste “com quebra” (dois modelos separados) explica os dados muito melhor do que o ajuste “sem quebra” (um único modelo), isso é evidência de que algo mudou de fato na data indicada.

4. Exemplo conceitual fácil

Imagine o número de pedidos diários de um restaurante ao longo de dois anos, com uma data conhecida em que o cardápio mudou completamente. Antes da mudança, os pedidos cresciam de forma lenta e estável. Depois, cresceram muito mais rápido. Um teste de quebra estrutural nessa data específica verifica se essa diferença de padrão é grande demais para ser só coincidência de amostragem.

5. Como funciona, em linhas gerais

1. Escolha a data do evento **antes** de olhar os resultados — o teste perde validade se a data for escolhida depois de observar onde a série “parece” ter mudado.
2. Ajuste um único modelo (por exemplo, uma reta de tendência) usando toda a série.
3. Ajuste dois modelos separados: um só com os dados antes da data, outro só com os dados depois.
4. Compare o quanto os dois modelos separados reduzem o erro de ajuste em relação ao modelo único, usando uma estatística F.
5. Um valor-p baixo indica que a quebra melhora o ajuste mais do que seria esperado por acaso — evidência de mudança estrutural.



Dados ilustrativos, não representam nenhum projeto real.

Figura 6: Série com quebra estrutural em ponto conhecido a priori

6. O que o resultado significa

Um teste significativo diz que o comportamento da série antes e depois da data escolhida é estatisticamente diferente. Isso é consistente com “algo relevante aconteceu naquele momento” — mas o teste, sozinho, não prova que foi exatamente o evento que você tinha em mente.

7. Como interpretar

O resultado é evidência de correlação temporal com a data escolhida, não de causalidade. Se outro evento relevante aconteceu perto da mesma data — uma crise cambial perto de uma reforma trabalhista, por exemplo — o teste não consegue, sozinho, atribuir a mudança a um ou outro. É preciso julgamento de contexto, e idealmente outras fontes de evidência, para interpretar a causa.

8. Quando é útil

É útil sempre que existe uma data de interesse definida de antemão por motivos externos aos dados — uma lei, uma política, um evento histórico. No Hub-Racial-Brasil, esse teste é usado para verificar se a participação de um grupo no mercado de trabalho mudou de padrão num momento específico conhecido, como o início de uma crise ou a implementação de uma política.

9. Cuidados importantes

- Esse é um teste de **uma** quebra conhecida a priori — não uma busca por múltiplas quebras em datas desconhecidas (esse é um problema diferente, resolvido por métodos como o de Bai-Perron).
- Escolher a data depois de já ter visto onde a série “parece” quebrar invalida o teste — o valor-p deixa de ter a interpretação usual.
- O teste assume uma forma específica de modelo (geralmente linear) em cada pedaço da série; se a relação verdadeira for muito diferente disso, o resultado pode enganar.

- Séries curtas antes ou depois da data reduzem a capacidade do teste de detectar uma quebra real que de fato exista.

10. Um exemplo pequeno com números

Uma série de 40 observações tem, antes da data de corte, um coeficiente angular estimado de 0,15 por período. Depois da data de corte, o coeficiente estimado sobe para 0,55 por período, e o nível médio da série também sobe. Ajustando o modelo único (sem quebra) versus os dois modelos separados, a estatística F resultante é 4,35, com valor-p de 0,021 — abaixo do limiar convencional de 0,05. Conclusão: há evidência de mudança de padrão na data escolhida.

11. Exemplo de código simples

```
import numpy as np
import statsmodels.api as sm

# serie: array com a variável de interesse ao longo do tempo
# indice_quebra: posição conhecida a priori onde a quebra é testada
def teste_chow(serie, tempo, indice_quebra):
    X_completo = sm.add_constant(tempo)
    modelo_completo = sm.OLS(serie, X_completo).fit()
    rss_completo = modelo_completo.ssr

    X1 = sm.add_constant(tempo[:indice_quebra])
    X2 = sm.add_constant(tempo[indice_quebra:])
    rss1 = sm.OLS(serie[:indice_quebra], X1).fit().ssr
    rss2 = sm.OLS(serie[indice_quebra:], X2).fit().ssr

    k = X_completo.shape[1]
    n = len(serie)
    f_stat = ((rss_completo - (rss1 + rss2)) / k) / ((rss1 + rss2) / (n - 2 * k))
    return f_stat
```

Diferenças-em-diferenças (DiD)

1. Que problema isso resolve?

Uma política, uma lei ou um evento afetou um grupo específico, enquanto outro grupo parecido ficou de fora. Como saber se a mudança observada no grupo afetado depois do evento é resultado do próprio evento, e não só a continuação de uma tendência que já estava acontecendo de qualquer forma? O desenho de diferenças-em-diferenças (DiD) usa o grupo não afetado como referência para responder essa pergunta com uma leitura mais próxima de causal do que uma simples comparação de antes e depois.

2. Intuição

Comparar só o grupo afetado antes e depois do evento é enganoso, porque muita coisa muda ao longo do tempo por razões que não têm nada a ver com o evento. A solução é comparar a **mudança** no grupo afetado com a **mudança** no grupo não afetado, no mesmo período. Se os dois grupos vinham seguindo trajetórias parecidas antes do evento, a diferença entre as duas mudanças pode ser atribuída, com mais segurança, ao próprio evento.

3. Explicação simples

O nome “diferença em diferenças” vem exatamente disso: primeiro você calcula a diferença (mudança) dentro de cada grupo, depois calcula a diferença entre essas duas diferenças. Esse desenho básico pode ser estendido de várias formas: comparando **coortes** definidas por quando nasceram ou entraram em algum sistema (desenho por coorte), acompanhando o efeito **período a período** relativo ao momento do evento (event-study), e testando se o resultado se sustenta em **datas falsas** (placebo) — um passo essencial de verificação, não um detalhe opcional.


4. Exemplo conceitual fácil

Imagine uma cidade que introduziu um novo programa de transporte público gratuito para estudantes, enquanto uma cidade vizinha parecida não introduziu nada. Antes do programa, a frequência escolar nas duas cidades vinha subindo de forma parecida. Depois do programa, a frequência na cidade que adotou o programa subiu bem mais rápido do que na cidade vizinha. A diferença entre essas duas mudanças é a estimativa do efeito do programa.

5. Como funciona, em linhas gerais

1. Defina claramente o grupo tratado (afetado pelo evento) e o grupo de controle (não afetado), e o momento do evento.
2. Verifique a suposição de **tendências paralelas**: os dois grupos seguiam trajetórias parecidas antes do evento? Isso é feito comparando visualmente e estatisticamente os períodos anteriores à intervenção.
3. Estime a diferença nas mudanças médias entre os dois grupos, do período pré para o período pós-evento.
4. Quando há vários períodos de dados, um **event-study** estima o efeito separadamente para cada período relativo ao evento, em vez de um único número agregado — isso revela se o efeito aparece de forma abrupta, se cresce com o tempo, ou se já existia uma diferença antes do evento (o que enfraqueceria a suposição de tendências paralelas).

5. Rode testes de **placebo**: aplique o mesmo desenho a uma data falsa, sem mudança real de política, e verifique se aparece um “efeito” mesmo assim. Se aparecer, isso é sinal de alerta sobre o desenho.



Dados ilustrativos, não representam nenhum projeto real.

Figura 7: Grupo tratado e grupo de controle antes e depois da intervenção

6. O que o resultado significa

O efeito estimado é a diferença entre a mudança do grupo tratado e a mudança do grupo de controle, no mesmo período. Com boas tendências paralelas antes do evento e ausência de efeito nos testes de placebo, essa diferença tem uma leitura causal razoavelmente defensável — mais forte do que compará-la a uma simples série de antes e depois de um único grupo.

7. Como interpretar

DiD dá uma leitura causal **mais forte** que comparar antes e depois de um único grupo, mas ainda **depende** da suposição de tendências paralelas — ou seja, de que, na ausência do evento, os dois grupos teriam continuado a seguir trajetórias parecidas. Essa suposição não é diretamente testável para o período pós-evento (é justamente o que não observamos); o que se pode testar é se ela se sustentava no período pré-evento. “Tendências paralelas sustentadas no pré-período” não é prova de que a suposição vale — é apenas evidência de que os dados não contradizem essa suposição, o que é uma leitura bem mais fraca.

8. Quando é útil

É útil sempre que existe uma política ou evento com um grupo claramente afetado e outro claramente não afetado, com dados disponíveis antes e depois. No Hub-Racial-Brasil, esse desenho é usado para explorar se uma lei — como uma política de cotas raciais — teve efeito causal, comparando coortes nascidas antes e depois de uma data de corte, ou setores afetados e não afetados pela lei ao longo do tempo.

9. Cuidados importantes

- “Não encontrar efeito” não é o mesmo que “não há efeito” — um desenho com poucos grupos, poucos períodos, ou métrica muito ruidosa pode simplesmente não ter poder estatístico suficiente para detectar um efeito real.
- Escolha do grupo de controle importa muito: um grupo pouco comparável ao tratado enfraquece a suposição de tendências paralelas.
- Sempre reporte os resultados de placebo junto com o efeito principal — reportar só o resultado favorável é uma forma comum (e enganosa) de apresentar DiD.

10. Um exemplo pequeno com números

Antes do evento, o indicador do grupo tratado sobe de 40 para 47 (mudança de +7); no grupo de controle, sobe de 40 para 46 (mudança de +6) — tendências muito parecidas. Depois do evento, o grupo tratado sobe de 47 para 68 (mudança de +21); o grupo de controle sobe de 46 para 53 (mudança de +7). A estimativa DiD é $(21 - 7) = 14$ unidades de efeito atribuível ao evento, acima do que já era esperado pela tendência natural comum aos dois grupos.

11. Exemplo de código simples

```
import pandas as pd
import statsmodels.formula.api as smf

# dados_painel: colunas [unidade, periodo, tratado, pos, resultado]
# tratado: 1 se pertence ao grupo tratado, 0 caso contrário
# pos: 1 se período é depois do evento, 0 caso contrário
modelo = smf.ols("resultado ~ tratado * pos", data=dados_painel).fit(
    cov_type="cluster", cov_kwds={"groups": dados_painel["unidade"]}
)
print(modelo.params["tratado:pos"]) # estimativa do efeito DiD
print(modelo.pvalues["tratado:pos"])
```

Análise de transições em painel rotativo

1. Que problema isso resolve?

Comparar duas fotografias isoladas — a taxa de desemprego de um grupo neste trimestre e a taxa de desemprego do mesmo grupo no trimestre seguinte — não diz nada sobre o que aconteceu com as pessoas individualmente. Será que foram as mesmas pessoas que continuaram desempregadas, ou uma leva saiu do desemprego enquanto outra entrou, mantendo a taxa agregada parecida? Análise de transições em painel rotativo responde a essa pergunta acompanhando indivíduos ao longo de entrevistas sucessivas, não apenas comparando retratos agregados.

2. Intuição

Algumas pesquisas domiciliares entrevistam o mesmo domicílio (e, na medida do possível, os mesmos moradores) várias vezes ao longo de um período — esse é o “painel rotativo”: uma parte da amostra é substituída a cada rodada, mas outra parte permanece, permitindo observar a mesma pessoa em entrevistas consecutivas. Isso possibilita perguntar diretamente: de quem estava desempregado na primeira entrevista, que fração estava empregada na entrevista seguinte? E essa fração é diferente entre grupos?

3. Explicação simples

Depois de parear os registros da mesma pessoa entre entrevistas consecutivas, constrói-se uma **matriz de transição**: linhas representam o estado inicial (por exemplo, desempregado), colunas representam o estado seguinte (por exemplo, empregado formal, empregado informal, desempregado, fora da força de trabalho), e cada célula mostra a proporção de pessoas que fez aquela transição específica. Comparar essa matriz entre grupos revela diferenças de mobilidade que uma comparação de taxas agregadas não capturaria.

4. Exemplo conceitual fácil

Imagine dois grupos de clientes de um serviço de assinatura, ambos com a mesma taxa de cancelamento agregada num mês. No Grupo A, quase todo mundo que cancelou já vinha sinalizando insatisfação havia meses. No Grupo B, os cancelamentos vêm de clientes recém-chegados que nunca chegaram a usar o serviço de verdade. A taxa agregada é igual, mas a história por trás dela — e a ação recomendada — é completamente diferente. Acompanhar transições individuais é o que revela essa diferença.

5. Como funciona, em linhas gerais

1. Identifique, na base de dados, os registros que correspondem à mesma pessoa em entrevistas consecutivas — normalmente por um identificador de domicílio combinado com características que ajudam a confirmar que é a mesma pessoa (idade, sexo, relação com o responsável pelo domicílio).
2. Descarte ou trate separadamente os casos em que o pareamento falha — pessoas que mudaram de domicílio, domicílios com troca de morador, ou registros inconsistentes.
3. Para cada par de entrevistas consecutivas, classifique o estado da pessoa em cada momento (empregado, desempregado, fora da força de trabalho, por exemplo).
4. Construa a matriz de transição, separadamente para cada grupo de interesse.

5. Compare as taxas de transição específicas (por exemplo, a probabilidade de sair do desemprego) entre os grupos, com o devido teste de significância.




Figura 8: Probabilidade acumulada de sair do desemprego, por grupo

6. O que o resultado significa

Uma taxa de transição maior para um grupo — por exemplo, sair do desemprego com mais frequência — indica maior mobilidade real observada para aquele grupo nesse painel específico, algo que uma comparação de taxas agregadas entre dois momentos isolados não conseguiria distinguir de simples substituição de composição.

7. Como interpretar

A taxa de transição descreve o que aconteceu com as pessoas efetivamente pareadas entre entrevistas — não com toda a população. Se o pareamento falhar de forma sistematicamente diferente entre os grupos (por exemplo, se um grupo tiver taxas de mudança de domicílio mais altas, e por isso for mais difícil de acompanhar), as taxas de transição estimadas podem não representar corretamente a experiência de todo o grupo, e sim apenas da fração dele que permaneceu rastreável.

8. Quando é útil

É a ferramenta certa sempre que a pergunta é sobre mobilidade individual — transições entre emprego e desemprego, entre formalidade e informalidade, entre faixas de renda — e a pesquisa usada tem desenho de painel rotativo (a mesma unidade entrevistada mais de uma vez). No Hub-Racial-Brasil, esse tipo de análise usa o fato de a mesma pessoa aparecer em algumas entrevistas consecutivas de uma pesquisa domiciliar para acompanhar transições individuais e comparar taxas de mobilidade entre grupos raciais.

9. Cuidados importantes

- Paineis rotativos **não é** o mesmo que um painel longitudinal completo, em que a mesma amostra inteira é seguida por muitos anos — no painel rotativo, cada pessoa só é observada por um número limitado de rodadas antes de sair da amostra.
- Boa parte dos dados de painéis rotativos é, na verdade, repeated cross-section (corte transversal repetido) fora da janela em que o pareamento é possível — é essencial saber exatamente quais rodadas permitem acompanhar a mesma pessoa.
- O pareamento entre entrevistas pode falhar por vários motivos: mudança de domicílio, substituição de morador, erros de digitação em identificadores, ou simples atrito amostral (a pessoa não é mais localizada). A taxa de sucesso do pareamento deve sempre ser reportada.
- Se a taxa de sucesso do pareamento for diferente entre os grupos comparados, isso pode introduzir viés de seleção nos resultados — vale testar isso explicitamente.

10. Um exemplo pequeno com números

De um total de 500 pessoas desempregadas do Grupo A na primeira entrevista, foi possível parear 420 (84%) com uma segunda entrevista um trimestre depois; dessas, 92 estavam empregadas — taxa de transição de 21,9%. Do Grupo B, de 480 pessoas desempregadas, 390 (81%) foram pareadas; dessas, 59 estavam empregadas — taxa de 15,1%. A diferença de quase 7 pontos percentuais é testada estatisticamente (por exemplo, com um teste de proporções) para verificar se é grande demais para ser atribuída ao acaso.

11. Exemplo de código simples

```
import pandas as pd
from statsmodels.stats.proportion import proportions_ztest

# base_pareada: uma linha por pessoa pareada com sucesso,
# colunas: grupo, estado_t0, estado_t1
desempregados_t0 = base_pareada[base_pareada["estado_t0"] == "desempregado"]

transicao_por_grupo = desempregados_t0.groupby("grupo")["estado_t1"].apply(
    lambda s: (s == "empregado").mean()
)
print(transicao_por_grupo)

contagens = desempregados_t0.groupby("grupo")["estado_t1"].apply(
    lambda s: (s == "empregado").sum()
)
totais = desempregados_t0.groupby("grupo").size()
estatistica, p_valor = proportions_ztest(contagens.values, totais.values)
print(estatistica, p_valor)
```

Fundamentos de teste A/B

1. Que problema isso resolve?

Uma equipe de produto muda alguma coisa — o texto de um botão, a ordem de duas etapas de cadastro, um novo algoritmo de recomendação — e quer saber se essa mudança realmente melhora o resultado que importa, ou se qualquer variação observada depois do lançamento é só ruído do dia a dia. Comparar “antes” com “depois” não resolve isso sozinho, porque muita coisa além da mudança testada também varia com o tempo (sazonalidade, uma campanha de marketing, um feriado). O teste A/B resolve isso comparando duas versões ao mesmo tempo, em grupos de usuários formados por sorteio.

2. Intuição

Se você dividir aleatoriamente um grupo grande de usuários em dois, os dois subgrupos tendem a ser parecidos em tudo — idade, dispositivo, hábito de compra, humor do dia — exceto na única coisa que você decidiu diferenciar entre eles: qual versão do produto cada um viu. Se depois disso o resultado médio dos dois grupos for diferente, a explicação mais simples é a própria mudança testada, não uma diferença pré-existente entre os usuários. É essa lógica — comparação simultânea com atribuição aleatória — que dá ao teste A/B uma leitura mais confiável do que comparar períodos diferentes de tempo.

3. Explicação simples


Depois de rodar o experimento por tempo suficiente, calcula-se a diferença entre a métrica média (ou proporção) do grupo tratamento e do grupo controle. Essa diferença observada quase nunca será exatamente zero, mesmo que a mudança não tenha efeito real nenhum — sempre existe variação de amostragem. O teste de hipótese pergunta: essa diferença é grande o suficiente, dado o tamanho dos grupos e a variabilidade da métrica, para não ser plausivelmente explicada só por acaso? O intervalo de confiança de 95% em volta da diferença mostra a faixa de valores plausíveis para o efeito real, não só um número único.

4. Exemplo conceitual fácil

Imagine um site que testa uma nova cor de botão de “finalizar compra”. Metade dos visitantes, sorteados aleatoriamente, vê o botão azul de sempre; a outra metade vê o botão verde novo. Depois de duas semanas, compara-se a taxa de conversão dos dois grupos. Como a divisão foi aleatória, qualquer diferença consistente e grande o suficiente entre os dois grupos tende a vir da cor do botão — não de um grupo ter, por coincidência, mais usuários propensos a comprar.

5. Como funciona, em linhas gerais

1. Define-se, antes de rodar o experimento, uma métrica primária (por exemplo, taxa de conversão) e o tamanho de amostra necessário.
2. Cada usuário elegível é designado aleatoriamente para controle ou tratamento, geralmente numa proporção fixa (50/50 é comum, mas não obrigatória).
3. O experimento roda por um período pré-definido, sem espiar o resultado repetidamente e tomar decisões no meio do caminho.
4. Calcula-se a diferença entre as médias (ou proporções) dos dois grupos, o erro-padrão dessa diferença, e a partir daí a estatística de teste, o valor-p e o intervalo de confiança de 95%.



Dados ilustrativos, não representam nenhum projeto real.

Figura 9: Barras de conversão do grupo controle e do grupo tratamento, cada uma com seu intervalo de confiança de 95%

5. Antes de confiar no resultado, checa-se se a randomização funcionou como planejado — é aqui que entram testes complementares como o de Sample Ratio Mismatch e a checagem de balanceamento de covariáveis.

6. O que o resultado significa

Um valor-p baixo (tipicamente abaixo de 0,05) indica que uma diferença desse tamanho seria incomum se, na realidade, a mudança não tivesse efeito algum — evidência a favor de um efeito real. O intervalo de confiança mostra a magnitude plausível desse efeito: um IC estreito e distante de zero sugere um efeito real e razoavelmente bem estimado; um IC largo, mesmo que não cruze o zero, indica uma estimativa ainda incerta sobre o tamanho exato do efeito.

7. Como interpretar

Significância estatística não é o mesmo que importância prática: um efeito de 0,1 ponto percentual pode ser estatisticamente significativo com amostra grande o suficiente, mas irrelevante para a decisão de negócio. E “não significativo” não é o mesmo que “sem efeito” — pode simplesmente significar que o experimento não teve amostra suficiente para detectar um efeito do tamanho que de fato existe. Vale sempre olhar o tamanho do efeito e seu intervalo de confiança junto com o valor-p, nunca o valor-p isolado.

8. Quando é útil

Sempre que for possível randomizar quem recebe cada versão de um produto, processo ou comunicação, e existir uma métrica primária clara para julgar o resultado — típico em testes de interface, algoritmos de recomendação, políticas de preço, ou fluxos de cadastro. Esses fundamentos — efeito, erro- padrão, IC 95%, teste de hipótese — são o ponto de partida para praticamente qualquer leitura mais avançada de experimento, incluindo checagens de integridade da randomização, ajuste por covariáveis e testes de não-inferioridade.

9. Cuidados importantes

- A validade do teste depende da randomização ter funcionado de fato — nunca assuma isso sem checar (ver Sample Ratio Mismatch).
- Olhar o resultado repetidamente enquanto o experimento roda e parar assim que ele “fica significativo” infla a taxa de falso positivo — defina o tamanho de amostra e o período antes de começar.
- Testar muitas métricas secundárias ao mesmo tempo aumenta a chance de achar algo “significativo” por acaso; trate achados secundários como hipóteses para o próximo experimento, não como conclusões.
- Um efeito estatisticamente significativo em uma métrica pode vir acompanhado de piora em outra (uma métrica de guardrail) — é para isso que existe o teste de não-inferioridade.

10. Um exemplo pequeno com números

Um site testa um novo botão de finalização de compra contra o botão atual, com 12.000 visitantes em cada grupo. O grupo controle converte a 8,2%; o grupo tratamento converte a 9,4% — uma diferença de 1,2 ponto percentual, ou um aumento relativo de aproximadamente 15%. O erro-padrão da diferença, calculado a partir do tamanho de cada grupo e da variabilidade de uma taxa

de conversão, resulta numa estatística z de aproximadamente 3,0 e num valor- p abaixo de 0,01. O intervalo de confiança de 95% para a diferença fica aproximadamente entre 0,4 e 2,0 pontos percentuais — inteiramente acima de zero, reforçando que o ganho é improvável de ser só ruído amostral.

11. Exemplo de código simples

```
import numpy as np
from statsmodels.stats.proportion import proportions_ztest, confint_proportions_2indep

conversoes = np.array([984, 1128])      # ilustrativo: controle, tratamento
visitantes = np.array([12000, 12000])  # ilustrativo

estatistica, valor_p = proportions_ztest(conversoes, visitantes)
ic_baixo, ic_alto = confint_proportions_2indep(
    conversoes[1], visitantes[1], conversoes[0], visitantes[0], method="wald"
)

print(f"z = {estatistica:.2f}, valor-p = {valor_p:.4f}")
print(f"IC 95% da diferença: [{ic_baixo:.4f}, {ic_alto:.4f}]")
```

O teste de duas proporções resume, numa única estatística, se a diferença observada entre as taxas de conversão dos dois grupos é grande demais para ser explicada só por variação amostral.

Teste de Sample Ratio Mismatch (SRM)

Pressupõe os fundamentos de teste A/B — veja [Fundamentos de teste A/B](#) para o vocabulário de aleatorização, grupos e métrica primária usado aqui.

1. Que problema isso resolve?

Um experimento foi planejado com uma divisão específica entre os grupos — 50/50 é a mais comum, mas pode ser 90/10, 70/30, ou qualquer outra proporção definida de antemão. Depois de rodar, será que essa proporção realmente saiu como planejado? Se o sistema de randomização tiver um bug, se algum tipo de usuário estiver sendo perdido de forma diferente entre os grupos, ou se o critério de elegibilidade interagir mal com a atribuição, a divisão real pode sair torta — e, quando isso acontece, nada do que o experimento medir depois pode ser interpretado com confiança.

2. Intuição

Se você jogar uma moeda honesta 20.000 vezes, não espera exatamente 10.000 caras e 10.000 coroas — mas espera algo bem próximo disso, com um desvio que segue um padrão previsível. Um SRM (Sample Ratio Mismatch, ou “descompasso na proporção de amostra”) acontece quando o desvio da proporção planejada é grande demais para ser explicado por esse acaso esperado. É basicamente perguntar: “essa moeda ainda é honesta, ou tem algo quebrado nela?” — só que a moeda, aqui, é o próprio mecanismo de randomização do experimento.

3. Explicação simples


O teste compara a contagem observada de usuários em cada braço do experimento com a contagem que se esperaria sob a proporção planejada, usando um teste qui-quadrado (ou, de forma equivalente para dois grupos, um teste binomial). Quanto maior a distância entre observado e esperado, mais evidência de que a randomização não está funcionando como deveria.

4. Exemplo conceitual fácil

Um app planeja testar uma nova tela de onboarding para 50% dos novos usuários, mantendo os outros 50% na tela atual. Ao final do experimento, o grupo da tela atual tem 10.432 usuários e o grupo da tela nova tem 9.568 — uma diferença de quase 900 usuários. Isso pode ser só flutuação normal, ou pode ser sinal de que, por algum motivo técnico, usuários de um certo tipo de dispositivo estão sendo excluídos do grupo novo antes mesmo de serem contados. O teste de SRM ajuda a decidir qual dos dois cenários é mais plausível.

5. Como funciona, em linhas gerais

1. Define-se a proporção planejada de alocação entre os braços (por exemplo, 50%/50%).
2. Conta-se quantos usuários efetivamente caíram em cada braço ao final do experimento (ou de um período de checagem).
3. Calcula-se a contagem esperada em cada braço, aplicando a proporção planejada ao total observado.
4. Aplica-se um teste qui-quadrado de aderência (goodness-of-fit) comparando contagens observadas e esperadas, produzindo um valor-p.
5. Um valor-p muito baixo (o critério comum é bem mais rígido que o de um teste de efeito, algo como 0,001, porque um falso alarme aqui pára o experimento inteiro) é o sinal de alerta.



Dados ilustrativos, não representam nenhum projeto real.

Figura 10: Barras comparando a proporção planejada e a proporção observada em cada braço do experimento

6. O que o resultado significa

Um SRM não significativo não prova que a randomização está perfeita — apenas que a proporção observada é compatível com a planejada, dentro do que se espera de variação aleatória. Um SRM significativo é evidência de que a proporção real dos grupos se desviou da planejada mais do que o esperado por acaso — um sinal de que algo no mecanismo de atribuição, ou na forma como os usuários são contados, não está funcionando como deveria.

7. Como interpretar

Um SRM significativo não diz, por si só, qual é a causa do desbalanceamento — só que existe um problema a investigar antes de confiar em qualquer leitura de efeito do experimento. Causas comuns incluem: bugs no código de atribuição, diferenças na velocidade de carregamento entre as versões (fazendo uma delas “perder” mais usuários por timeout), filtros de bot ou de qualidade de tráfego aplicados de forma assimétrica, e problemas de log que registram um grupo de forma mais completa que o outro.

8. Quando é útil

Em todo experimento randomizado, como checagem de rotina antes de interpretar qualquer resultado de efeito — é o primeiro teste a rodar, não um extra opcional. É especialmente importante em experimentos com muitos sistemas técnicos envolvidos na atribuição (múltiplas plataformas, múltiplos pontos de entrada, filtros de elegibilidade complexos), onde a chance de um bug sutil quebrar a randomização é maior.

9. Cuidados importantes

- Um SRM significativo invalida a leitura de qualquer efeito medido até que a causa seja encontrada e corrigida — não adianta “olhar o efeito mesmo assim” ou tentar compensar o desbalanceamento estatisticamente depois.
- O critério de significância usado costuma ser mais rígido que o padrão 0,05 (algo como 0,001 ou menor), porque o custo de ignorar um SRM real é alto e a checagem é barata de rodar.
- Ausência de SRM na alocação geral não garante ausência de SRM em subgrupos específicos (um tipo de dispositivo, uma região) — vale checar por segmento quando a causa suspeita for localizada.
- SRM pode aparecer só em parte do período do experimento (por exemplo, um bug corrigido no meio do caminho) — olhar a proporção ao longo do tempo, não só o total acumulado, ajuda a diagnosticar isso.

10. Um exemplo pequeno com números

Um experimento foi planejado com divisão 50/50. Ao final, o grupo controle tem 10.432 usuários e o grupo tratamento tem 9.568, num total de 20.000. O valor esperado em cada braço, sob a proporção planejada, é 10.000. A estatística qui-quadrado é:

$$\chi^2 = \frac{(10.432 - 10.000)^2}{10.000} + \frac{(9.568 - 10.000)^2}{10.000} \approx 37,3$$

Com 1 grau de liberdade, esse valor corresponde a um valor-p extremamente baixo (bem abaixo de 0,001) — evidência forte de que a proporção observada não é compatível com uma divisão

50/50 aleatória. Antes de interpretar qualquer efeito medido nesse experimento, a causa dessa discrepância precisa ser encontrada.

11. Exemplo de código simples

```
from scipy.stats import chisquare
```

```
observado = [10432, 9568]          # ilustrativo
```

```
proporcao_planejada = [0.5, 0.5]
```

```
total = sum(observado)
```

```
esperado = [p * total for p in proporcao_planejada]
```

```
resultado = chisquare(f_obs=observado, f_exp=esperado)
```

```
print(f"qui-quadrado = {resultado.statistic:.2f}, valor-p = {resultado.pvalue:.6f}")
```

Um valor-p abaixo do limiar rígido usado para SRM (por exemplo, 0,001) é o sinal para parar e investigar antes de seguir com qualquer análise de efeito.

Balanceamento de covariáveis e ajuste por covariáveis

Pressupõe os fundamentos de teste A/B — veja [Fundamentos de teste A/B](#).

1. Que problema isso resolve?

Um experimento foi randomizado, mas será que os dois grupos realmente saíram parecidos em características que existiam antes do experimento começar — idade dos usuários, tempo de uso prévio do produto, comportamento histórico? E, separadamente: dado que existem essas características medidas antes do experimento, dá para usá-las para tornar a estimativa do efeito mais precisa, mesmo quando os grupos já estão bem balanceados? São duas perguntas relacionadas, mas diferentes, e é comum confundi-las.

2. Intuição

A checagem de balanceamento é uma auditoria: com grupos formados por sorteio, características que não deveriam ter relação nenhuma com a atribuição — porque foram medidas antes do experimento sequer existir — devem estar distribuídas de forma parecida entre os grupos. Se estiverem muito diferentes, isso é sinal de alerta sobre a randomização, não uma característica normal do desenho experimental.

Já o ajuste por covariáveis é outra coisa: mesmo com randomização perfeita, sempre existe alguma variação de usuário para usuário que não tem nada a ver com o tratamento. Se uma característica medida antes do experimento (como o valor de compra do mês anterior) ajuda a prever a métrica que está sendo testada, “descontar” essa característica da comparação reduz o ruído da estimativa — sem viesar o resultado, porque a característica foi medida antes de qualquer efeito do tratamento poder existir.


3. Explicação simples

Para balanceamento: compara-se, para cada covariável de interesse, a média (ou proporção) entre o grupo controle e o grupo tratamento, geralmente através da diferença padronizada de médias — a diferença dividida por um desvio-padrão combinado, o que permite comparar covariáveis em escalas bem diferentes (idade em anos, gasto em reais) numa régua comum.

Para ajuste: em vez de comparar só as médias brutas dos dois grupos, ajusta-se um modelo que já leva em conta essas covariáveis pré-experimento (uma regressão, por exemplo), ou usa-se pós-estratificação — dividir a amostra em estratos definidos pelas covariáveis e combinar as estimativas dentro de cada estrato. O resultado é uma estimativa do mesmo efeito, mas com erro-padrão menor.

4. Exemplo conceitual fácil

Um app de assinatura testa uma nova política de preço. Antes de olhar qualquer resultado do experimento, a equipe compara idade média, tempo de assinatura anterior e gasto médio do mês anterior entre o grupo controle e o grupo tratamento. Todas as três estão bem próximas entre os grupos — sinal de que a randomização funcionou. Depois, ao estimar o efeito da nova política sobre a receita, a equipe usa o gasto do mês anterior como covariável de ajuste, porque sabe que esse gasto passado é um bom preditor do gasto futuro — isso deixa a estimativa do efeito mais precisa, com um intervalo de confiança mais estreito, sem mudar seu significado.



Dados ilustrativos, não representam nenhum projeto real.

Figura 11: Gráfico de balanceamento (love plot) mostrando a diferença padronizada de cada covariável entre os grupos, com uma faixa de referência em torno de zero

5. Como funciona, em linhas gerais

Balanceamento (checagem pré-experimento): 1. Lista-se as covariáveis relevantes, medidas antes do início do experimento (nunca depois — covariáveis pós-tratamento podem já ter sido afetadas pelo próprio experimento). 2. Calcula-se a diferença padronizada de médias entre os grupos para cada covariável. 3. Compara-se cada diferença a um limite de referência comum (0,1 é um valor frequentemente usado na literatura) — abaixo disso, considera-se balanceamento aceitável.

Ajuste por covariáveis (redução de variância): 1. Escolhem-se covariáveis pré-experimento que sejam boas preditoras da métrica de interesse. 2. Ajusta-se um modelo (regressão linear simples, ou uma técnica como CUPED) que usa essas covariáveis para explicar parte da variação da métrica que não tem relação com o tratamento. 3. A estimativa do efeito do tratamento, depois desse ajuste, tem a mesma interpretação de antes, mas com erro-padrão reduzido.

6. O que o resultado significa

Balanceamento aceitável em todas as covariáveis observadas dá mais confiança de que os grupos eram comparáveis antes do experimento começar — reforçando a leitura causal do teste de efeito. O ajuste por covariáveis, por sua vez, não muda a interpretação do efeito estimado (ainda é a diferença causada pelo tratamento); ele só reduz a incerteza em torno dessa estimativa, permitindo detectar efeitos menores com a mesma amostra, ou obter a mesma precisão com uma amostra menor.

7. Como interpretar

Um desbalanceamento em uma covariável não invalida automaticamente o experimento, mas pede investigação — pode ser apenas um falso positivo (com muitas covariáveis testadas, algumas vão parecer desbalanceadas por acaso) ou pode ser sinal de um problema real de randomização, situação em que um teste de Sample Ratio Mismatch complementar é o próximo passo natural. Balanceamento bom em covariáveis observadas nunca garante balanceamento em covariáveis não observadas — é uma evidência a favor da randomização, não uma prova completa.

8. Quando é útil

A checagem de balanceamento deve ser rotina em todo experimento randomizado, como parte da validação de que a randomização funcionou. O ajuste por covariáveis é especialmente valioso quando a métrica primária tem alta variabilidade entre usuários (o que é comum, por exemplo, em métricas de receita ou de engajamento) e existe uma covariável pré-experimento fortemente correlacionada com ela — nesses casos, o ganho de precisão pode ser substancial.

9. Cuidados importantes

- Nunca use uma covariável medida depois do início do experimento para ajuste ou checagem de balanceamento — ela pode já ter sido afetada pelo próprio tratamento, o que introduz viés em vez de reduzir ruído.
- Ajuste por covariáveis não “conserta” um desbalanceamento real na atribuição — ele serve para reduzir variância quando a randomização já funcionou, não como substituto de uma randomização quebrada.
- Testar balanceamento em dezenas de covariáveis ao mesmo tempo aumenta a chance de encontrar alguma “desbalanceada” por acaso — olhar o padrão geral, não reagir isoladamente a uma covariável isolada fora do limite.
- A escolha de quais covariáveis usar para ajuste deve ser feita antes de olhar os resultados do experimento, para não introduzir viés de seleção retroativo.

10. Um exemplo pequeno com números

Um app de assinatura roda um experimento com 8.000 usuários por braço. Comparando o gasto médio do mês anterior ao experimento: controle R\$ 42,10 (desvio-padrão R\$ 18,40), tratamento R\$ 42,80 (desvio-padrão R\$ 18,90). A diferença padronizada de médias é:

$$SMD = \frac{42,80 - 42,10}{\sqrt{(18,40^2 + 18,90^2)/2}} \approx 0,037$$

Bem abaixo do limite de referência de 0,1 — balanceamento aceitável. Ao estimar o efeito da nova política de preço sobre a receita do mês seguinte, o estimador simples (diferença de médias) produz um IC 95% de largura $\pm 1,05$ ponto percentual em torno do efeito estimado; usando o gasto do mês anterior como covariável de ajuste, o IC cai para aproximadamente $\pm 0,62$ ponto percentual — o mesmo efeito estimado, com bem mais precisão.

11. Exemplo de código simples

```
import numpy as np
import statsmodels.api as sm
```

```

# ilustrativo: y = receita no mês do experimento, trat = 1 se tratamento
# gasto_anterior = covariável pré-experimento (gasto no mês anterior)
X_ajustado = sm.add_constant(np.column_stack([trat, gasto_anterior]))
modelo = sm.OLS(y, X_ajustado).fit(cov_type="HC1")

print(modelo.summary())
# O coeficiente de 'trat' é o efeito ajustado; seu erro-padrão tende a ser
# menor que o de uma regressão sem a covariável, quando ela é preditiva.

```

O coeficiente associado ao indicador de tratamento é a estimativa ajustada do efeito; comparar seu erro-padrão ao de uma regressão sem a covariável mostra diretamente o ganho de precisão obtido.

Teste de não-inferioridade

Pressupõe os fundamentos de teste A/B — veja [Fundamentos de teste A/B](#).

1. Que problema isso resolve?

Nem toda métrica de um experimento é “quanto maior, melhor”. Algumas são métricas de guardrail: coisas que não podem piorar além de um certo ponto, mesmo que a métrica principal melhore bastante — taxa de fraude, tempo de carregamento, taxa de erro, reclamações de suporte. A pergunta nesse caso não é “essa métrica mudou?”, é mais específica: “essa métrica não piorou mais do que eu consigo tolerar?”. Um teste de duas pontas comum, desenhado para perguntar se há qualquer diferença, não responde bem a essa pergunta — porque ele trata “melhorou muito” e “não piorou muito” da mesma forma, quando na prática só a segunda é o que importa para uma métrica de guardrail.

2. Intuição

Pense na diferença entre dois tipos de pergunta. Um teste comum pergunta: “essa métrica é diferente daquela?” — em qualquer direção. Um teste de não-inferioridade pergunta algo mais estreito: “essa métrica não é pior que aquela por mais de X?” — só numa direção, e permitindo explicitamente que ela seja um pouco pior, até um limite definido como aceitável de antemão. Essa margem X não é um número que a estatística escolhe; é uma decisão de negócio, tomada antes do experimento, sobre quanto de piora é tolerável em troca do que se ganha em outro lugar.

3. Explicação simples

Em vez de testar se a diferença é exatamente zero, testa-se se a diferença é menor que a margem de não-inferioridade combinada — normalmente construindo o intervalo de confiança da diferença e verificando se ele fica inteiramente abaixo dessa margem (para uma métrica onde “maior é pior”, como taxa de fraude). Se o limite superior do intervalo de confiança estiver abaixo da margem, há evidência de não-inferioridade. Se o intervalo cruzar a margem, não há evidência suficiente — o que não significa necessariamente que a métrica piorou muito, apenas que não dá para descartar essa possibilidade com confiança.

4. Exemplo conceitual fácil

Uma empresa lança um novo modelo de detecção de fraude, mais rápido, mas com uma pequena chance de ser um pouco menos preciso. A equipe de risco define, antes do experimento, que um aumento de até 0,5 ponto percentual na taxa de fraude é aceitável, dado o ganho de velocidade. O experimento roda, e a diferença observada na taxa de fraude entre o novo modelo e o modelo atual é pequena, com um intervalo de confiança que fica inteiramente abaixo de 0,5 ponto percentual. Isso é evidência de não-inferioridade: mesmo sem provar que o novo modelo é exatamente igual ou melhor, há confiança suficiente de que ele não piora a fraude além do que foi definido como tolerável.

5. Como funciona, em linhas gerais

1. Define-se a margem de não-inferioridade antes do experimento — uma decisão de negócio, não estatística, sobre quanto de piora é tolerável.




Figura 12: Estimativa pontual e intervalo de confiança da diferença de fraude, comparados à margem de não-inferioridade

2. Formulam-se as hipóteses de forma unilateral: a hipótese nula é que a métrica piorou mais do que a margem; a hipótese alternativa é que ela não piorou mais do que a margem.
3. Roda-se o experimento normalmente, coletando a diferença observada e seu intervalo de confiança, geralmente com um nível de confiança de um lado só (por exemplo, 95% unilateral, equivalente a um IC de 90% bilateral).
4. Compara-se o limite relevante do intervalo de confiança (o limite que indica “pior”) com a margem definida.
5. Se esse limite estiver dentro da margem aceitável, conclui-se não-inferioridade.

6. O que o resultado significa

Concluir não-inferioridade significa que há evidência estatística de que a métrica não piorou além da margem definida — não significa que a métrica é igual, nem que ela melhorou. Um resultado inconclusivo (quando o intervalo de confiança cruza a margem) significa apenas que a amostra não trouxe evidência suficiente para descartar uma piora maior que a margem — não é o mesmo que concluir que a métrica de fato piorou.

7. Como interpretar

A margem de não-inferioridade precisa ser definida antes de olhar os dados do experimento e deve refletir um julgamento de negócio explícito: quanto dessa métrica a organização está disposta a “gastar” em troca de outro ganho. Não existe margem “estatisticamente correta” — ela é uma escolha, e diferentes margens levam a diferentes conclusões sobre o mesmo dado. Também vale lembrar que “não inferior” não é sinônimo de “sem custo” — mesmo dentro da margem, uma piora pequena e consistente pode se acumular ao longo do tempo ou de escala.

8. Quando é útil

Em qualquer experimento onde exista uma métrica de guardrail com um limite de tolerância claro — segurança, risco, performance técnica, satisfação mínima do cliente. É comum usá-lo em conjunto com um teste de efeito tradicional sobre a métrica primária: a métrica principal é testada da forma usual (há diferença?), enquanto métricas de guardrail são testadas por não-inferioridade (a piora, se houver, está dentro do tolerável?).

9. Cuidados importantes

- A margem precisa ser fixada antes do experimento — escolher a margem depois de ver o resultado, para “fazer o teste passar”, invalida a interpretação do teste.
- Um resultado de não-inferioridade não é o mesmo que “a métrica não mudou” — ela pode ter piorado um pouco, só que dentro do que foi considerado aceitável.
- Amostra pequena tende a produzir intervalos de confiança largos, que cruzam a margem mesmo quando o efeito real é pequeno — um resultado inconclusivo pede atenção ao poder estatístico do desenho, não conclusão apressada de que a métrica piorou.
- Vale checar a direção certa da margem: para métricas onde “maior é pior” (fraude, erro), a margem limita o quanto a métrica pode subir; para métricas onde “menor é pior” (satisfação, retenção), a lógica se inverte.

10. Um exemplo pequeno com números

Uma empresa testa um novo modelo de detecção de fraude contra o modelo atual, com margem de não-inferioridade definida em 0,5 ponto percentual (um aumento na taxa de fraude maior que isso seria inaceitável). A taxa de fraude observada é 2,10% no grupo controle (modelo atual) e 2,02% no grupo tratamento (modelo novo) — uma diferença de -0,08 ponto percentual (o novo modelo teve fraude ligeiramente menor). O intervalo de confiança de 95% para essa diferença fica aproximadamente entre -0,34 e +0,18 ponto percentual. Como o limite superior do intervalo (+0,18) está bem abaixo da margem de 0,5 ponto percentual, conclui-se não-inferioridade: há evidência de que o novo modelo não piora a fraude além do tolerável — e, nesse caso, a estimativa central sugere até uma leve melhora, embora o intervalo não permita afirmar isso com a mesma confiança que a não-inferioridade.

11. Exemplo de código simples

```
import numpy as np
from statsmodels.stats.proportion import confint_proportions_2indep

margem = 0.5 # pontos percentuais; decisão de negócio, não estatística

fraude_controle = (252, 12000) # ilustrativo: (casos, total)
fraude_tratamento = (242, 12000) # ilustrativo

ic_baixo, ic_alto = confint_proportions_2indep(
    fraude_tratamento[0], fraude_tratamento[1],
    fraude_controle[0], fraude_controle[1],
    method="wald",
)
```

```
ic_baixo_pp, ic_alto_pp = ic_baixo * 100, ic_alto * 100

nao_inferior = ic_alto_pp < margem
print(f"IC 95%: [{ic_baixo_pp:.2f}, {ic_alto_pp:.2f}] p.p. | margem: {margem} p.p.")
print(f"Não-inferioridade concluída: {nao_inferior}")
```

A decisão não depende de um valor-p único, mas de comparar o limite superior do intervalo de confiança diretamente com a margem definida de antemão.

Teste de heterogeneidade de efeito e decaimento de novidade

1. Que problema isso resolve?

Um experimento mostra que uma mudança teve efeito médio positivo. Mas será que esse efeito é igual para todo mundo, ou existe um subgrupo puxando o resultado para cima enquanto outros não sentem nada? E será que o efeito medido na primeira semana ainda existe na oitava semana, ou já era só curiosidade passageira em torno de algo novo?

Essas são duas perguntas diferentes, frequentemente confundidas: **heterogeneidade de efeito** pergunta se o efeito muda entre grupos, num mesmo momento. **Decaimento de efeito de novidade** pergunta se o efeito muda ao longo do tempo, dentro do mesmo grupo. Este documento cobre as duas, porque costumam aparecer juntas na leitura de um resultado de experimento.

2. Intuição

Uma média geral pode esconder histórias completamente diferentes. Um efeito médio de +3% de conversão pode ser +12% para clientes novos e +0% para clientes antigos — ou pode ser +3% distribuído igualmente por todo mundo. Sem testar isso formalmente, as duas situações parecem idênticas no relatório principal, mas pedem decisões de produto completamente diferentes.

O mesmo vale no tempo: um efeito de +5% medido só na primeira semana pode refletir curiosidade genuína das pessoas com algo novo na tela — um “efeito novidade” — que se dissolve assim que a novidade passa a ser rotina.

3. Explicação simples

Para heterogeneidade, o método formal não é simplesmente comparar o efeito “visualmente” entre subgrupos (isso sempre vai parecer diferente por puro acaso). Em vez disso, inclui-se um **termo de interação** num modelo estatístico — algo como “tratamento $\times$ subgrupo” — e testa-se se esse termo é estatisticamente diferente de zero. Isso responde: a diferença de efeito entre subgrupos é maior do que se esperaria só por variação amostral?

Para o decaimento de novidade, observa-se o efeito estimado separadamente em janelas de tempo sucessivas desde o lançamento (semana 1, semana 2, semana 3...) e verifica-se se existe uma tendência de queda.

4. Exemplo conceitual fácil

Imagine um aplicativo de streaming que testa um novo layout de tela inicial. O efeito médio sobre tempo de uso diário é positivo. Ao separar por tipo de usuário, o efeito é grande entre quem assina há menos de um mês e quase nulo entre assinantes antigos — plausível, já que quem já tem hábitos formados reage menos a uma mudança visual. Ao olhar semana a semana, o efeito começa alto e cai pela metade em um mês — também plausível, porque parte da reação inicial é só curiosidade com a tela nova.

5. Como funciona, em linhas gerais

Heterogeneidade: ajusta-se um modelo com o efeito do tratamento, um indicador de subgrupo, e a interação entre os dois. O coeficiente da interação mede o quanto o efeito difere entre o

subgrupo em questão e o subgrupo de referência; seu erro-padrão e valor-p dizem se essa diferença é estatisticamente confiável.

Decaimento de novidade: estima-se o efeito (e seu intervalo de confiança) separadamente para cada janela de tempo desde o lançamento, e observa-se a trajetória dessas estimativas — idealmente com um teste formal de tendência, não só inspeção visual.

6. O que o resultado significa

Um termo de interação estatisticamente significativo é evidência de que o efeito realmente difere entre os subgrupos testados — não é apenas ruído de amostragem. Uma trajetória de decaimento consistente, com o efeito das semanas finais claramente menor que o das primeiras, é evidência de que parte do efeito medido no início era temporário.

7. Como interpretar

Heterogeneidade real muda a decisão de lançamento: pode fazer sentido lançar só para o subgrupo que respondeu, em vez de para todos. Decaimento de novidade muda o horizonte de avaliação: decidir com base só na primeira semana pode superestimar o ganho de longo prazo. As duas leituras são independentes uma da outra — um efeito pode ser homogêneo entre subgrupos e ainda assim decair no tempo, ou heterogêneo e estável.

8. Quando é útil

Comum na leitura de experimentos de produto: testar se o efeito de uma mudança varia por camada de fidelidade, canal de aquisição, tipo de dispositivo ou outro corte relevante, e se o efeito observado logo após o lançamento se sustenta nas semanas seguintes.

9. Cuidados importantes

Testar muitos subgrupos aumenta a chance de encontrar uma diferença “significativa” só por acaso — esse é o problema de **comparações múltiplas**. Se você testar 10 subgrupos ao nível de 5% de significância, espera-se por puro acaso quase meio subgrupo “significativo” mesmo sem heterogeneidade real. Por isso, um resultado de heterogeneidade isolado, especialmente vindo de um subgrupo escolhido depois de olhar os dados, merece bem mais cautela do que um subgrupo definido antes do experimento e confirmado de forma consistente.

10. Um exemplo pequeno com números

Um teste A/B mede efeito de +4,0 pontos percentuais em conversão no grupo “clientes novos” (erro-padrão 1,1) e +0,4 pontos no grupo “clientes antigos” (erro-padrão 0,9). A diferença entre os dois efeitos é 3,6 pontos, com erro-padrão combinado de aproximadamente 1,45 — resultando numa estatística z de cerca de 2,5, acima do limiar usual de significância. Isso é evidência de heterogeneidade real, não apenas coincidência de amostra.


Separadamente, o efeito medido semana a semana desde o lançamento foi de +8,5 pontos na semana 1, +5,2 na semana 4 e +1,8 na semana 8 — uma queda consistente compatível com efeito de novidade.

11. Exemplo de código simples

```
import statsmodels.formula.api as smf

# tratamento: 0/1; subgrupo: categórico; conversao: métrica contínua
modelo = smf.ols("conversao ~ tratamento * subgrupo", data=df).fit()
print(modelo.summary())
# o coeficiente de "tratamento:subgrupo[T.novo]" é o termo de interação

# decaimento de novidade: efeito por semana desde o lançamento
efeitos_semana = (
    df.groupby("semana_desde_lancamento")
      .apply(lambda g: smf.ols("conversao ~ tratamento", data=g).fit().params["tratamento"])
)
print(efeitos_semana)
```



Dados ilustrativos, não representam nenhum projeto real.

Figura 13: Efeito estimado por subgrupo, com intervalos de confiança e a linha do efeito médio geral

Poder estatístico e efeito mínimo detectável (MDE)

1. Que problema isso resolve?

Você está desenhando um experimento — testar uma mudança num aplicativo, uma nova campanha, um novo processo — e precisa decidir o tamanho da amostra antes de começar. A pergunta raramente feita, mas essencial, é: **com o tamanho de amostra que eu consigo rodar, existe alguma chance real de detectar o efeito que eu espero, se ele de fato existir?** Rodar um experimento caro por semanas para no final não conseguir concluir nada — porque o desenho nunca teve força suficiente — é um dos desperdícios mais comuns e mais evitáveis em times de produto e growth.

2. Intuição

Todo teste estatístico tem uma capacidade limitada de enxergar efeitos pequenos. Quanto menor a amostra e quanto mais ruidosa (variável) a métrica, mais “embaçada” é a visão do teste — efeitos pequenos se perdem no meio do ruído amostral, mesmo que sejam reais. O **poder estatístico** é a probabilidade de um teste detectar um efeito verdadeiro de um certo tamanho, dado o desenho do experimento. O **efeito mínimo detectável (MDE)** é o espelho dessa mesma ideia: em vez de perguntar “qual a chance de detectar um efeito de X%?”, pergunta-se “qual o menor efeito que esse desenho consegue detectar com uma chance razoável (tipicamente 80%)?”.

3. Explicação simples


Quatro ingredientes determinam o MDE de um experimento: o tamanho da amostra, a variância (dispersão) da métrica, o nível de significância aceito (a probabilidade de um falso positivo, geralmente 5%) e o poder desejado (geralmente 80%). Aumentar a amostra ou reduzir a variância da métrica diminui o MDE — o teste enxerga efeitos cada vez menores. Só que o ganho não é linear: dobrar a amostra não divide o MDE por dois, divide por aproximadamente 1,4 (raiz de dois). Isso importa na prática: depois de um certo ponto, gastar muito mais tempo de experimento para reduzir o MDE de 3% para 2,5% pode não valer o custo.

4. Exemplo conceitual fácil

Imagine um aplicativo de assinaturas testando um novo fluxo de cadastro. A equipe espera, de forma realista, um ganho de 2 pontos percentuais na taxa de conversão. Antes de rodar o experimento, calcula-se o MDE para o tráfego disponível em duas semanas. Se o MDE calculado for 5 pontos percentuais, o experimento simplesmente não tem força para detectar um ganho de 2 pontos, mesmo que ele exista de verdade — rodar do jeito que está seria gastar tempo para aprender pouco. A solução é aumentar a duração, aumentar a proporção de tráfego exposta, ou aceitar que só efeitos maiores serão detectáveis.

5. Como funciona, em linhas gerais

1. Define-se a métrica primária e estima-se sua variância (a partir de dados históricos, sempre que possível).
2. Define-se o nível de significância (geralmente $= 0,05$) e o poder-alvo (geralmente 80%).
3. Define-se o tamanho de amostra disponível (ou, no sentido inverso, o efeito mínimo que se quer conseguir detectar).



Dados ilustrativos, não representam nenhum projeto real.

Figura 14: Efeito mínimo detectável caindo com o tamanho da amostra, mostrando retornos decrescentes

4. Usa-se a relação entre essas quatro grandezas — amostra, variância, significância e poder — para calcular a que falta: o MDE (dado o tamanho de amostra) ou o tamanho de amostra necessário (dado um MDE-alvo).
5. Compara-se o MDE resultante com o efeito que faria sentido de negócio esperar. Se o MDE for maior que qualquer efeito plausível, o desenho precisa mudar antes de rodar o experimento — não depois.

6. O que o resultado significa

Um MDE de, digamos, 4% significa: “este desenho de experimento consegue detectar, com 80% de chance, um efeito real de 4% ou mais — efeitos menores que isso provavelmente passarão despercebidos, mesmo que existam.” Não é uma garantia de que o efeito real seja 4% — é uma característica do desenho do experimento, calculada antes de qualquer dado ser coletado.

7. Como interpretar

Um MDE alto não é, por si, um problema — o problema é um MDE alto relativo ao efeito que faria sentido esperar. Se a mudança testada só teria valor de negócio caso o efeito fosse de pelo menos 5%, e o MDE calculado é 2%, o desenho está sobredimensionado (bom para detectar até efeitos pequenos, mas possivelmente caro demais). Se o MDE é 8% e o efeito plausível é 2%, o desenho está subdimensionado — é preciso aumentar a amostra, simplificar a métrica, ou aceitar que só efeitos grandes serão vistos.

8. Quando é útil

No planejamento de qualquer experimento controlado, antes de comprometer tempo e tráfego a um desenho que talvez nunca tivesse chance de mostrar nada. Também é útil no meio de um experimento já em andamento, quando a janela disponível muda — por exemplo, um prazo de negócio força o encerramento antes do previsto, ou o tráfego disponível caiu. Recalcular o MDE nesse momento, com o tamanho de amostra efetivamente alcançado, evita duas armadilhas: encerrar um experimento achando que “não deu efeito” quando na verdade ele nunca teve força para detectar o efeito esperado, ou continuar rodando por mais tempo do que o necessário.

9. Cuidados importantes

- O MDE depende da variância estimada da métrica — se essa estimativa for ruim (baseada em pouco histórico, ou em um período atípico), o MDE calculado também será impreciso.
- Poder e MDE não dizem nada sobre a probabilidade de o efeito verdadeiro ser do tamanho esperado — eles dizem apenas o que o desenho é capaz de detectar, caso o efeito exista.
- Calcular o MDE depois de olhar os dados do próprio experimento (e não antes, ou de forma independente com base em uma janela fixa) para decidir se “vale a pena continuar” pode introduzir viés — decisões de parada precisam de um plano definido com antecedência.
- Métricas com distribuição muito assimétrica (poucos valores extremos dominando a variância) inflam a variância estimada e, com isso, o MDE — vale investigar se a métrica ou uma transformação dela é mais estável.

10. Um exemplo pequeno com números

Uma rede de lojas de conveniência quer testar um novo layout de vitrine. A métrica primária é a taxa de conversão de visitante em comprador, atualmente em 20%. Com significância de 5% e poder-alvo de 80%, uma amostra de 20.000 visitantes por grupo (tratamento e controle) produz um MDE relativo de aproximadamente 8% — ou seja, o desenho consegue detectar, com confiança razoável, uma conversão que suba de 20% para cerca de 21,6% ou mais. Se a equipe espera um ganho realista de apenas 3%, esse desenho não tem força suficiente: seria necessário um tamanho de amostra bem maior, algo em torno de 140.000 visitantes por grupo, para alcançar um MDE compatível com um efeito dessa magnitude.

11. Exemplo de código simples

```
from statsmodels.stats.power import NormalIndPower
from statsmodels.stats.proportion import proportion_effectsize

analise = NormalIndPower()

# efeito mínimo detectável (em unidades de effect size) para n fixo por grupo
mde_effect_size = analise.solve_power(
    effect_size=None, nobs1=20_000, alpha=0.05, power=0.8, ratio=1.0
)

# tamanho de amostra necessário para detectar um efeito específico
effect_size_alvo = proportion_effectsize(0.23, 0.20) # 20% -> 23%
n_necessario = analise.solve_power(
    effect_size=effect_size_alvo, nobs1=None, alpha=0.05, power=0.8, ratio=1.0
)

print(f"MDE (effect size) para n=20.000: {mde_effect_size:.4f}")
print(f"Amostra necessária por grupo para efeito de 20% -> 23%: {n_necessario:.0f}")
```

O mesmo raciocínio serve para recalcular o poder no meio de um experimento: basta trocar `nobs1` pelo tamanho de amostra efetivamente coletado até o momento e resolver para `power` em vez de para `nobs1` ou `effect_size`.

Análise de transbordamento espacial e canibalização

1. Que problema isso resolve?

Você testou uma mudança em algumas lojas, cidades ou regiões — uma nova campanha, um novo serviço, uma alteração de preço — e mediu um efeito positivo comparando essas unidades tratadas com unidades de controle. Mas e se parte desse “efeito” não for criação de valor nova, e sim clientes que simplesmente migraram de uma loja de controle vizinha para a loja tratada? Nesse caso, o experimento não está medindo ganho real — está medindo deslocamento, e a unidade de controle mais próxima já não serve mais de referência neutra, porque ela também foi afetada.

2. Intuição

Um experimento geograficamente espalhado assume, implicitamente, que as unidades de controle continuam se comportando “normalmente”, sem qualquer influência do que está acontecendo nas unidades tratadas. Essa suposição quebra quando tratamento e controle competem pelo mesmo público — a mesma cidade, o mesmo raio de entrega, a mesma base de clientes. Se uma loja tratada atrai clientes que antes compravam numa loja de controle a poucos quilômetros de distância, essa loja de controle vai vender menos durante o experimento — não porque nada mudou para ela, mas porque o tratamento “roubou” parte do seu movimento. Comparar tratado contra esse controle contaminado infla o efeito aparente.

3. Explicação simples

A lógica de diagnóstico central é comparar dois tipos de controle: unidades de controle **próximas** às unidades tratadas (que podem estar sofrendo transbordamento) e unidades de controle **distantes** (fora de qualquer raio plausível de competição direta). Se o efeito estimado usando controles próximos for bem maior do que o efeito estimado usando controles distantes, a diferença é um sinal de canibalização: parte do “ganho” medido contra o controle próximo é, na verdade, perda dele, não criação líquida em algum outro lugar.

4. Exemplo conceitual fácil

Imagine uma rede de lojas de conveniência testando um novo programa de fidelidade em algumas lojas de uma cidade. Comparando essas lojas com as lojas de controle do mesmo bairro, o programa parece aumentar as vendas em 12%. Comparando as mesmas lojas tratadas com lojas de controle em bairros distantes, sem nenhuma loja tratada por perto, o aumento medido cai para 6%. A diferença entre 12% e 6% sugere que boa parte do “ganho” nas lojas próximas veio de clientes que simplesmente trocaram de loja dentro do mesmo bairro — não de novos clientes ou de aumento real de consumo.

5. Como funciona, em linhas gerais

1. Mapeia-se a localização de cada unidade experimental (tratada e controle) e calcula-se a distância entre cada controle e a unidade tratada mais próxima.
2. Definem-se faixas de distância — por exemplo, controles a menos de 3 km de distância (“próximos”, possivelmente contaminados) e controles a mais de 10 km (“distantes”, improvável competição direta).
3. Estima-se o efeito do tratamento separadamente contra cada grupo de controle.




Figura 15: Efeito estimado usando controle próximo versus controle distante

4. Compara-se a magnitude dos dois efeitos. Uma diferença grande entre eles é evidência de transbordamento; efeitos parecidos sugerem que a contaminação espacial, se existir, é pequena.
5. Quando possível, examina-se também como o efeito sobre o controle varia continuamente com a distância até a unidade tratada mais próxima — um efeito de canibalização real tende a diminuir suavemente com a distância, em vez de cair abruptamente.

6. O que o resultado significa

Se o efeito medido contra controles próximos for consistentemente maior do que contra controles distantes, o “efeito líquido real” — aquele que reflete criação de valor, não apenas realocação — está mais próximo da estimativa com controle distante. O efeito com controle próximo mede algo diferente: quanto a unidade tratada ganhou às custas da vizinhança imediata, mais o que ela criou de novo.

7. Como interpretar

Nem toda canibalização é um problema — às vezes ela é exatamente o esperado e aceitável (por exemplo, uma marca sabe que um novo produto vai roubar vendas de um produto antigo da mesma linha, e isso é parte do plano). O que importa é não confundir deslocamento com criação líquida na hora de decidir se vale a pena expandir a mudança para todas as unidades. Se o objetivo é crescimento de mercado, o efeito líquido (via controle distante) é a métrica relevante. Se o objetivo é apenas entender o desempenho relativo da unidade tratada frente à vizinhança imediata, o efeito com controle próximo também tem valor, mas para uma pergunta diferente.

8. Quando é útil

Em qualquer experimento com unidades geograficamente próximas que competem pelo mesmo público — lojas físicas, zonas de entrega, regiões de cobertura de um serviço. É especialmente importante quando o resultado positivo do experimento parece “bom demais” e vai embasar uma decisão de expansão em larga escala, onde uma canibalização não detectada infla as expectativas de ganho e pode levar a projeções de receita otimistas demais.

9. Cuidados importantes

- A escolha do ponto de corte entre “próximo” e “distante” é uma decisão de desenho que precisa de justificativa — baseada em raio real de competição (por exemplo, distância que clientes tipicamente percorrem), não em um número arbitrário.
- Controles “distantes” precisam realmente estar fora de qualquer influência do tratamento — se o raio de competição for maior do que o assumido, até os controles “distantes” podem estar parcialmente contaminados, subestimando a diferença entre os dois grupos.
- Um efeito líquido pequeno ou nulo (via controle distante) ao lado de um efeito grande via controle próximo não significa que a mudança “não funcionou” — significa que ela redistribuiu demanda em vez de criar demanda nova, o que pode ainda ser um resultado valioso dependendo do objetivo do negócio.
- Amostras pequenas de unidades tratadas e controladas (poucas lojas, poucas regiões) tornam as estimativas de efeito instáveis; nesse cenário, a incerteza em torno da comparação entre os dois efeitos precisa ser reportada, não só o ponto estimado.

10. Um exemplo pequeno com números

Uma rede de lojas testa um novo horário de funcionamento estendido em 15 lojas de uma região metropolitana. Vinte lojas de controle no mesmo bairro ficam a menos de 3 km de alguma loja tratada; outras 25 lojas de controle, usadas como grupo de comparação distante, ficam a mais de 12 km de qualquer loja tratada.

- Vendas médias diárias, lojas tratadas: R\$ 8.400 (antes) → R\$ 9.660 (depois).
- Vendas médias diárias, controle próximo: R\$ 8.100 (antes) → R\$ 7.930 (depois) — queda de 2,1%.
- Vendas médias diárias, controle distante: R\$ 8.050 (antes) → R\$ 8.170 (depois) — alta de 1,5%.

O efeito estimado contra o controle próximo é de aproximadamente 17,3% (porque o controle caiu enquanto o tratado subiu). O efeito estimado contra o controle distante é de aproximadamente 13,5%. A diferença de cerca de 3,8 pontos percentuais é consistente com algum grau de canibalização das lojas vizinhas — parte do aumento nas lojas tratadas veio de clientes que antes compravam nas lojas de controle próximas, e não apenas de aumento de consumo na região como um todo.

11. Exemplo de código simples

```
import numpy as np
import pandas as pd

# dados ilustrativos: uma linha por loja, com distância até a loja tratada mais próxima
lojas = pd.DataFrame({
```

```

    "loja_id": range(1, 61),
    "tratada": [True] * 15 + [False] * 45,
    "distancia_km": [0] * 15 + list(np.random.default_rng(1).uniform(0.5, 20, 45)),
    "vendas_antes": np.random.default_rng(2).normal(8100, 400, 60),
    "vendas_depois": np.random.default_rng(3).normal(8300, 500, 60),
})

controle_proximo = lojas[(~lojas["tratada"]) & (lojas["distancia_km"] < 3)]
controle_distante = lojas[(~lojas["tratada"]) & (lojas["distancia_km"] > 10)]
tratadas = lojas[lojas["tratada"]]

def variacao_percentual(df):
    return (df["vendas_depois"].mean() / df["vendas_antes"].mean() - 1) * 100

var_tratado = variacao_percentual(tratadas)
var_proximo = variacao_percentual(controle_proximo)
var_distante = variacao_percentual(controle_distante)

efeito_vs_proximo = var_tratado - var_proximo
efeito_vs_distante = var_tratado - var_distante

print(f"Efeito vs. controle próximo: {efeito_vs_proximo:.1f} pp")
print(f"Efeito vs. controle distante: {efeito_vs_distante:.1f} pp")
print(f"Diferença (sinal de canibalização): {efeito_vs_proximo - efeito_vs_distante:.1f} pp")

```

Erros-padrão robustos a cluster

1. Que problema isso resolve?

O cálculo padrão de erro-padrão assume que cada observação da amostra traz informação nova e independente das demais. Mas e quando várias observações vêm do mesmo grupo — a mesma loja, a mesma turma, a mesma região — e se parecem entre si por razões que nada têm a ver com a variável que você está testando? Tratar essas observações como independentes faz o erro-padrão parecer menor do que realmente é, e pode levar a declarar “significativo” algo que não é.

2. Intuição

Pense em medir a satisfação de clientes em 20 lojas, com 50 respostas por loja — 1.000 observações no total. Se cada loja tem sua própria cultura de atendimento, gerente, localização e clientela, respostas da mesma loja tendem a se parecer entre si por causa desses fatores compartilhados, não só por coincidência. Na prática, você não tem 1.000 pedaços independentes de informação — tem algo mais perto de 20 “blocos” de informação, cada um formado por respostas correlacionadas entre si. Calcular o erro-padrão como se fossem 1.000 observações independentes exagera a precisão da estimativa.

3. Explicação simples

Cada observação nova dentro do mesmo cluster carrega menos informação adicional do que uma observação de um cluster diferente, porque parte do que ela mostra já era previsível a partir das outras observações do mesmo grupo. O erro-padrão robusto a cluster reconhece essa correlação interna e ajusta o cálculo para refletir o número efetivo de “unidades independentes de informação” — que fica mais perto do número de clusters do que do número total de observações.

4. Exemplo conceitual fácil

Uma rede de academias testa um novo programa de treino em 8 unidades (tratamento) contra outras 8 unidades (controle), com cerca de 40 alunos por unidade. Alunos da mesma unidade compartilham o mesmo instrutor, o mesmo horário de pico, a mesma vizinhança — fatores que afetam o resultado independentemente do programa testado. Um erro-padrão que ignora isso trata os 640 alunos como 640 fontes independentes de evidência; na prática, a evidência real está muito mais próxima de vir de 16 unidades.

5. Como funciona, em linhas gerais

Em vez de assumir que os erros do modelo são independentes entre todas as observações, o erro-padrão robusto a cluster permite que os erros sejam correlacionados dentro de cada cluster (sem exigir uma forma específica dessa correlação) e apenas assume independência **entre** clusters diferentes. A matriz de variância-covariância dos coeficientes é recalculada somando as contribuições cluster por cluster, em vez de observação por observação — o que produz, tipicamente, um erro-padrão maior (mais conservador, mais honesto) do que o cálculo ingênuo.

6. O que o resultado significa

O ponto estimado do efeito não muda — só o erro-padrão em volta dele. Um intervalo de confiança calculado com erro-padrão robusto a cluster é mais largo, refletindo com mais fidelidade a real

incerteza da estimativa, dado que a quantidade efetiva de informação independente é menor do que o número bruto de linhas na base de dados.

7. Como interpretar

Se um resultado era “significativo” com o erro-padrão ingênuo e deixa de ser com o erro-padrão robusto a cluster, isso não é um defeito do método — é a correção mostrando que a confiança original estava artificialmente inflada. Quanto mais forte a correlação dentro dos clusters e quanto mais desigual o tamanho dos clusters, maior costuma ser essa diferença.

8. Quando é útil

Sempre que a unidade de aleatorização ou de coleta de dados for diferente da unidade de análise — por exemplo, um experimento randomizado por loja mas analisado no nível do cliente, uma pesquisa domiciliar em que várias pessoas do mesmo domicílio respondem, ou dados organizados por região geográfica ao longo de vários períodos de tempo.

9. Cuidados importantes

Com **poucos clusters** (regra prática comum: menos de 30-40), mesmo o erro-padrão robusto a cluster pode ser instável e enviesado para baixo — a correção assintótica que o sustenta depende de ter clusters suficientes para funcionar bem. Nesse cenário, métodos alternativos como inferência por randomização ou bootstrap wild-cluster costumam ser preferíveis (veja os documentos correspondentes).


10. Um exemplo pequeno com números

Num modelo simples com 1.000 observações em 20 clusters, suponha que o coeficiente estimado de interesse seja 5,0. O erro-padrão ingênuo (tratando as 1.000 observações como independentes) é 0,45, dando uma estatística $t = 11,1$ — fortemente significativo. Ao recalculá-lo como erro-padrão robusto a cluster, considerando a correlação dentro de cada uma das 20 lojas, o erro-padrão sobe para 1,60, dando $t = 3,1$ — ainda significativo, mas com uma margem de confiança bem mais realista.

11. Exemplo de código simples

```
import statsmodels.formula.api as smf

modelo = smf.ols("satisfacao ~ tratamento", data=df).fit(
    cov_type="cluster",
    cov_kwds={"groups": df["loja_id"]},
)
print(modelo.summary())
```



Dados ilustrativos, não representam nenhum projeto real.

Figura 16: Comparação entre o intervalo de confiança calculado com erro-padrão ingênuo e com erro-padrão robusto a cluster

Inferência por randomização (teste de permutação)

1. Que problema isso resolve?

Testes estatísticos comuns (teste t, por exemplo) dependem de aproximações que funcionam bem quando há muitas observações. Mas e quando um experimento tem poucas unidades — poucas lojas, poucas cidades, poucas turmas — porque a aleatorização aconteceu num nível agregado, não no nível de cada pessoa? Com poucas unidades, essas aproximações deixam de ser confiáveis. A inferência por randomização resolve isso sem depender de nenhuma aproximação: ela usa a própria aleatoriedade do desenho do experimento para construir o teste.

2. Intuição

Se o tratamento foi atribuído por sorteio, existe um número finito e conhecido de formas como esse sorteio poderia ter saído. A pergunta central do método é: “entre todas as formas possíveis de sortear quem seria tratado, que fração delas produziria um efeito tão grande quanto (ou maior que) o efeito que eu de fato observei?” Se a resposta for “quase nenhuma”, o resultado observado é incomum o suficiente para ser evidência de um efeito real, não apenas do sorteio que calhou de acontecer.

3. Explicação simples

O método reembaralha, entre as unidades disponíveis, todas as combinações possíveis (ou uma amostra grande delas) de quem seria “tratamento” e quem seria “controle”, recalculando a estatística de interesse (geralmente a diferença de médias) para cada reembaralhamento. Isso gera uma distribuição inteira de resultados possíveis sob a hipótese de que o tratamento não teve efeito nenhum. O valor-p é a fração dessa distribuição que é tão extrema quanto o resultado realmente observado.

4. Exemplo conceitual fácil

Considere um experimento com apenas 4 lojas, das quais 2 serão sorteadas para receber um novo layout de vitrine e 2 permanecerão como estão. Existem exatamente $\binom{4}{2} = 6$ formas diferentes de escolher quais 2 lojas recebem o tratamento. Cada uma dessas 6 formas produz uma diferença de vendas diferente entre “tratamento” e “controle”. A distribuição de referência do teste é formada por essas 6 diferenças possíveis — nada mais.

5. Como funciona, em linhas gerais

1. Calcula-se a estatística observada (por exemplo, a diferença de médias entre o grupo tratado e o grupo controle, na atribuição real do experimento).
2. Enumeram-se todas as reatribuições possíveis de tratamento/controle entre as mesmas unidades (ou, quando o número de combinações é grande demais para enumerar, sorteia-se uma amostra grande de reatribuições, tipicamente milhares).
3. Para cada reatribuição, recalcula-se a mesma estatística, mantendo os valores observados de cada unidade fixos — só a rotulagem tratamento/ controle muda.
4. O valor-p é a proporção dessas estatísticas recalculadas que é igual ou mais extrema que a estatística observada na atribuição real.

6. O que o resultado significa

Um valor-p baixo diz que a atribuição real do experimento produziu um resultado incomum, comparado a todas as outras formas como o sorteio poderia ter saído. Isso é evidência de que o tratamento teve efeito — sem depender de nenhuma suposição sobre a forma da distribuição dos dados.

7. Como interpretar

A validade do método depende inteiramente de a atribuição ao tratamento ter sido de fato aleatória (ou de o desenho permitir tratar as reatribuições como igualmente prováveis). Diferente de testes que assumem normalidade ou amostra grande, aqui a única suposição necessária é a aleatoriedade real da atribuição — o que faz do método especialmente confiável quando essa aleatoriedade é garantida, e especialmente inadequado quando não é.

8. Quando é útil

Muito útil quando o número de unidades experimentais é pequeno — poucas zonas geográficas, poucas lojas, poucas turmas — situação comum em experimentos randomizados no nível de cluster (geografia, loja, unidade organizacional), em que testes assintóticos tradicionais perdem confiabilidade.

9. Cuidados importantes

Com poucas unidades, o número de reatribuições possíveis também é pequeno, o que limita a granularidade do valor-p — com 4 lojas divididas 2 a 2, por exemplo, o menor valor-p possível é $1/6 \approx 0,167$, nunca menor que isso, mesmo com um efeito enorme. Esse é um limite estrutural do método com amostras muito pequenas, não um defeito de implementação.

10. Um exemplo pequeno com números

Seis lojas participam de um experimento, três sorteadas para tratamento e três para controle. As vendas semanais observadas são: 12, 15, 9, 22, 18, 11 (em milhares de reais), com as três primeiras sendo o grupo de tratamento na atribuição real. A diferença de médias observada é $(12 + 15 + 9)/3 - (22 + 18 + 11)/3 = 12,0 - 17,0 = -5,0$.

Existem $\binom{6}{3} = 20$ formas possíveis de escolher quais 3 lojas seriam tratamento. Calculando a diferença de médias para cada uma das 20 combinações, obtém-se a distribuição de referência completa. Nesse exemplo, 6 das 20 combinações produzem uma diferença tão extrema quanto (ou mais extrema que) $-5,0$ em valor absoluto — dando um valor-p bilateral de $6/20 = 0,30$. Não é um resultado significativo: entre as 20 formas possíveis de sortear o tratamento, uma diferença tão grande quanto a observada não é particularmente incomum.

11. Exemplo de código simples


```
import numpy as np
from itertools import combinations

vendas = np.array([12.0, 15.0, 9.0, 22.0, 18.0, 11.0])
tratamento_real = {0, 1, 2} # índices das 3 lojas tratadas de fato
```

```
def diferenca(idx_tratamento, idx_controle):
    return vendas[list(idx_tratamento)].mean() - vendas[list(idx_controle)].mean()

todas_unidades = set(range(6))
diferencas = []
for combo in combinations(range(6), 3):
    combo = set(combo)
    diferencas.append(diferenca(combo, todas_unidades - combo))

diferencas = np.array(diferencas)
observada = diferenca(tratamento_real, todas_unidades - tratamento_real)
valor_p = np.mean(np.abs(diferencas) >= abs(observada))
print(valor_p)
```



Dados ilustrativos, não representam nenhum projeto real.

Figura 17: Distribuição de referência por permutação, com todas as 20 reatribuições possíveis e a diferença observada destacada

Bootstrap wild-cluster

1. Que problema isso resolve?

Erros-padrão robustos a cluster funcionam bem quando há muitos clusters, mas ficam pouco confiáveis quando há poucos — uma dezena ou menos, por exemplo. Nesse cenário, um teste de hipótese baseado nessa aproximação pode rejeitar a hipótese nula com muito mais frequência do que deveria, mesmo quando ela é verdadeira. O bootstrap wild-cluster é uma forma de construir uma distribuição de referência mais confiável nessa situação, sem depender da aproximação assintótica que falha com poucos clusters.

2. Intuição

Em vez de confiar numa fórmula teórica para o erro-padrão, o método gera muitas versões alternativas e plausíveis dos dados — mantendo o padrão real de dependência dentro de cada cluster — e observa como a estatística de teste varia entre essas versões. Essa variação observada vira a régua para julgar se o resultado real é incomum.

3. Explicação simples

O bootstrap wild-cluster não reamostra linhas de dados individuais, nem sorteia clusters inteiros com reposição (como faz um bootstrap de cluster comum). Em vez disso, ele pega os **resíduos** de um modelo já ajustado, multiplica **todos os resíduos de um mesmo cluster pelo mesmo número aleatório** (tipicamente $+1$ ou -1 , sorteado cluster por cluster), soma esses resíduos perturbados de volta a uma previsão sob a hipótese nula, e reajusta o modelo. Repetindo isso milhares de vezes, obtém-se uma distribuição inteira de estatísticas de teste “poderia ter sido assim, sob a hipótese nula”.

4. Exemplo conceitual fácil

Imagine uma rede de 6 hospitais testando um novo protocolo de triagem, com apenas 6 clusters (hospitais) no total — poucos demais para confiar num erro-padrão robusto a cluster convencional. O bootstrap wild-cluster gera milhares de cenários alternativos em que os desvios (resíduos) observados em cada hospital são “invertidos” ou “mantidos” em bloco, de forma aleatória, hospital por hospital — preservando o padrão de que dentro de um mesmo hospital os desvios tendem a se mover juntos.

5. Como funciona, em linhas gerais

1. Ajusta-se o modelo sob a hipótese nula (por exemplo, efeito do tratamento igual a zero) e obtêm-se os resíduos desse ajuste restrito.
2. Para cada réplica de bootstrap, sorteia-se um sinal aleatório ($+1$ ou -1) **por cluster** — todas as observações do mesmo cluster recebem o mesmo sinal naquela réplica.
3. Multiplicam-se os resíduos de cada cluster pelo sinal sorteado para aquele cluster, gerando uma nova variável dependente sintética.
4. Reajusta-se o modelo a essa variável sintética e recalcula-se a estatística de teste.
5. Repetindo os passos 2 a 4 muitas vezes (tipicamente 999 ou mais réplicas), forma-se a distribuição de referência da estatística de teste sob a hipótese nula.

6. O que o resultado significa

O valor-p do bootstrap wild-cluster é a fração das réplicas em que a estatística recalculada é tão extrema quanto, ou mais extrema que, a estatística observada nos dados reais. Diferente do erro-padrão robusto a cluster tradicional, essa distribuição de referência é construída diretamente dos dados, sem depender de uma aproximação normal que só funciona bem com muitos clusters.

7. Como interpretar

Um valor-p baixo no bootstrap wild-cluster é evidência mais confiável, com poucos clusters, do que um valor-p igualmente baixo vindo de um erro-padrão robusto a cluster convencional — porque o método não depende da suposição assintótica que falha justamente nesse cenário.

8. Quando é útil

Especialmente indicado quando há poucos clusters (uma faixa comum na literatura aplicada é abaixo de 30, com atenção redobrada abaixo de 10-15), e o efeito de interesse vem de um modelo de regressão — com ou sem variáveis de controle — em vez de uma comparação simples de médias entre dois grupos (nesse caso mais simples, inferência por randomização também é uma alternativa direta).

9. Cuidados importantes

O método ainda depende de o modelo estar razoavelmente bem especificado — ele resolve o problema do erro-padrão sob poucos clusters, mas não conserta um modelo mal especificado. Com clusters extremamente poucos (2 ou 3, por exemplo), mesmo o bootstrap wild-cluster enfrenta limitações, já que o número de combinações possíveis de sinais por cluster também fica pequeno.

10. Um exemplo pequeno com números

Um modelo de regressão com 6 clusters produz um coeficiente estimado de tratamento de 4,2, com erro-padrão robusto a cluster convencional de 1,3, dando $t = 3,2$ — aparentemente significativo pela referência t assintótica usual. Rodando o bootstrap wild-cluster com 999 réplicas (sinais aleatórios sorteados por cluster, 6 possibilidades de sinal combinando $2^6 = 64$ padrões possíveis), a estatística t observada de 3,2 cai no percentil 91 da distribuição bootstrap — correspondendo a um valor-p bilateral de aproximadamente 0,09, mais alto (mais conservador) do que o valor-p assintótico original de cerca de 0,003. A conclusão muda de “fortemente significativo” para “sugestivo, mas não conclusivo a 5%”.

11. Exemplo de código simples


```
import numpy as np
import statsmodels.formula.api as smf

def wild_cluster_bootstrap(df, formula, cluster_col, n_boot=999, seed=0):
    rng = np.random.default_rng(seed)
    modelo_restrito = smf.ols(formula, data=df).fit()
    residuos = modelo_restrito.resid
    ajustado = modelo_restrito.fittedvalues
    clusters = df[cluster_col].unique()
```

```

t_boot = []
for _ in range(n_boot):
    sinais = {c: rng.choice([-1, 1]) for c in clusters}
    peso = df[cluster_col].map(sinais).values
    y_sintetico = ajustado + residuos * peso
    df_boot = df.assign(y_sintetico=y_sintetico)
    modelo_boot = smf.ols(formula.replace(formula.split("~")[0].strip(), "y_sintetico"),
                          data=df_boot).fit(cov_type="cluster",
                                             cov_kws={"groups": df_boot[cluster_col]})
    t_boot.append(modelo_boot.tvalues["tratamento"])
return np.array(t_boot)

```



Dados ilustrativos, não representam nenhum projeto real.

Figura 18: Distribuição wild-cluster bootstrap comparada à referência t assintótica, com 6 clusters

Decomposição de coorte e retenção

1. Que problema isso resolve?

A taxa de retenção geral de um produto caiu neste trimestre. É tentador procurar uma causa única — uma mudança de preço, um problema técnico, um concorrente novo — mas essa queda agregada pode vir de lugares muito diferentes: pode ser que os clientes que entraram recentemente estejam saindo mais rápido que o normal, pode ser que todos os clientes, antigos e novos, estejam saindo um pouco mais, ou pode até ser que ninguém individual esteja se comportando diferente, e a queda seja só um efeito de composição — mais gente nova entrando, e clientes novos naturalmente têm retenção mais baixa que clientes antigos nos primeiros meses. Cada uma dessas causas pede uma resposta completamente diferente.

2. Intuição

Uma “taxa de retenção” única, olhada mês a mês, mistura pessoas que entraram em momentos muito diferentes — e cada uma dessas pessoas está numa fase diferente da sua própria curva de vida como cliente. Uma **coorte** é o grupo de clientes que entrou no mesmo período (por exemplo, todos que assinaram em janeiro). Ao invés de olhar uma única curva de retenção agregada, olha-se uma curva por coorte, alinhada pelo tempo desde a entrada (mês 0, mês 1, mês 2...), não pelo calendário. Isso separa duas coisas que a métrica agregada mistura: o comportamento de uma coorte específica ao longo da sua vida, e a mudança na proporção de coortes recentes versus antigas na base total de clientes num dado mês.

3. Explicação simples


Constrói-se uma curva de retenção para cada coorte de entrada: a proporção da coorte original que ainda está ativa em cada mês seguinte à entrada. Coortes diferentes podem ter curvas parecidas (sinal de que o comportamento do cliente é estável ao longo do tempo) ou diferentes (sinal de que algo mudou para quem entrou num período específico — uma mudança de produto, uma campanha de aquisição que trouxe um público menos engajado, um problema técnico que afetou desproporcionalmente quem estava em fase de onboarding). Comparando essas curvas lado a lado, dá para identificar se uma queda agregada vem de uma coorte específica, de todas as coortes igualmente, ou de mudança na composição da base.

4. Exemplo conceitual fácil

Imagine um aplicativo de assinaturas que percebe uma queda na retenção média do mês 3 (a fração de assinantes que ainda está ativa três meses depois de assinar). Olhando a retenção agregada, parece que “os clientes estão saindo mais”. Mas ao separar por coorte de entrada, fica claro que as coortes de janeiro, fevereiro e março têm curvas praticamente idênticas às de meses anteriores — só a coorte de abril, que coincide com uma mudança no processo de cobrança, tem uma queda visível na retenção do mês 3. A causa não é geral, é específica de uma coorte e de um evento identificável.

5. Como funciona, em linhas gerais

1. Agrupam-se os clientes pela data (mês, semana) em que entraram — essa é a coorte.
2. Para cada coorte, calcula-se a fração ainda ativa em cada período seguinte à entrada (mês 0 = 100%, mês 1 = fração retida, e assim por diante).



Dados ilustrativos, não representam nenhum projeto real.

Figura 19: Curvas de retenção por coorte de entrada, com uma coorte recente destacada

3. Plotam-se as curvas de todas as coortes relevantes, alinhadas por tempo desde a entrada, não por data de calendário.
4. Compara-se visualmente e numericamente: coortes recentes estão pior do que coortes antigas no mesmo ponto da curva? Se sim, algo específico às coortes recentes está acontecendo.
5. Separa-se o efeito de composição: mesmo sem nenhuma coorte piorando individualmente, se a base atual tem uma proporção maior de coortes recentes (que estão numa fase de vida com retenção naturalmente mais baixa), a métrica agregada cai só por causa dessa mudança de mix.

6. O que o resultado significa

Se uma coorte específica tem retenção visivelmente pior do que as coortes anteriores no mesmo ponto do tempo desde a entrada, isso aponta para uma causa localizada — algo que aconteceu especificamente para quem entrou naquele período. Se todas as coortes, incluindo as antigas, mostram queda a partir de um certo mês de calendário, isso aponta para um evento que afetou todo mundo ao mesmo tempo, independente de quando entraram. Se as curvas individuais de cada coorte são estáveis, mas a métrica agregada ainda assim caiu, a explicação está na composição — a base mudou de mix, não de comportamento.

7. Como interpretar

É importante não pular direto para “a coorte X piorou, então algo quebrou especificamente para eles” sem checar se a diferença é grande o suficiente para não ser apenas ruído amostral — coortes

menores (por exemplo, um mês com poucas entradas) têm curvas naturalmente mais instáveis. Também vale verificar se a composição da coorte mudou (por exemplo, um canal de aquisição diferente trazendo um público diferente), porque isso pode explicar a diferença sem que nada tenha “quebrado” no produto — só o público que entrou mudou.

8. Quando é útil

Sempre que uma métrica agregada de retenção, churn, ou permanência muda de forma inesperada e a causa não é óbvia. É especialmente útil para distinguir um problema de produto ou operação (que normalmente aparece como uma queda localizada numa coorte específica, coincidindo com uma mudança conhecida) de um efeito estrutural de composição da base (que não exige uma correção pontual, mas sim entender por que o mix de clientes está mudando).

9. Cuidados importantes

- Coortes muito pequenas produzem curvas instáveis — cuidado ao comparar coortes de tamanhos muito diferentes sem levar isso em conta.
- Retenção medida em janelas de calendário fixas (não alinhadas ao tempo desde a entrada) mistura coortes em fases diferentes da vida e esconde o próprio fenômeno que a decomposição por coorte tenta revelar.
- Uma coorte “pior” pode refletir mudança na fonte de aquisição, não um problema de produto — vale cruzar com dados de canal de aquisição antes de concluir causa.
- Comparações entre coortes são observacionais, não experimentais — mesmo quando uma coorte específica piora após uma mudança conhecida, a coincidência temporal sugere, mas não prova, causalidade; outros fatores que também mudaram naquele período podem estar por trás da diferença.

10. Um exemplo pequeno com números

Um serviço de streaming fictício acompanha a retenção do mês 3 (percentual de assinantes ainda ativos três meses após a assinatura) para quatro coortes mensais de entrada:

Coorte	Retenção mês 3
Janeiro	39%
Fevereiro	38%
Março	40%
Abril	26%

A retenção agregada da base inteira, olhada só no mês corrente, caiu de 38% para 34% em relação ao trimestre anterior. Isolando por coorte, fica claro que janeiro, fevereiro e março estão dentro do padrão histórico (38–40%) — só a coorte de abril, 12 a 14 pontos percentuais abaixo das demais, está puxando a média agregada para baixo. A investigação, então, se concentra no que foi diferente para quem assinou em abril — nesse caso hipotético, uma mudança na política de cobrança de cartão que coincidiu exatamente com esse mês.

11. Exemplo de código simples

```
import pandas as pd
import numpy as np

# dados ilustrativos: uma linha por assinante, com coorte de entrada e status por mês
rng = np.random.default_rng(5)

coortes = ["2026-01", "2026-02", "2026-03", "2026-04"]
retencao_base = {"2026-01": 0.39, "2026-02": 0.38, "2026-03": 0.40, "2026-04": 0.26}

registros = []
for coorte in coortes:
    n = rng.integers(800, 1200)
    ativos_mes3 = rng.binomial(n, retencao_base[coorte])
    registros.append({"coorte": coorte, "assinantes": n, "ativos_mes3": ativos_mes3})

resumo = pd.DataFrame(registros)
resumo["retencao_mes3"] = resumo["ativos_mes3"] / resumo["assinantes"]

media_historica = resumo.loc[resumo["coorte"] != "2026-04", "retencao_mes3"].mean()
print(resumo[["coorte", "retencao_mes3"]])
print(f"\nMédia histórica (excluindo abril): {media_historica:.1%}")
print(f"Retenção da coorte de abril: {resumo.loc[resumo.coorte == '2026-04', 'retencao_mes3'].:.1%}")
```

Decomposição de crescimento (total, comparável e preço-volume-mix)

1. Que problema isso resolve?

Uma rede de lojas fecha o trimestre com receita 12% maior que no ano anterior. A diretoria comemora — mas alguém pergunta: “esse crescimento veio de vender mais para os mesmos clientes, ou simplesmente de termos aberto oito lojas novas?” E, dentro do que já existia, “vendemos mais unidades, ou só aumentamos o preço?” Sem separar essas peças, um número de crescimento agregado pode esconder tanto uma operação saudável quanto uma que só está mascarando queda de volume com reajustes de preço.

2. Intuição

Crescimento total é uma soma de coisas muito diferentes: lojas novas que nunca existiram no período anterior, e lojas antigas que estavam lá nos dois períodos. Comparar isso tudo junto é como comparar o crescimento de peso de uma pessoa que fez academia com o de uma família que teve um bebê — o segundo número cresce por um motivo completamente diferente do primeiro.

3. Explicação simples

O método separa o crescimento em duas perguntas sucessivas:

Pergunta 1 — de onde veio o crescimento? Divide a receita total em lojas “comparáveis” (que existiam em ambos os períodos, também chamadas *like-for-like*) e lojas novas (aberturas, expansão geográfica). Só o crescimento comparável mede se o negócio que já existia está indo melhor.

Pergunta 2 — dentro do crescimento comparável, o que mudou? Decompõe em três efeitos: **preço** (os mesmos itens ficaram mais caros ou mais baratos), **volume** (vendeu-se mais ou menos unidades) e **mix** (a composição do que foi vendido mudou — por exemplo, mais itens de ticket alto no carrinho).

4. Exemplo conceitual fácil

Imagine uma cafeteria que vendia só um tipo de café a R\$5. No mês seguinte, vende a mesma quantidade de xícaras, mas passou a cobrar R\$5,50. A receita subiu — só por efeito **preço**, sem mudança de volume nem de mix. Agora imagine que, em vez disso, ela manteve o preço mas vendeu mais xícaras: isso é efeito **volume**. E se ela passou a vender mais itens de um combo mais caro (café + bolo) em vez do café avulso, isso é efeito **mix** — a composição das vendas mudou, mesmo que preço e volume unitário não tenham se alterado sozinhos.

5. Como funciona, em linhas gerais

1. Classifica cada unidade (loja, região, canal) como “comparável” — presente em ambos os períodos — ou “nova”.
2. Calcula o crescimento total como a diferença de receita entre os dois períodos.
3. Isola a parcela vinda de unidades novas (receita das unidades que só existem no período mais recente).
4. O restante é o crescimento comparável — só entre unidades presentes nos dois períodos.

5. Dentro do crescimento comparável, decompõe a variação de receita em efeito preço (mantendo o mix e o volume de unidades fixos, variando só o preço médio), efeito volume (mantendo preço e mix fixos, variando a quantidade) e efeito mix (o resíduo, capturando mudança na composição do que é vendido).

Cada componente responde à pergunta “quanto teria sido o crescimento se só esse fator tivesse mudado, mantendo os outros constantes?” — por isso a soma dos três efeitos fecha exatamente o crescimento comparável total.

6. O que o resultado significa

Um crescimento total positivo pode conter uma base comparável estagnada ou até encolhendo, compensada por expansão geográfica. E um crescimento comparável positivo pode vir majoritariamente de preço (o que levanta a pergunta: até quando dá para repassar preço sem perder volume?) ou de volume real (sinal mais robusto de demanda).

7. Como interpretar

Volume subindo é geralmente o sinal mais saudável — indica demanda real crescendo. Preço subindo isoladamente, sem volume acompanhando, pode ser inflação repassada ou power de precificação, mas não é, sozinho, evidência de mais clientes ou mais consumo. Mix positivo pode indicar sucesso em upsell, ou simplesmente uma mudança na demanda do mercado que nada tem a ver com estratégia interna — vale investigar a causa antes de comemorar.

8. Quando é útil

Sempre que a métrica de crescimento reportada mistura fontes estruturalmente diferentes: expansão versus operação existente, preço versus quantidade. É a lógica por trás do “crescimento comparável” (*same-store sales, like-for-like*) usado em relatórios de varejo, redes de franquia e análises de portfólio de produtos — nesses contextos é comum usar exatamente esse tipo de decomposição para separar quanto da receita adicional veio de abrir novos pontos de venda versus vender mais nos pontos já existentes.

9. Cuidados importantes

- A decomposição preço-volume-mix depende da ordem em que os efeitos são calculados quando há interação entre eles (por exemplo, preço e volume mudando ao mesmo tempo) — diferentes convenções de cálculo produzem números ligeiramente diferentes para cada componente individual, embora a soma total seja sempre a mesma.
- “Comparável” precisa de uma definição consistente de janela de tempo (ex.: loja precisa estar aberta há pelo menos 12 meses completos) — mudar esse critério muda os números.
- Mix pode acabar sendo tratado como resíduo que absorve erros de mensuração dos outros dois efeitos; sempre checar se o valor de mix é plausível dado o contexto do negócio.

10. Um exemplo pequeno com números

Uma rede fictícia teve receita de R\$48 milhões no ano anterior e R\$53,2 milhões no ano atual — crescimento total de R\$5,2 milhões (+10,8%). Dessas, R\$3,6 milhões vieram de lojas novas abertas no período. O crescimento comparável foi, portanto, R\$1,6 milhão. Decompondo esse valor: preço contribuiu com +R\$2,1 milhões, volume com −R\$1,4 milhão (queda de unidades vendidas nas lojas

antigas) e mix com +R\$0,9 milhão. Ou seja: o crescimento comparável só ficou positivo porque preço e mix compensaram uma queda real de volume — um sinal de alerta que o número agregado de +10,8% sozinho não mostrava.




Figura 20: Decomposição em cascata do crescimento de receita

11. Exemplo de código simples

```
import pandas as pd

# receita por loja, dois períodos, com quantidade vendida
df = pd.DataFrame({
    "loja": ["A", "B", "C", "D"],
    "comparavel": [True, True, True, False], # D é loja nova
    "receita_anterior": [12.0, 15.0, 18.0, 0.0],
    "receita_atual": [12.8, 14.1, 19.7, 3.6],
    "qtd_anterior": [2400, 3000, 3600, 0],
    "qtd_atual": [2280, 2820, 3760, 720],
})

comp = df[df["comparavel"]]

receita_anterior_total = df["receita_anterior"].sum()
receita_atual_total = df["receita_atual"].sum()
crescimento_total = receita_atual_total - receita_anterior_total

crescimento_lojas_novas = df.loc[~df["comparavel"], "receita_atual"].sum()
crescimento_comparavel = (
    comp["receita_atual"].sum() - comp["receita_anterior"].sum()
)
```

```

preco_anterior = comp["receita_anterior"].sum() / comp["qtd_anterior"].sum()
preco_atual = comp["receita_atual"].sum() / comp["qtd_atual"].sum()

efeito_volume = (comp["qtd_atual"].sum() - comp["qtd_anterior"].sum()) * preco_anterior
efeito_preco = (preco_atual - preco_anterior) * comp["qtd_atual"].sum()
efeito_mix = crescimento_comparavel - efeito_volume - efeito_preco

print(f"Crescimento total: {crescimento_total:.2f}")
print(f"  Lojas novas: {crescimento_lojas_novas:.2f}")
print(f"  Comparável: {crescimento_comparavel:.2f}")
print(f"    Preço: {efeito_preco:.2f} | Volume: {efeito_volume:.2f} | Mix: {efeito_mix:.2f}")

```

Regressão de Poisson com efeitos fixos

1. Que problema isso resolve?

Um analista quer prever quantos gols um time marca em uma partida, em função da força ofensiva do time, da força defensiva do adversário e de jogar em casa ou fora. O problema: número de gols é uma contagem — 0, 1, 2, 3... — e uma regressão linear comum pode prever valores absurdos como “−0,4 gol” ou tratar igualmente o salto de 0 para 1 gol e de 5 para 6 gols, quando na prática esses saltos não têm o mesmo “peso” estatístico.

2. Intuição

Contagens de eventos raros e discretos — gols numa partida, número de clientes que entram numa loja por hora, número de falhas de uma máquina por semana — tendem a seguir um padrão característico: nunca são negativas, são inteiras, e a maioria dos valores fica concentrada perto de zero com uma cauda longa à direita (é bem mais comum ver 0, 1 ou 2 gols do que 6 ou 7). Uma distribuição normal (a curva de sino simétrica) não captura nada disso — ela permite valores negativos e é simétrica ao redor da média. A distribuição de Poisson foi desenhada exatamente para esse tipo de dado.

3. Explicação simples

A regressão de Poisson modela o número esperado de eventos como uma função exponencial das variáveis explicativas, garantindo que a previsão nunca seja negativa. Em vez de prever o número de gols diretamente, o modelo prevê o **logaritmo** do número esperado de gols como uma combinação linear das variáveis — e depois converte de volta usando a exponencial. Essa escolha (chamada de “forma log-linear”) é o que garante que, não importa quais sejam os coeficientes, a previsão final sempre será positiva.

Efeitos fixos por time entram no modelo como um “ajuste individual” para cada equipe — uma forma de dizer “descontando o quanto esse time específico costuma marcar ou sofrer gols, o que sobra do efeito que estou investigando (por exemplo, mandar o jogo em casa)?”

4. Exemplo conceitual fácil

Imagine comparar o número médio de clientes que entram em duas lojas por hora: uma no centro (movimento alto) e uma no bairro (movimento baixo). Se você quer isolar o efeito de “ser sexta-feira” no fluxo de clientes, precisa primeiro descontar que a loja do centro já tem um patamar de movimento muito maior que a do bairro — senão qualquer diferença observada pode ser só reflexo de qual loja está sendo olhada, não do dia da semana. O efeito fixo por loja faz exatamente esse desconto, loja por loja, antes de estimar o efeito de “sexta-feira”.

5. Como funciona, em linhas gerais

1. Para cada observação (uma partida, uma hora, um período), o número esperado de eventos é escrito como $\lambda = e^{(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots)}$ — a soma ponderada das variáveis explicativas, exponenciada.
2. Uma dummy (variável indicadora) é criada para cada unidade que recebe efeito fixo (cada time, por exemplo) — isso permite que cada time tenha seu próprio “nível base” de gols esperados, sem impor que todos os times sejam iguais na ausência das outras variáveis.

3. O modelo é ajustado por máxima verossimilhança, encontrando os coeficientes que tornam os dados observados mais prováveis sob a suposição de que a contagem em cada observação segue uma distribuição de Poisson com média λ .
4. Cada coeficiente estimado representa o efeito daquela variável na escala logarítmica do número esperado de eventos.

6. O que o resultado significa

O coeficiente de uma variável, ao ser exponenciado (e^β), vira um **fator multiplicativo** sobre o número esperado de eventos — não um efeito aditivo. Se o coeficiente de “jogar em casa” é 0,30, então $e^{0,30} \approx 1,35$: jogar em casa multiplica o número esperado de gols por 1,35, ou seja, um aumento de 35%, mantendo tudo o mais constante.

7. Como interpretar

Sempre traduza o coeficiente bruto (na escala log) para o fator multiplicativo antes de comunicar o resultado — “o coeficiente foi 0,30” não diz nada a alguém sem estatística, mas “jogar em casa aumenta em 35% o número esperado de gols” é imediatamente interpretável. Fatores multiplicativos maiores que 1 indicam aumento; menores que 1, redução (por exemplo, 0,85 significa uma queda de 15%).

8. Quando é útil

Sempre que a variável de resposta é uma contagem de eventos — não uma proporção, não uma média contínua. É o tipo de modelo tipicamente usado em análises esportivas para estimar quantos gols uma equipe deve marcar, combinando a força ofensiva do próprio time, a força defensiva do adversário e o efeito de mandar o jogo em casa, com efeitos fixos por clube isolando as diferenças de nível entre equipes.


9. Cuidados importantes

- A Poisson assume que a variância da contagem é igual à média (equidispersão). Quando a variância observada é claramente maior que a média — **sobredispersão** — os erros-padrão calculados pela Poisson pura ficam artificialmente pequenos, inflando a aparente significância estatística. Nesses casos, modelos alternativos (Poisson com erro-padrão robusto, binomial negativa) são mais adequados.
- Efeitos fixos por unidade (time, loja) consomem graus de liberdade — com muitas unidades e poucas observações por unidade, o modelo pode ficar instável.
- O modelo pressupõe independência entre eventos condicional às variáveis incluídas; contextos com forte dependência temporal (uma sequência de vitórias que muda a confiança do time) violam essa suposição.

10. Um exemplo pequeno com números

Suponha um modelo simplificado (sem efeitos fixos, para ilustrar a mecânica) em que o número esperado de gols de um time visitante é $\lambda = e^{0,10} \approx 1,11$ e, jogando em casa, $\lambda = e^{0,10+0,30} = e^{0,40} \approx 1,49$. A razão entre os dois, $1,49/1,11 \approx 1,35$, confirma que o efeito de jogar em casa multiplica o número esperado de gols por 1,35 — um aumento de 35% — sem que precisemos calcular a

diferença simples entre 1,49 e 1,11 (que seria apenas 0,38 gol, uma leitura menos informativa que o fator multiplicativo).



Dados ilustrativos, não representam nenhum projeto real.

Figura 21: Distribuição de contagem de gols comparada a uma curva normal

11. Exemplo de código simples

```
import numpy as np
import pandas as pd
import statsmodels.api as sm
import statsmodels.formula.api as smf

# uma linha por partida-time: gols marcados, mando de campo e times envolvidos
df = pd.DataFrame({
    "gols": [1, 2, 0, 3, 1, 2, 0, 1, 2, 1],
    "mandante": [1, 0, 1, 0, 1, 0, 1, 0, 1, 0],
    "time": ["A", "A", "B", "B", "C", "C", "D", "D", "E", "E"],
})

modelo = smf.glm(
    formula="gols ~ mandante + C(time)",
    data=df,
    family=sm.families.Poisson(),
).fit()

print(modelo.summary())
```

```
# fator multiplicativo do efeito de mandar o jogo em casa  
coef_mandante = modelo.params["mandante"]  
print(f"Fator multiplicativo (jogar em casa): {np.exp(coef_mandante):.2f}")
```

Tendência por mínimos quadrados ponderados (WLS) com classificação por intervalo de confiança

1. Que problema isso resolve?

Um analista quer saber, para cada loja de uma rede, se o ticket médio está subindo, caindo ou estável ao longo dos últimos trimestres. O problema é que nem todos os trimestres têm o mesmo número de vendas registradas — um trimestre com 500 transações é uma estimativa muito mais confiável do que um com 20. Uma regressão linear comum trata todos os pontos como igualmente confiáveis, deixando um único trimestre com poucos dados distorcer a tendência estimada tanto quanto um trimestre robusto.

2. Intuição

Imagine perguntar a duas pessoas a nota média de um restaurante: uma respondeu com base em 400 avaliações, a outra com base em 3. Intuitivamente, você confia mais na primeira resposta. Mínimos quadrados ponderados (*Weighted Least Squares*, WLS) faz exatamente isso ao ajustar uma linha de tendência: dá mais peso aos pontos baseados em mais observações, e menos peso aos pontos baseados em poucas.

3. Explicação simples

O método ajusta uma reta (ou outra tendência simples) aos dados ao longo do tempo, exatamente como uma regressão linear comum — mas em vez de minimizar a soma simples dos erros ao quadrado, minimiza a soma **ponderada** dos erros ao quadrado, usando o número de observações de cada período como peso. Depois de estimar a inclinação da reta, calcula-se um intervalo de confiança para essa inclinação, e a tendência é classificada de forma simples e objetiva:

- Se o intervalo de confiança da inclinação está inteiramente **acima de zero** → tendência de **alta**.
- Se está inteiramente **abaixo de zero** → tendência de **queda**.
- Se o intervalo **inclui o zero** → tendência **estável** (não há evidência estatística suficiente de que a inclinação seja diferente de zero).

4. Exemplo conceitual fácil

Duas lojas registram ticket médio ao longo de seis trimestres. A Loja A sobe de forma consistente, trimestre após trimestre, com muitas vendas em cada período — a inclinação estimada é claramente positiva e o intervalo de confiança não chega perto de zero: classificação de “subindo”. A Loja B oscila para cima e para baixo sem padrão claro, com poucas vendas em alguns trimestres — a inclinação estimada pode até ser levemente positiva, mas o intervalo de confiança é largo o suficiente para incluir zero: classificação de “estável”, mesmo que a reta ajustada não seja perfeitamente horizontal.

5. Como funciona, em linhas gerais

1. Para cada unidade (loja, região, categoria), organiza-se a métrica de interesse ao longo do tempo (trimestre, mês) junto com o número de observações que sustentam cada ponto.

2. Ajusta-se uma reta pelo método dos mínimos quadrados ponderados, em que o peso de cada ponto é proporcional ao seu número de observações — pontos com mais dados “puxam” mais a reta na direção deles.
3. Calcula-se o erro-padrão da inclinação estimada, que já incorpora a ponderação.
4. Constrói-se um intervalo de confiança (tipicamente 95%) para a inclinação.
5. Classifica-se a tendência como subindo, caindo ou estável, dependendo da posição do intervalo de confiança em relação a zero.

6. O que o resultado significa

A inclinação estimada diz o quanto, em média, a métrica muda por período. O intervalo de confiança diz o quão precisa é essa estimativa — intervalos largos (comuns quando há poucas observações, muita variabilidade, ou poucos períodos de tempo) tornam mais difícil afirmar com confiança que existe uma tendência real, mesmo que a inclinação pontual pareça diferente de zero.

7. Como interpretar

“Estável” na classificação não significa necessariamente “sem nenhuma mudança” — significa “não há evidência estatística suficiente, dados o volume e a variabilidade observados, para distinguir a inclinação de zero”. Uma loja pode estar genuinamente estável, ou pode simplesmente não ter dados suficientes para detectar uma tendência real que exista mas seja pequena. É importante não confundir as duas situações ao comunicar o resultado.

8. Quando é útil


Sempre que se quer classificar a tendência de muitas unidades (lojas, jogadores, regiões, produtos) de forma sistemática e comparável, especialmente quando o número de observações por período varia bastante entre unidades ou ao longo do tempo. É a lógica usada em análises esportivas para classificar se o desempenho de um clube está em ascensão, queda ou estabilidade ao longo de uma temporada, ponderando cada período pelo número de partidas ou eventos observados naquele trecho.

9. Cuidados importantes

- A classificação por IC depende do nível de confiança escolhido (95% é comum, mas não universal) — um IC de 90% classifica mais séries como “subindo” ou “caindo” que um IC de 99%, para os mesmos dados.
- Poucos pontos no tempo (por exemplo, só três ou quatro períodos) tornam o intervalo de confiança muito largo, dificultando qualquer classificação diferente de “estável” mesmo quando existe uma tendência real.
- WLS assume uma relação linear com o tempo; tendências não lineares (crescimento que acelera ou desacelera) podem ser mal capturadas por uma única reta.
- O peso pelo número de observações corrige desigualdade de precisão amostral, mas não corrige problemas de qualidade dos dados dentro de cada período (por exemplo, um período com muitas transações mas registradas com erro sistemático).

10. Um exemplo pequeno com números

Duas lojas, doze trimestres cada, número de observações variando de 40 a 400 por trimestre. Na Loja A, a inclinação estimada por WLS é de +2,4 (unidades da métrica por trimestre), com intervalo de confiança de 95% entre +1,1 e +3,7 — inteiramente acima de zero, classificada como **subindo**. Na Loja B, a inclinação estimada é de +0,05, com intervalo de confiança entre -1,2 e +1,3 — cruza o zero, classificada como **estável**, mesmo que a inclinação pontual seja tecnicamente positiva.



Dados ilustrativos, não representam nenhum projeto real.

Figura 22: Classificação de tendência ponderada para duas lojas

11. Exemplo de código simples

```
import numpy as np
import pandas as pd
import statsmodels.api as sm

df = pd.DataFrame({
    "trimestre": range(12),
    "ticket_medio": [100, 102, 105, 104, 108, 110, 111, 115, 116, 119, 121, 124],
    "n_observacoes": [40, 55, 380, 390, 60, 400, 45, 370, 50, 360, 400, 390],
})

X = sm.add_constant(df["trimestre"])
modelo = sm.WLS(df["ticket_medio"], X, weights=df["n_observacoes"]).fit()

inclinacao = modelo.params["trimestre"]
ic_baixo, ic_alto = modelo.conf_int(alpha=0.05).loc["trimestre"]

if ic_baixo > 0:
    classificacao = "subindo"
elif ic_alto < 0:
    classificacao = "caindo"
```

```
else:
    classificacao = "estável"

print(f"Inclinação: {inclinacao:.2f} | IC 95%: [{ic_baixo:.2f}, {ic_alto:.2f}] | Classificação
```

Regressão logística

1. Que problema isso resolve?

Um analista quer prever se algo vai acontecer ou não — um cliente cancela ou não, um time cai ou não, um paciente responde ao tratamento ou não — a partir de uma ou mais variáveis contínuas. O problema: o desfecho é binário (0 ou 1), e uma regressão linear comum, ajustada diretamente a essa variável de 0/1, pode prever valores como $-0,3$ ou $1,4$, que não correspondem a nenhuma probabilidade real.

2. Intuição

Uma probabilidade precisa ficar entre 0 e 1, sempre. A regressão logística resolve isso modelando, não a probabilidade diretamente, mas uma transformação dela — o **log da razão de chances** (log-odds) — como uma combinação linear das variáveis explicativas. Essa combinação linear pode assumir qualquer valor, de menos a mais infinito; a transformação de volta (a função logística, em forma de S) comprime esse valor para o intervalo (0, 1), garantindo que a saída do modelo seja sempre uma probabilidade válida.

3. Explicação simples

O modelo estima, para cada combinação de variáveis explicativas, a probabilidade do desfecho ser 1. A curva que relaciona a combinação linear das variáveis à probabilidade tem formato de S (sigmoide): perto do meio, pequenas mudanças na variável mudam bastante a probabilidade prevista; nos extremos (perto de 0 ou perto de 1), a mesma mudança tem efeito quase nenhum — a probabilidade já está perto do limite e não pode ultrapassá-lo.

4. Exemplo conceitual fácil

Pense em prever se um estudante passa numa prova a partir de quantas horas estudou. Quem estudou 0 horas quase certamente não passa; quem estudou 20 horas quase certamente passa — nos dois extremos, uma hora a mais ou a menos quase não muda a previsão. É na faixa do meio (por exemplo, entre 4 e 8 horas) que uma hora extra de estudo faz mais diferença na probabilidade de aprovação — exatamente a região onde a curva em S é mais inclinada.

5. Como funciona, em linhas gerais

1. Para cada observação, o modelo calcula uma combinação linear das variáveis explicativas:
$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots$$
2. Essa combinação passa pela função logística, $p = 1/(1 + e^{-z})$, que converte qualquer número real numa probabilidade entre 0 e 1.
3. Os coeficientes β são estimados por máxima verossimilhança — o conjunto de valores que torna os desfechos observados (quem teve 1, quem teve 0) mais prováveis sob o modelo.
4. Para classificar uma observação nova, compara-se a probabilidade prevista a um limiar (0,5, por padrão) — acima, prevê-se 1; abaixo, prevê-se 0. O limiar pode ser ajustado conforme o custo de cada tipo de erro.

6. O que o resultado significa

Cada coeficiente, exponenciado (e^β), vira uma **razão de chances** (odds ratio): quanto a chance do desfecho ser 1 multiplica quando a variável aumenta em uma unidade, mantendo tudo o mais constante. Uma razão de chances de 2,0 significa que a chance dobra; uma de 0,5, que ela cai pela metade. “Chance” aqui é a razão $p/(1-p)$, não a probabilidade p em si — a distinção importa porque razão de chances e probabilidade não mudam na mesma proporção.

7. Como interpretar

Traduza sempre o coeficiente bruto (na escala log-odds) para razão de chances antes de comunicar — “o coeficiente foi 0,69” não diz nada por si só, mas “cada ponto a mais na pontuação de satisfação reduz a chance de cancelamento pela metade” ($e^{-0,69} \approx 0,50$) é imediatamente interpretável. Para avaliar a qualidade do modelo como classificador — não só a significância dos coeficientes —, duas métricas usuais são a **AUC** (área sob a curva ROC: a probabilidade de o modelo dar uma pontuação mais alta a uma observação positiva aleatória do que a uma negativa aleatória; 0,5 é aleatório, 1,0 é separação perfeita) e o **Brier score** (erro quadrático médio entre probabilidade prevista e desfecho observado; quanto menor, melhor calibrado).

8. Quando é útil

Sempre que o desfecho de interesse é binário e se quer tanto **quantificar o efeito** de cada variável explicativa (via razão de chances) quanto **prever uma probabilidade** para casos novos — não apenas uma classificação 0/1. É o tipo de modelo indicado para transformar um indicador contínuo (ritmo de pontos, pontuação de satisfação, tempo de uso) numa chance real de um desfecho binário acontecer.


9. Cuidados importantes

- **Quase-separação:** quando uma variável separa quase perfeitamente as duas classes (por exemplo, todo mundo acima de certo valor tem desfecho 1 e todo mundo abaixo tem 0), o algoritmo de máxima verossimilhança não converge de forma estável — os coeficientes e seus erros-padrão ficam artificialmente grandes. Isso costuma acontecer justamente quando o modelo está funcionando bem, e não invalida a direção do efeito, mas exige cautela ao interpretar o intervalo de confiança.
- **Correlação entre observações:** se várias observações vêm da mesma unidade (o mesmo cliente em meses diferentes, o mesmo time em rodadas diferentes de uma temporada), tratá-las como independentes infla artificialmente a confiança do modelo. Nesses casos, validar com uma divisão que respeite a estrutura de grupo (por exemplo, deixar uma unidade inteira de fora por vez) é mais confiável do que confiar só no ajuste dentro da amostra.
- **Significância não é acurácia:** um coeficiente pode ser estatisticamente significativo (p pequeno) e o modelo, mesmo assim, ter pouco poder de separar as classes (AUC próxima de 0,5) — são perguntas diferentes.

10. Um exemplo pequeno com números

Suponha um modelo com uma única variável (x = pontuação de satisfação de 0 a 10) prevendo cancelamento, com coeficiente $\hat{\beta} = -0,69$ (erro-padrão 0,10) e intercepto $\hat{\beta}_0 = 3,45$. A razão de chances é $e^{-0,69} \approx 0,50$: cada ponto a mais de satisfação reduz a chance de cancelamento pela

metade. O ponto de 50% de probabilidade prevista fica em $x = -\hat{\beta}_0/\hat{\beta} = 5,0$ — abaixo disso, o modelo prevê mais chance de cancelar do que de ficar; acima, o contrário.



dados simulados, fins didáticos.

Figura 23: Regressão logística: da variável contínua à probabilidade

11. Exemplo de código simples


```
import numpy as np
import pandas as pd
import statsmodels.api as sm

# uma linha por cliente: pontuação de satisfação e se cancelou (1) ou não (0)
df = pd.DataFrame({
    "satisfacao": [1, 2, 3, 4, 5, 6, 7, 8, 9, 10],
    "cancelou":   [1, 1, 1, 1, 0, 1, 0, 0, 0, 0],
})

X = sm.add_constant(df["satisfacao"])
modelo = sm.Logit(df["cancelou"], X).fit()
print(modelo.summary())

# razão de chances de cada ponto a mais de satisfação
print(f"Razão de chances: {np.exp(modelo.params['satisfacao']):.2f}")

# probabilidade prevista para um cliente com satisfação = 6
print(modelo.predict([1, 6]))
```



classificador ilustrativo, dados simulados.

Figura 24: Curva ROC de um classificador ilustrativo