

Metodologias Estatísticas — Explicação Completa

Sumário

Fundamentos de teste A/B

Este documento cobre os fundamentos estatísticos de um teste A/B — desenho experimental, aleatorização, efeito, erro-padrão, intervalo de confiança e teste de hipótese para médias e proporções. Os três documentos seguintes (Sample Ratio Mismatch, balanceamento de covariáveis e teste de não-inferioridade) pressupõem este conteúdo como pré-requisito e vão direto ao que cada um acrescenta.

Conceito

Um teste A/B é um experimento controlado e randomizado aplicado a um contexto de produto ou negócio: unidades (geralmente usuários) são designadas aleatoriamente a uma condição de controle ou de tratamento, e uma métrica primária pré-definida é comparada entre os dois grupos ao final de um período fixo.

A ideia central é isolar o efeito causal da mudança testada. Em uma comparação observacional — por exemplo, “antes” versus “depois” do lançamento, ou usuários que optaram por usar um recurso novo versus os que não optaram — qualquer diferença encontrada pode vir de dezenas de fatores que também mudam ao longo do tempo ou que diferem sistematicamente entre quem escolhe e quem não escolhe algo. A aleatorização quebra esse vínculo: em expectativa, o sorteio torna os dois grupos comparáveis em tudo, observável ou não, exceto na condição atribuída. Isso é o que permite atribuir uma diferença de resultado à mudança testada, com uma margem de incerteza quantificável.

Formulação matemática

Diferença de médias (métrica contínua)

Sejam os grupos controle (C) e tratamento (T), com médias amostrais $\bar{x}_C$ e $\bar{x}_T$, variâncias amostrais s_C^2 e s_T^2 , e tamanhos n_C e n_T . O efeito estimado é:

$$\hat{\Delta} = \bar{x}_T - \bar{x}_C$$

O erro-padrão dessa diferença, sem assumir variâncias iguais entre os grupos (a mesma lógica do teste t de Welch), é:

$$SE(\hat{\Delta}) = \sqrt{\frac{s_T^2}{n_T} + \frac{s_C^2}{n_C}}$$

A estatística de teste e o intervalo de confiança de 95% seguem como:

$$t = \frac{\hat{\Delta}}{SE(\hat{\Delta})}, \quad \text{IC 95\%} = \hat{\Delta} \pm z_{0,975} \cdot SE(\hat{\Delta})$$

onde $z_{0,975} \approx 1,96$ para uma aproximação normal (adequada com amostras grandes; com amostras pequenas, usa-se o quantil da distribuição t com os graus de liberdade de Welch-Satterthwaite).

Diferença de proporções (métrica binária, como conversão)

Sejam $\hat{p}_C = x_C/n_C$ e $\hat{p}_T = x_T/n_T$ as taxas observadas em cada grupo, com x_C e x_T conversões e n_C , n_T tamanhos de amostra. O efeito estimado é $\hat{\Delta} = \hat{p}_T - \hat{p}_C$. Para o teste de hipótese, usa-se a proporção combinada (pooled) sob a hipótese nula de igualdade:

$$\hat{p}_{pool} = \frac{x_C + x_T}{n_C + n_T}, \quad SE_0 = \sqrt{\hat{p}_{pool}(1 - \hat{p}_{pool}) \left(\frac{1}{n_C} + \frac{1}{n_T} \right)}$$

$$z = \frac{\hat{p}_T - \hat{p}_C}{SE_0}$$

Note que o erro-padrão usado no teste (SE_0 , sob H_0) é diferente do erro-padrão usado para construir o intervalo de confiança em torno do efeito observado, que não assume proporções iguais:

$$SE(\hat{\Delta}) = \sqrt{\frac{\hat{p}_C(1 - \hat{p}_C)}{n_C} + \frac{\hat{p}_T(1 - \hat{p}_T)}{n_T}}$$

Tamanho de amostra / poder

O tamanho de amostra necessário para detectar um efeito mínimo δ com poder $1 - \beta$ e significância α (teste de duas pontas) é aproximadamente, para uma métrica de proporção:

$$n \approx \frac{(z_{1-\alpha/2} + z_{1-\beta})^2 \cdot [p_C(1 - p_C) + p_T(1 - p_T)]}{\delta^2}$$

onde $z_{1-\alpha/2}$ e $z_{1-\beta}$ são os quantis normais correspondentes à confiança e ao poder desejados, e $\delta = p_T - p_C$ é o efeito mínimo que se quer conseguir detectar.

Suposições

- **Aleatorização efetiva:** cada unidade elegível tem probabilidade de designação conhecida (tipicamente igual) e independente das demais. Sem isso, todo o argumento causal desmorona — daí a importância de checar a proporção observada de alocação (ver Sample Ratio Mismatch).
- **Independência entre unidades:** o resultado de uma unidade não deve depender de qual condição outra unidade recebeu (ausência de interferência ou “SUTVA” — Stable Unit Treatment Value Assumption). Em contextos com efeitos de rede ou de mercado compartilhado, essa suposição pode falhar.

- **Métrica bem definida e estável antes do experimento:** a métrica primária, sua janela de agregação e o critério de elegibilidade devem ser fixados antes de olhar os dados, para evitar viés de seleção retroativa.
- **Ausência de espionagem repetida (peeking) sem correção:** parar o experimento assim que o valor-p cruza 0,05, sem um método sequencial apropriado, infla a taxa de falso positivo muito acima do α nominal.

Hipóteses

Para uma métrica contínua ou de proporção, o teste de duas pontas padrão é:

$$H_0 : \Delta = 0 \quad H_1 : \Delta \neq 0$$

onde Δ é a diferença real (populacional) entre tratamento e controle. O nível de significância α é tipicamente fixado em 0,05 antes do experimento. Rejeita-se H_0 quando o valor-p é menor que α , ou, equivalentemente, quando o intervalo de confiança de $(1 - \alpha)$ não contém zero.

Interpretação

Rejeitar H_0 é evidência de que o efeito observado não é plausivelmente explicado só por variação amostral — não é prova de causalidade por si só; essa leitura causal vem da aleatorização, não do teste estatístico em isolado. O tamanho do intervalo de confiança comunica a precisão da estimativa: dois experimentos podem ter o mesmo ponto estimado de efeito com graus de confiança muito diferentes, dependendo do tamanho de amostra e da variabilidade da métrica.

É essencial distinguir significância estatística de relevância prática. Um efeito de 0,05 ponto percentual em conversão pode ser estatisticamente significativo com milhões de usuários, mas não justificar o custo de engenharia da mudança. Da mesma forma, “não significativo” não equivale a “efeito nulo” — um experimento subdimensionado (poder baixo) simplesmente não tem sensibilidade para detectar efeitos do tamanho que realmente importam; nesse caso, o resultado correto a reportar é “não há evidência suficiente”, não “não há efeito”.

Limitações

- Um teste A/B mede o efeito médio populacional sob as condições específicas do experimento (período, mix de usuários, contexto de produto naquele momento) — generalizar o resultado para outro período ou população exige cautela.
- Testar muitas métricas secundárias simultaneamente sem correção para comparações múltiplas aumenta a chance de encontrar “efeitos” espúrios. Achados secundários interessantes merecem ser tratados como hipótese a confirmar num experimento dedicado, não como conclusão definitiva.
- O resultado agregado pode esconder heterogeneidade — o efeito pode ser positivo para um subgrupo e negativo para outro, cancelando-se no total (ver teste de heterogeneidade/interação).
- A validade de tudo depende da randomização ter funcionado como planejado; o teste de hipótese em si não verifica isso.


Exemplo

Suponha um site de e-commerce testando um novo layout da página de checkout contra o layout atual. A equipe randomiza 12.000 visitantes para cada braço e roda o experimento por duas semanas completas, sem parar antes do previsto.

Resultado observado:

	Controle	Tratamento
Visitantes	12.000	12.000
Conversões	984	1.128
Taxa	8,20%	9,40%

O efeito estimado é $\hat{\Delta} = 0,094 - 0,082 = 0,012$ (1,2 ponto percentual). A proporção combinada sob H_0 é $\hat{p}_{pool} = (984 + 1128)/24000 \approx 0,088$, o que dá $SE_0 \approx 0,00366$ e $z \approx 3,28$, correspondendo a um valor-p abaixo de 0,01. O intervalo de confiança de 95% para a diferença, calculado sem assumir proporções iguais, fica aproximadamente entre 0,4 e 2,0 pontos percentuais — inteiramente acima de zero.



Dados ilustrativos, não representam nenhum projeto real.

Figura 1: Distribuição de referência sob a hipótese nula com a estatística observada marcada

A conclusão estatística é clara: o novo layout aumentou a conversão, e o tamanho desse aumento (entre aproximadamente 5% e 24% de aumento relativo, dependendo de onde no intervalo o efeito real estiver) é grande o bastante para justificar investigação de custo-benefício de lançamento. Antes de declarar vitória, porém, a equipe checaria: (1) se a alocação observada (12.000/12.000, ou próxima disso) bate com o planejado — um teste de SRM; e (2) se nenhuma métrica de guardrail, como tempo de carregamento ou taxa de erro, piorou além de uma margem aceitável — um teste de não-inferioridade.

Erros-padrão robustos a cluster

Conceito

A inferência estatística clássica (erros-padrão de mínimos quadrados ordinários, por exemplo) assume que os erros do modelo são independentes e identicamente distribuídos entre observações. Essa suposição é violada sempre que os dados têm estrutura de **agrupamento**: observações dentro do mesmo cluster (loja, região, domicílio, turma, unidade amostral de uma pesquisa) compartilham choques não observados em comum, o que gera correlação intra-cluster nos erros.

Ignorar essa estrutura não enviesava o ponto estimado do coeficiente — o estimador de mínimos quadrados continua não-viesado sob as suposições usuais — mas enviesava **para baixo** o erro-padrão calculado, porque a fórmula padrão conta cada observação como uma unidade totalmente independente de informação, quando na verdade parte da variação dentro do cluster é repetição, não novidade.

O erro-padrão robusto a cluster (também chamado de “cluster-robust variance estimator”, CRVE) corrige isso permitindo correlação arbitrária dentro de cada cluster e exigindo independência apenas entre clusters.

Formulação matemática

Para um modelo linear $Y_i = X_i'\beta + \varepsilon_i$, o estimador de mínimos quadrados é $\hat{\beta} = (X'X)^{-1}X'Y$. A variância clássica de $\hat{\beta}$ assume ε_i i.i.d. com variância σ^2 :

$$\widehat{\text{Var}}(\hat{\beta})_{\text{clássico}} = \hat{\sigma}^2(X'X)^{-1}$$

O estimador robusto a cluster, com G clusters indexados por $g = 1, \dots, G$, cada um com matriz de covariáveis X_g e vetor de resíduos $\hat{u}_g = Y_g - X_g\hat{\beta}$, é da forma “sanduíche”:

$$\widehat{\text{Var}}(\hat{\beta})_{\text{cluster}} = (X'X)^{-1} \left(\sum_{g=1}^G X_g' \hat{u}_g \hat{u}_g' X_g \right) (X'X)^{-1}$$

onde:

- $X_g' \hat{u}_g \hat{u}_g' X_g$ é a contribuição do cluster g ao termo central — permite que os resíduos de observações do mesmo cluster estejam correlacionados entre si de forma arbitrária, sem impor uma estrutura específica de correlação;
- a soma é feita cluster por cluster, não observação por observação — é isso que preserva a correlação interna em vez de tratá-la como ruído independente;
- $(X'X)^{-1}$ nas pontas (“pão” do sanduíche) é a mesma matriz do estimador clássico.

É comum aplicar uma correção de graus de liberdade em amostras finitas, multiplicando o resultado por um fator como:

$$c = \frac{G}{G-1} \cdot \frac{n-1}{n-k}$$

com n o número total de observações, k o número de parâmetros estimados, e G o número de clusters — essa correção ajuda, mas não resolve completamente, o comportamento problemático com poucos clusters (ver limitações).

Suposições

- **Independência entre clusters.** A correção só é válida se clusters diferentes forem de fato independentes entre si — se houver dependência também entre clusters (por exemplo, um choque macroeconômico afetando todas as regiões ao mesmo tempo), o erro-padrão robusto a cluster ainda subestima a incerteza real.
- **Número de clusters suficientemente grande.** As propriedades assintóticas do estimador dependem de $G \rightarrow \infty$. Na prática, valores de G abaixo de 30-40 tornam a aproximação normal da distribuição de $\hat{\beta}$ pouco confiável, mesmo com n grande dentro de cada cluster.
- **A variável de cluster está corretamente especificada.** Agrupar no nível errado (por exemplo, por loja quando a verdadeira fonte de correlação é por região, que agrega várias lojas) subestima a correlação real e ainda produz erro-padrão pequeno demais.

Hipóteses

O CRVE não introduz um novo teste de hipótese — ele é um método de cálculo de erro-padrão, usado dentro dos testes usuais sobre coeficientes de regressão:

- $H_0: \beta_j = 0$ (o coeficiente de interesse é nulo na população)
- $H_1: \beta_j \neq 0$
- Estatística de teste: $t = \hat{\beta}_j / \widehat{SE}_{\text{cluster}}(\hat{\beta}_j)$, comparada à distribuição t com $G - 1$ graus de liberdade (uma escolha comum e conservadora, já que a variação efetiva de informação está mais próxima do número de clusters do que do número de observações).
- Intervalo de confiança de 95%: $\hat{\beta}_j \pm t_{0,975, G-1} \cdot \widehat{SE}_{\text{cluster}}(\hat{\beta}_j)$.

Interpretação

O ponto estimado do efeito não muda ao trocar o erro-padrão clássico pelo robusto a cluster — só a incerteza em volta dele muda. Um efeito que deixa de ser significativo sob erro-padrão robusto a cluster não é “menos real” — a estimativa continua sendo a melhor disponível; apenas a confiança declarada nela estava inflada antes da correção.

Vale reforçar: o erro-padrão robusto a cluster corrige a inferência, não a identificação causal. Se o desenho do estudo tem outros problemas (variável omitida, seleção, ausência de randomização), o erro-padrão robusto a cluster não resolve nada disso — ele só garante que, dado o ponto estimado, a margem de erro declarada é mais fiel à estrutura de dependência dos dados.

Limitações

- **Poucos clusters.** Esta é a limitação mais citada na literatura aplicada. Com poucos clusters (regra prática comum: abaixo de 30-40), o CRVE tende a subestimar a variância verdadeira, mesmo com a correção de graus de liberdade, e a distribuição da estatística de teste se afasta da aproximação t assumida. Nesse cenário, dois caminhos alternativos, cobertos em documentos próprios neste repositório, costumam funcionar melhor: **inferência por randomização**, quando o número de reatribuições possíveis do tratamento é pequeno o suficiente para enumerar (ou amostrar) diretamente; e **bootstrap wild-cluster**, que reamostra resíduos multiplicados por sinais aleatórios por cluster e tende a ter melhor comportamento em amostras finitas com poucos clusters do que o CRVE assintótico. Em geral: CRVE é a opção padrão e mais simples quando há clusters suficientes (dezenas ou mais); com poucos clusters, prefira wild-cluster bootstrap como alternativa mais acessível computacionalmente, ou inferência

por randomização quando a estrutura do desenho permitir enumerar as reatribuições possíveis de forma natural.

- **Clusters muito desiguais em tamanho.** Um cluster muito maior que os demais pode dominar a soma da fórmula sanduíche, tornando a estimativa de variância instável.
- **Escolha do nível de cluster.** Agrupar em um nível “fino” demais (subestimando a correlação real) invalida a correção tanto quanto ignorar o agrupamento por completo. Na dúvida, o nível de cluster deveria corresponder ao nível em que o tratamento (ou a fonte de dependência) de fato varia.

Exemplo


Uma rede de cafeterias testa um novo layout de balcão em 24 unidades (12 tratamento, 12 controle), medindo o tempo médio de fila por cliente, com cerca de 150 observações de clientes por unidade — 3.600 observações no total.

Um modelo simples de comparação de médias, ignorando a estrutura de cluster, estima um efeito de $-1,8$ minuto no tempo de fila, com erro-padrão de $0,25$ (tratando as 3.600 observações como independentes), dando $t \approx -7,2$ — fortemente significativo.

Ao recalcular o erro-padrão como robusto a cluster, agrupando por unidade (24 clusters), o erro-padrão sobe para $0,68$ — quase três vezes maior — dando $t \approx -2,65$. Ainda significativo ao nível de 5%, mas com uma margem de confiança substancialmente mais realista: o intervalo de 95% passa de aproximadamente $[-2,3; -1,3]$ para $[-3,2; -0,4]$.

A razão da diferença: clientes da mesma unidade compartilham o mesmo barista, o mesmo fluxo de horário de pico e a mesma disposição física da fila — fatores que fazem os tempos de fila dentro da mesma unidade se parecerem entre si por motivos que nada têm a ver com o novo layout. A informação real disponível está muito mais próxima de vir de 24 unidades do que de 3.600 clientes independentes.

Com apenas 24 clusters, ainda dentro de uma faixa razoável para o CRVE funcionar bem, mas próxima do limite em que valeria a pena confirmar o resultado com wild-cluster bootstrap como checagem de robustez adicional.



Dados ilustrativos, não representam nenhum projeto real.

Figura 2: Intervalo de confiança calculado com erro-padrão ingênuo comparado ao intervalo com erro-padrão robusto a cluster, mesmo ponto estimado

Decomposição de coorte e retenção

Conceito

Uma métrica agregada de retenção — calculada sobre toda a base de clientes num dado mês — confunde dois eixos de variação que precisam ser separados para uma leitura correta: a **dinâmica ao longo do ciclo de vida** (como a retenção de um grupo de clientes evolui à medida que o tempo passa desde que eles entraram) e a **dinâmica de composição** (como a proporção de clientes em diferentes fases do ciclo de vida muda ao longo do calendário, à medida que a empresa cresce ou desacelera aquisição).

A decomposição de coorte resolve essa confusão reorganizando os dados em torno do tempo desde a entrada (*tenure*), em vez do tempo de calendário. Uma **coorte** é o conjunto de clientes que entraram no sistema durante o mesmo período de referência (um mês, uma semana). A **curva de retenção de uma coorte** é a sequência de frações da coorte original ainda ativas em cada período subsequente. Comparando curvas de coortes diferentes, alinhadas por *tenure*, é possível atribuir uma mudança na métrica agregada a três fontes possíveis, não mutuamente exclusivas: deterioração específica de uma ou mais coortes recentes, deterioração generalizada (um evento de calendário que afeta todas as coortes simultaneamente, independente de sua idade), ou mudança na composição da base (mais peso relativo de coortes jovens, que naturalmente retêm pior nos primeiros meses do que coortes maduras).

Formulação matemática

Seja N_c o tamanho inicial da coorte c (número de clientes que entraram no período c), e seja $A_{\{c, t\}}$ o número de clientes dessa coorte ainda ativos t períodos depois da entrada. A curva

de retenção da coorte é:

$$R_c(t) = A_{\{c,t\}} / N_c$$

com $R_c(0) = 1$ por definição.

A retenção agregada observada no período de calendário T , considerando todas as coortes que já existiam até T , é uma média ponderada das curvas individuais, avaliada em diferentes pontos de tenure:

$$R_{\text{agregada}}(T) = \sum_c [N_c \cdot R_c(T - c)] / \sum_c N_c$$

onde a soma é sobre todas as coortes $c \leq T$, e $T - c$ é o tenure da coorte c no momento T (quanto tempo se passou desde sua entrada).

Essa fórmula deixa explícito o mecanismo de confusão: $R_{\text{agregada}}(T)$ muda de um período de calendário para o outro tanto porque as curvas individuais $R_c(\cdot)$ mudam (efeito de comportamento), quanto porque os pesos relativos N_c das coortes recentes versus antigas mudam (efeito de composição), sem que nenhuma curva individual precise mudar.

Uma decomposição simples da variação da retenção agregada entre dois momentos (T_0 e T_1) pode ser aproximada separando os dois efeitos:

$$\Delta R_{\text{agregada}} \approx \text{Efeito de comportamento} + \text{Efeito de composição}$$

$$\text{Efeito de comportamento} = \sum_c w_c(T_0) \cdot [R_c(T_1 - c) - R_c(T_0 - c)]$$

$$\text{Efeito de composição} = \sum_c [w_c(T_1) - w_c(T_0)] \cdot R_c(T_1 - c)$$

onde $w_c(T)$ é o peso da coorte c na base total em T (N_c dividido pelo total de clientes ativos considerados em T). O primeiro termo isola quanto da mudança vem de as curvas de retenção terem realmente mudado; o segundo isola quanto vem apenas da mudança na composição de coortes que compõem a base.


Suposições

- **Tenure comparável entre coortes:** a decomposição assume que “mês 3 desde a entrada” significa a mesma coisa para todas as coortes — ou seja, que o produto/serviço e o processo de onboarding não mudaram de forma que torne a comparação de tenure inválida entre coortes muito distantes no tempo.
- **Definição consistente de “ativo”:** a métrica de atividade que define $A_{\{c,t\}}$ (assinatura ativa, login no período, compra no período) precisa ser aplicada de forma idêntica a todas as coortes; uma mudança na própria definição operacional de “ativo” no meio do período analisado contamina a comparação.
- **Tamanho de coorte suficiente para estabilidade estatística:** coortes pequenas produzem curvas de retenção com variância amostral alta, especialmente em tenures avançados, onde restam poucos clientes da coorte original.
- **Ausência de censura diferencial:** coortes mais recentes têm, por definição, menos períodos observados (não é possível saber a retenção no mês 6 de uma coorte que entrou há 3 meses) — comparações que ignoram essa censura, comparando pontos de tenure não observados para coortes recentes, produzem conclusões inválidas.

Hipóteses

A decomposição de coorte é primariamente descritiva/exploratória, mas pode ser formalizada como teste de hipótese ao comparar a curva de uma coorte específica contra a curva média histórica:

- **H0:** a curva de retenção da coorte c em um tenure t específico não difere da retenção média histórica de coortes comparáveis no mesmo tenure ($R_c(t) = \bar{R}(t)$).



Dados ilustrativos, não representam nenhum projeto real.

Figura 3: Decomposição em cascata da queda agregada de retenção em efeito de coorte específica e efeito de mix

- **H1:** $R_c(t) \neq \bar{R}(t)$ — a coorte em questão retém de forma significativamente diferente do padrão histórico.

O teste pode ser conduzido como uma comparação de duas proporções (a coorte em questão vs. a média histórica ponderada, ou vs. a coorte imediatamente anterior), com um teste z de proporções ou um teste exato, dependendo do tamanho da coorte.

Interpretação

O resultado da decomposição direcional, de forma direta, o tipo de investigação subsequente. Um efeito de comportamento concentrado numa coorte específica direciona a investigação para o que foi diferente para quem entrou naquele período — uma mudança de produto, uma alteração no processo de cobrança, uma campanha de aquisição com público diferente. Um efeito de comportamento distribuído por todas as coortes ao mesmo tempo, a partir de um marco de calendário específico, direciona a investigação para um evento que afetou a base inteira simultaneamente, independente de tenure — uma mudança de preço geral, um problema técnico amplo, uma mudança regulatória. Um efeito de composição dominante, sem mudança relevante nas curvas individuais, direciona a atenção para a estratégia de aquisição — por que a base está mais jovem em média — em vez de para um problema de retenção propriamente dito.

É importante não interpretar uma coincidência temporal entre uma coorte pior e uma mudança conhecida como prova de causalidade — a decomposição identifica onde procurar, não confirma a causa. Confirmar a causa tipicamente exige informação adicional (por exemplo, uma mudança testada via experimento controlado, ou uma comparação com um grupo não afetado pela mudança suspeita).

Limitações

- A decomposição não controla por fatores de confusão dentro de uma coorte — se uma coorte específica também difere em composição demográfica ou de canal de aquisição em relação às demais, parte do “efeito de coorte” pode na verdade ser um efeito dessas outras variáveis, não do momento de entrada em si.
- Coortes recentes têm, inerentemente, menos pontos de tenure observados — qualquer comparação precisa restringir-se aos tenures efetivamente observados em todas as coortes comparadas, ou reconhecer explicitamente a incerteza maior nas coortes mais novas.
- A decomposição em efeito de comportamento e efeito de composição, como apresentada, é uma aproximação de primeira ordem — quando as mudanças em ambos os componentes são grandes, existe um termo de interação residual que a decomposição simples não atribui explicitamente a nenhum dos dois efeitos.
- A análise é observacional. Mesmo identificando com precisão que uma coorte específica piorou, e mesmo havendo uma mudança de produto coincidente, outros fatores concorrentes no mesmo período (sazonalidade, condições de mercado, ações de concorrentes) podem ser explicações alternativas que a decomposição de coorte, por si só, não descarta.

Exemplo

Uma rede fictícia de academias com modelo de assinatura mensal observa que a retenção agregada do mês 3 caiu de 58% no trimestre anterior para 52% no trimestre atual. A equipe decompõe a retenção por coorte de entrada (mês em que o cliente assinou):

Coorte	Tamanho da coorte	Retenção mês 3
Coorte T-3 (mais antiga)	1.240	59%
Coorte T-2	1.310	57%
Coorte T-1	1.180	58%
Coorte T (mais recente, período da queda)	1.850	41%

Duas coisas chamam atenção: primeiro, a coorte T tem retenção significativamente mais baixa (41% contra uma média histórica de aproximadamente 58% nas três coortes anteriores) — um efeito de comportamento concentrado nessa coorte. Segundo, a coorte T também é consideravelmente maior que as anteriores (1.850 contra uma média de cerca de 1.240 nas coortes anteriores) — o que significa que ela tem peso maior na média agregada do trimestre atual, amplificando o impacto da sua retenção mais baixa sobre a métrica geral (um efeito de composição adicional, ainda que secundário ao efeito de comportamento neste caso).

Investigando o que mudou especificamente para a coorte T, a equipe encontra que ela coincide com uma campanha de aquisição agressiva com desconto de primeiro mês, que trouxe um público historicamente menos propenso a continuar após o período promocional — uma explicação plausível tanto para a retenção mais baixa quanto para o tamanho maior da coorte.

Exemplo de código

```
import pandas as pd
import numpy as np

rng = np.random.default_rng(23)

coortes = pd.DataFrame({
    "coorte": ["T-3", "T-2", "T-1", "T"],
    "tamanho": [1240, 1310, 1180, 1850],
    "retencao_mes3": [0.59, 0.57, 0.58, 0.41],
})

## retenção agregada ponderada pelo tamanho da coorte
retencao_agregada = np.average(coortes["retencao_mes3"], weights=coortes["tamanho"])
print(f"Retenção agregada do trimestre: {retencao_agregada:.1%}")

## contrafactual: qual seria a retenção agregada se a coorte T tivesse a
## retenção média das coortes anteriores, mantendo o mesmo tamanho (isola o
## efeito de comportamento da coorte T)
retencao_media_historica = coortes.loc[coortes.coorte != "T", "retencao_mes3"].mean()
coortes_contrafactual = coortes.copy()
coortes_contrafactual.loc[coortes_contrafactual.coorte == "T", "retencao_mes3"] = retencao_media_historica
retencao_contrafactual = np.average(
    coortes_contrafactual["retencao_mes3"], weights=coortes_contrafactual["tamanho"]
)

efeito_comportamento_coorte_T = retencao_contrafactual - retencao_agregada
print(f"Retenção agregada se a coorte T tivesse retenção histórica: {retencao_contrafactual:.1%}")
print(f"Efeito atribuível à queda de comportamento da coorte T: {efeito_comportamento_coorte_T:.1%}")
```

Balanceamento de covariáveis e ajuste por covariáveis

Pressupõe os fundamentos de teste A/B — veja [Fundamentos de teste A/B](#).

Conceito

Este tópico cobre duas ferramentas relacionadas, mas conceitualmente distintas, ambas construídas sobre covariáveis medidas antes do início de um experimento.

Balanceamento de covariáveis é uma checagem de validade da randomização: compara-se a distribuição de características pré-experimento entre os grupos de tratamento e controle. Como a atribuição é aleatória, essas características — que não têm nenhuma relação causal com o tratamento, por terem sido medidas antes de ele existir — deveriam estar distribuídas de forma semelhante entre os grupos, a menos de variação amostral. Um desbalanceamento sistemático é evidência contra a premissa de que a randomização funcionou como planejado.

Ajuste por covariáveis (que inclui pós-estratificação e estimadores como CUPED) é uma técnica de redução de variância: usa covariáveis pré-experimento correlacionadas com a métrica de interesse para explicar parte da variação entre unidades que não tem relação com o tratamento, deixando a estimativa do efeito mais precisa — sem mudar o que ela estima. É importante não confundir os dois: balanceamento é uma checagem de diagnóstico feita (idealmente) antes de olhar resultados; ajuste é uma técnica de estimação aplicada ao calcular o efeito. Uma randomização bem-sucedida não precisa de ajuste para ser válida; o ajuste é sobre precisão, não sobre correção de um problema.

Formulação matemática

Diferença padronizada de médias (balanceamento)

Para uma covariável contínua X , com médias $\bar{x}_C$ e $\bar{x}_T$ e desvios-padrão s_C e s_T nos grupos controle e tratamento:

$$SMD = \frac{\bar{x}_T - \bar{x}_C}{\sqrt{\frac{s_C^2 + s_T^2}{2}}}$$

O denominador é o desvio-padrão combinado (pooled), o que torna o SMD independente da escala original da covariável e comparável entre covariáveis diferentes. Um limite de referência comumente citado na literatura de causal inference é $|SMD| < 0,1$ para balanceamento aceitável, embora esse valor seja uma convenção prática, não um limite derivado estatisticamente.

Para uma covariável binária com proporções $\hat{p}_C$ e $\hat{p}_T$:

$$SMD = \frac{\hat{p}_T - \hat{p}_C}{\sqrt{\frac{\hat{p}_C(1 - \hat{p}_C) + \hat{p}_T(1 - \hat{p}_T)}{2}}}$$

Estimador ajustado por covariáveis (regressão)

O efeito ajustado é obtido incluindo a covariável pré-experimento Z (já centralizada em sua média, por conveniência de interpretação) num modelo linear:

$$Y_i = \alpha + \tau \cdot D_i + \beta \cdot (Z_i - \bar{Z}) + \varepsilon_i$$

onde D_i é o indicador de tratamento (1 se tratamento, 0 se controle), τ é o efeito ajustado do tratamento, e β captura a relação entre a covariável e o resultado. Como D_i é (aproximadamente) independente de Z_i por construção da randomização, $\hat{\tau}$ estima o mesmo efeito médio que a diferença simples de médias — mas com variância residual ε_i menor do que a variância total de Y_i , o que reduz o erro-padrão de $\hat{\tau}$ na proporção de quanto Z explica de Y .

CUPED (variância residual)

Uma forma equivalente, popular em experimentação de produto, usa uma métrica ajustada diretamente:

$$Y_i^{CUPED} = Y_i - \theta \cdot (Z_i - \bar{Z}), \quad \theta = \frac{\text{Cov}(Y, Z)}{\text{Var}(Z)}$$

A redução relativa de variância obtida é aproximadamente:

$$\frac{\text{Var}(Y^{CUPED})}{\text{Var}(Y)} \approx 1 - \rho^2$$

onde ρ é a correlação entre a covariável Z e a métrica Y . Quanto mais correlacionada a covariável pré-experimento com a métrica, maior o ganho de precisão.

Suposições

- **Covariáveis usadas devem ser estritamente pré-tratamento** — medidas antes do início do experimento. Usar uma covariável pós-tratamento (por exemplo, número de sessões *durante* o experimento) introduz viés, porque ela já pode ter sido afetada pelo próprio tratamento.
- **A escolha das covariáveis de ajuste deve ser especificada antes de olhar os resultados**, para evitar o viés de escolher, a posteriori, a covariável que “melhora” o resultado desejado.
- **Balanceamento é necessário, mas não suficiente, para validade causal** — ele checka covariáveis observadas; nada garante balanceamento em fatores não medidos, embora a aleatorização em expectativa também os balanceie.
- **O modelo de ajuste deve ser razoavelmente bem especificado** — uma relação muito não linear entre covariável e métrica, forçada num ajuste linear, pode não capturar todo o ganho de precisão disponível (embora raramente introduza viés, dado que $\bar{D}$ é aleatório).

Hipóteses

Para o teste de balanceamento por covariável, o teste de hipótese usual (um teste t ou de proporções sobre a covariável, análogo ao teste de efeito) é:

$$H_0 : \mu_{Z,C} = \mu_{Z,T} \quad H_1 : \mu_{Z,C} \neq \mu_{Z,T}$$

onde $\mu_{Z,C}$ e $\mu_{Z,T}$ são as médias populacionais da covariável Z em cada grupo. Na prática, muitas equipes preferem reportar o SMD diretamente em vez de um valor-p — quando o

número de covariáveis testadas é grande, um valor-p sozinho tem taxa de falso positivo alta (por acaso, algumas covariáveis vão “dar significativo”), enquanto o SMD dá uma medida de magnitude comparável entre covariáveis.

O ajuste por covariáveis não tem, ele mesmo, uma hipótese própria a testar — ele modifica a estimativa e o erro-padrão do teste de efeito do tratamento, cuja hipótese continua sendo a do documento de fundamentos de teste A/B ($H_0 : \tau = 0$).

Interpretação

Um SMD pequeno em todas as covariáveis observadas é evidência de que a randomização produziu grupos comparáveis nessas dimensões — reforça, mas não prova sozinho, que o teste de efeito subsequente terá leitura causal válida. Um SMD grande numa covariável isolada, entre muitas testadas, pode ser apenas variação amostral esperada (com k covariáveis testadas a 5% de significância, espera-se cerca de $0,05k$ “desbalanceamentos” por acaso). O padrão relevante é: várias covariáveis desbalanceadas simultaneamente, ou uma covariável central para o negócio fortemente desbalanceada, merecem investigação — possivelmente com um teste de Sample Ratio Mismatch complementar.

Sobre o ajuste: a estimativa pontual do efeito, com e sem ajuste, deveria ser muito próxima quando a randomização funcionou (a covariável é, em expectativa, não correlacionada com o tratamento). Uma mudança grande na estimativa pontual ao adicionar a covariável de ajuste é, ela mesma, um sinal de alerta sobre desbalanceamento — não o comportamento esperado de um ajuste de variância bem-comportado.


Limitações

- Balanceamento em covariáveis observadas não implica balanceamento em covariáveis não observadas — é evidência a favor da randomização, nunca prova completa.
- O ganho de precisão do ajuste por covariáveis depende inteiramente de quão preditiva a covariável é da métrica; covariáveis fracamente correlacionadas trazem ganho desprezível, mesmo que estatisticamente válidas de usar.
- Escolher a covariável de ajuste depois de ver que ela “melhora” o resultado (p-hacking indireto) invalida a interpretação do valor-p resultante, mesmo que a estimativa pontual continue não-viesada.
- Em desenhos com poucas unidades (por exemplo, poucas regiões geográficas tratadas), tanto SMD quanto ajuste por regressão podem ser instáveis — métodos de inferência mais robustos a amostras pequenas (inferência por randomização, bootstrap wild-cluster) tornam-se mais relevantes nesse regime.

Exemplo

Um aplicativo de assinatura testa uma nova política de preço, randomizando 8.000 usuários para controle e 8.000 para tratamento. Antes de olhar qualquer resultado, a equipe checa o balanceamento de quatro covariáveis pré-experimento:

Covariável	Controle	Tratamento	SMD
Idade (anos)	34,2	34,3	0,012
Tempo de uso prévio (dias)	210	204	-0,031
Gasto médio anterior (R\$)	42,10	42,80	0,045
Sessões na semana anterior	5,4	5,3	-0,008




Dados ilustrativos, não representam nenhum projeto real.

Figura 4: Love plot mostrando a diferença padronizada de cada covariável, todas dentro da faixa de referência $\pm 0,10$

Todas as quatro covariáveis têm $|SMD| < 0,1$ — balanceamento aceitável, reforçando que a randomização funcionou.

Em seguida, a equipe estima o efeito da nova política sobre a receita do mês do experimento, comparando dois estimadores: a diferença simples de médias e um estimador ajustado usando o gasto médio anterior como covariável (que tem correlação de aproximadamente 0,55 com a receita do mês do experimento).

Estimador	Efeito estimado	IC 95%
Diferença simples de médias	+2,3 p.p.	$\pm 1,05$ p.p.
Ajustado por gasto anterior	+2,3 p.p.	$\pm 0,62$ p.p.



Diferenças-em-diferenças (DiD): desenho por coorte, event-study, placebo e tendências paralelas

Conceito

Diferenças-em-diferenças (DiD) é um desenho de inferência causal para dados observacionais, aplicável quando uma intervenção (lei, política, evento) afeta um grupo específico em um momento conhecido, enquanto outro grupo comparável permanece não afetado. A ideia central é usar o grupo não afetado para estimar o que teria acontecido com o grupo afetado **na ausência** da intervenção — o chamado contrafactual — e atribuir a diferença entre o resultado observado e esse contrafactual ao efeito da intervenção.

A força do desenho vem de comparar **mudanças**, não níveis. Isso elimina automaticamente qualquer diferença fixa entre os grupos que já existisse antes da intervenção (por exemplo, um grupo já ganhar mais que o outro por razões históricas não relacionadas ao evento), e qualquer choque que afete igualmente os dois grupos ao mesmo tempo (uma recessão nacional, por exemplo). O que sobra, sob a suposição central do método, é o efeito específico da intervenção sobre o grupo afetado.

Este documento cobre quatro componentes do mesmo desenho, tratados juntos porque raramente aparecem isolados na prática: o desenho DiD básico (2x2), a extensão para **coortes de exposição**, a extensão para **event-study**, e os testes de **placebo e tendências paralelas** que sustentam (ou não) a validade do desenho.

Formulação matemática

DiD básico (2x2)

Com dois grupos (tratado T , controle C) e dois períodos (pré $t = 0$, pós $t = 1$), a especificação de regressão padrão é:

$$y_{it} = \alpha + \beta \cdot \text{Tratado}_i + \gamma \cdot \text{Pós}_t + \delta \cdot (\text{Tratado}_i \times \text{Pós}_t) + \varepsilon_{it}$$

Onde:

- y_{it} é o resultado de interesse para a unidade i no período t ;
- Tratado_i é um indicador (0/1) de pertencer ao grupo afetado;
- Pós_t é um indicador (0/1) de o período ser posterior à intervenção;
- α é o nível médio do grupo de controle no período pré;
- β captura a diferença fixa entre os grupos já existente antes da intervenção;
- γ captura a mudança comum a ambos os grupos entre os dois períodos (tendência de fundo);
- δ , o coeficiente de interação, é a **estimativa DiD**: a mudança adicional específica do grupo tratado, além da tendência comum — a quantidade de interesse.

Equivalentemente, sem regressão:

$$\hat{\delta} = (\bar{y}_{T,\text{pós}} - \bar{y}_{T,\text{pré}}) - (\bar{y}_{C,\text{pós}} - \bar{y}_{C,\text{pré}})$$

a diferença das duas diferenças de médias, o que dá nome ao método.

Desenho por coorte de exposição

Quando a intervenção afeta pessoas de forma diferente dependendo de quando nasceram, entraram em algum sistema, ou foram expostas, o desenho por coorte substitui o indicador

binário Tratado_i por um conjunto de indicadores de coorte $c \in \{1, \dots, C\}$, cada uma definida por uma janela de nascimento ou entrada em relação à data de corte da intervenção:

$$y_{ic} = \alpha + \sum_{c \neq c_0} \theta_c \cdot \mathbb{1}[\text{coorte}_i = c] + \mathbf{X}'_i \beta + \varepsilon_i$$

Onde c_0 é a coorte de referência (tipicamente a mais próxima da data de corte, do lado não exposto), θ_c é o efeito estimado para a coorte c relativo à coorte de referência, e $\mathbf{X}_i$ são controles observáveis (idade, região, etc.) que não deveriam, em teoria, variar de forma sistemática entre coortes vizinhas à data de corte — se variarem, isso é sinal de um problema de desenho (ver Limitações).

Event-study

O event-study generaliza o DiD básico para múltiplos períodos, estimando um efeito separado para cada período relativo à data do evento, em vez de um único coeficiente agregado:

$$y_{it} = \alpha_i + \lambda_t + \sum_{k \neq -1} \delta_k \cdot \mathbb{1}[t - t_i^* = k] \cdot \text{Tratado}_i + \varepsilon_{it}$$

Onde:

- α_i são efeitos fixos de unidade (controlam por características fixas de cada unidade ao longo do tempo);
- λ_t são efeitos fixos de período (controlam por choques comuns a todas as unidades em cada momento);
- $k = t - t_i^*$ é o tempo relativo ao evento (negativo antes, positivo depois, zero no período do evento);
- o período $k = -1$ (imediatamente antes do evento) é normalmente omitido como referência — todos os δ_k são interpretados em relação a esse período;
- δ_k , para $k < 0$, deveria ser estatisticamente indistinguível de zero se a suposição de tendências paralelas for razoável — esses coeficientes são o próprio teste visual/estatístico de tendências paralelas;
- δ_k , para $k \geq 0$, traça a trajetória do efeito ao longo do tempo desde o evento — revelando se o efeito é imediato, gradual, ou cresce e depois se estabiliza.

Teste de tendências paralelas

Não existe um teste único e definitivo de tendências paralelas — a prática padrão combina:

1. **Inspeção visual** da série de médias por grupo no período pré-evento.
2. **Teste conjunto formal** de que todos os coeficientes δ_k para $k < -1$ no event-study são simultaneamente iguais a zero (um teste F ou de Wald conjunto), contra a hipótese de que pelo menos um difere de zero.
3. Quando aplicável, um teste de **tendência linear diferencial** no pré-período: estimar se a inclinação da tendência do grupo tratado, no período pré-evento, é estatisticamente diferente da inclinação do grupo de controle.

Teste de placebo

Um teste de placebo repete o mesmo desenho (2x2, coorte, ou event-study) usando uma data falsa de “evento”, situada inteiramente dentro do período em que se sabe que não houve mudança real de política, ou aplicando o tratamento a um grupo que se sabe não ter sido

afetado. A estatística de interesse é o coeficiente δ (ou δ_k) estimado sob essa atribuição falsa — sob um desenho válido, ele deveria ser estatisticamente indistinguível de zero.

Suposições

- **Tendências paralelas:** na ausência da intervenção, o grupo tratado teria seguido, em média, a mesma trajetória que o grupo de controle. Esta é a suposição central e a mais forte do método — não observável diretamente para o período pós-evento (é justamente o contrafactual que falta), mas parcialmente avaliável no período pré-evento.
- **Nenhuma antecipação (no anticipation):** as unidades não mudam de comportamento antes da data oficial do evento em razão de já saberem que ele vai acontecer. Quando há antecipação (por exemplo, empresas que mudam contratações antes de uma lei entrar em vigor, sabendo que ela está a caminho), o período “pré-evento” já está contaminado, e o event-study costuma mostrar um pequeno efeito não nulo mesmo em $k = -2$ ou $k = -3$.
- **SUTVA (Stable Unit Treatment Value Assumption):** o tratamento de uma unidade não afeta o resultado de outras unidades (ausência de transbordamento/contaminação entre tratamento e controle). Quando o grupo de controle é afetado indiretamente pela intervenção (por exemplo, um efeito de equilíbrio geral que se espalha para setores não diretamente regulados), o efeito DiD estimado é enviesado.
- **Composição estável dos grupos ao longo do tempo:** em desenhos com dados de corte transversal repetido (não painel de indivíduos), a composição de quem está em cada grupo em cada período deve ser razoavelmente estável — se a composição do grupo tratado muda sistematicamente ao redor do evento (por exemplo, migração seletiva para dentro ou fora do grupo afetado), a comparação de médias deixa de refletir apenas o efeito do tratamento.
- **Ausência de outros choques concorrentes específicos ao grupo tratado:** nenhum outro evento, além da intervenção de interesse, deveria afetar especificamente o grupo tratado (e não o de controle) na mesma janela de tempo.

Hipóteses

Para o coeficiente de interesse δ (efeito DiD agregado) ou cada δ_k (efeito por período no event-study):

- $H_0: \delta = 0$ (ou $\delta_k = 0$) — não há efeito da intervenção.
- $H_1: \delta \neq 0$ (ou $\delta_k \neq 0$) — há efeito.
- Estatística de teste: $t = \hat{\delta} / \widehat{SE}(\hat{\delta})$, onde o erro-padrão deve, na prática, ser robusto a heterocedasticidade e, quando há múltiplas observações por unidade ao longo do tempo, agrupado (cluster) no nível da unidade — ignorar essa estrutura de agrupamento costuma subestimar o erro-padrão verdadeiro e inflar falsamente a significância.
- Intervalo de confiança: $\hat{\delta} \pm z_{1-\alpha/2} \cdot \widehat{SE}(\hat{\delta})$.
- Para o teste conjunto de tendências paralelas: $H_0: \text{ todos os } \delta_k = 0 \text{ para } k < -1$; estatística de teste F ou Wald conjunta.

Interpretação

DiD bem executado dá leitura causal mais forte que antes/depois — mas ainda condicional

Uma comparação simples de antes e depois de um único grupo confunde o efeito da intervenção com qualquer outra coisa que tenha mudado ao longo do tempo. O DiD remove a tendência comum aos dois grupos, isolando melhor o efeito específico do grupo tratado. Isso

é uma melhora real na credibilidade causal — mas o resultado continua sendo condicional à suposição de tendências paralelas ser válida. DiD não é um substituto para um experimento randomizado; é uma aproximação, cuja qualidade depende inteiramente de quão razoável é a suposição central no contexto específico.

“Tendências paralelas sustentadas” é uma leitura de poder insuficiente, não uma prova

Este é o ponto de interpretação mais importante, e o mais frequentemente mal compreendido: quando o teste conjunto de tendências paralelas no pré-período **não rejeita** a hipótese de que todos os δ_k ($k < -1$) são zero, isso é frequentemente lido como “a suposição de tendências paralelas foi confirmada”. Essa leitura é estatisticamente incorreta. Não rejeitar H_0 significa apenas que os dados não fornecem evidência suficiente **contra** a suposição — o que pode acontecer tanto porque a suposição é de fato razoável, quanto porque o teste tem pouco poder estatístico (poucos períodos pré-evento, amostra pequena, métrica ruidosa). Um teste com pouco poder “não rejeita” quase qualquer coisa. A forma correta de reportar isso é: “os dados pré-evento não contradizem a suposição de tendências paralelas” — nunca “a suposição foi confirmada” ou “provada”.

Distinção entre associação e causalidade

O coeficiente δ é, tecnicamente, sempre uma estimativa de associação condicional a um desenho específico. Ele ganha uma leitura causal na medida em que as suposições acima (especialmente tendências paralelas e ausência de antecipação) são plausíveis no contexto. A robustez dessa leitura aumenta quando: (a) os testes de placebo não mostram efeito espúrio; (b) o event-study mostra um padrão de pré-tendências planas seguido de uma mudança visível a partir do período do evento; e (c) o resultado é estável a diferentes especificações do grupo de controle e do período de análise. Nenhum desses pontos, isoladamente ou em conjunto, constitui prova definitiva — constitui evidência cumulativa.

Limitações

- **Sensibilidade à escolha do grupo de controle.** Grupos de controle diferentes (mas todos “razoáveis” à primeira vista) podem gerar estimativas de efeito substancialmente diferentes. É boa prática reportar a robustez do resultado a mais de uma definição de controle.
- **Comparações escalonadas (staggered) com efeitos heterogêneos.** Quando diferentes unidades são tratadas em momentos diferentes (adoção escalonada de uma política, por exemplo) e o efeito do tratamento varia ao longo do tempo ou entre unidades, a especificação de efeitos fixos bidirecionais clássica (unidade + período) pode produzir estimativas enviesadas, inclusive de sinal errado, por usar unidades já tratadas como “controle” implícito de unidades tratadas mais tarde. Estimadores mais recentes desenhados especificamente para esse cenário (Callaway-Sant’Anna, Sun-Abraham, entre outros) evitam esse problema.
- **Testes de placebo não cobrem todas as ameaças à validade.** Um placebo “limpo” (sem efeito espúrio em data falsa) aumenta a confiança no desenho, mas não descarta, por exemplo, um choque concorrente que afetou especificamente o grupo tratado na data real do evento.
- **Poder estatístico limitado é comum e subestimado.** Com poucos grupos (poucas regiões, poucos setores) ou séries curtas, mesmo um efeito real e de magnitude relevante pode não ser detectado — a ausência de significância não deve ser lida automaticamente como “não há efeito”.
- **Erros-padrão inadequados são um erro comum.** Ignorar a estrutura de agrupamento temporal dentro da mesma unidade (não usar erros-padrão robustos

a cluster) é uma das formas mais frequentes de inflar artificialmente a significância estatística em aplicações de DiD.

Exemplo

Considere um estudo hipotético sobre uma política de subsídio a cursos de qualificação profissional, implementada em um conjunto de municípios a partir de um ano específico, enquanto municípios vizinhos e comparáveis não receberam o subsídio.

Desenho 2x2 básico

A taxa de conclusão de cursos técnicos (%) nos dois grupos de municípios, no ano imediatamente anterior e no ano imediatamente posterior à introdução do subsídio:

	Pré-subsídio	Pós-subsídio	Mudança
Municípios com subsídio	40%	61%	+21 p.p.
Municípios sem subsídio	40%	47%	+7 p.p.

Estimativa DiD: $\hat{\delta} = 21 - 7 = 14$ pontos percentuais atribuíveis ao subsídio, além da tendência já compartilhada pelos dois grupos.

Desenho por coorte

Suponha que o subsídio, na prática, só valeu para pessoas que ingressaram no sistema de ensino técnico a partir de uma data de corte. Comparando coortes de ingresso um ano antes e um ano depois da data de corte, controlando por idade e região, o efeito estimado para a coorte imediatamente posterior à data de corte é de +9 pontos percentuais na taxa de conclusão, relativo à coorte imediatamente anterior — um pouco menor que a estimativa 2x2 agregada, o que é esperado, já que o desenho por coorte isola melhor quem foi de fato exposto ao subsídio desde o início do curso.

Event-study

Estendendo a análise para cinco anos antes e cinco anos depois da introdução do subsídio, os coeficientes δ_k relativos ao ano anterior imediato ($k = -1$) mostram: nos anos $k = -5$ a $k = -2$, coeficientes pequenos (entre -1 e +1,5 pontos percentuais) e estatisticamente não distinguíveis de zero — consistente (não idêntico a “prova de”) com tendências paralelas no pré-período. A partir de $k = 0$, os coeficientes sobem progressivamente: +6 p.p. no ano do evento, +11 p.p. um ano depois, +14 p.p. dois anos depois, estabilizando perto desse patamar — um padrão de efeito que cresce e depois se estabiliza, mais informativo do que o único número agregado do desenho 2x2.

Teste de placebo

Repetindo o mesmo desenho 2x2, mas usando como “data falsa” de evento um ano três anos antes da introdução real do subsídio (período em que nenhuma mudança de política ocorreu), a estimativa de “efeito” placebo é de +0,8 pontos percentuais, com valor-p de 0,71 — não significativo, como esperado sob um desenho válido. Esse resultado reforça (sem provar definitivamente) a credibilidade da estimativa principal.


```
import pandas as pd
import statsmodels.formula.api as smf
```

```

## desenho 2x2
modelo_2x2 = smf.ols(
    "taxa_conclusao ~ subsidio * pos", data=dados
).fit(cov_type="cluster", cov_kwds={"groups": dados["municipio"]})
print(modelo_2x2.params["subsidio:pos"])

## event-study: cria indicadores de tempo relativo ao evento,
## omitindo k = -1 como referência
dados["tempo_relativo"] = dados["ano"] - dados["ano_evento"]
dummies = pd.get_dummies(dados["tempo_relativo"], prefix="k").drop(columns=["k_-1"])
dados_es = pd.concat([dados, dummies], axis=1)
termos = " + ".join([f"subsidio:{c}" for c in dummies.columns])
modelo_es = smf.ols(
    f"taxa_conclusao ~ C(municipio) + C(ano) + {termos}", data=dados_es
).fit(cov_type="cluster", cov_kwds={"groups": dados_es["municipio"]})

```



Dados ilustrativos, não representam nenhum projeto real.

Figura 6: Coeficientes do desenho event-study, por período relativo à intervenção

Índice de dissimilaridade de Duncan

Conceito

O índice de dissimilaridade de Duncan (Duncan & Duncan, 1955) quantifica o quanto duas distribuições percentuais — de dois grupos populacionais sobre um mesmo conjunto de categorias — diferem entre si. É a métrica clássica de segregação: ocupacional, residencial, educacional, ou de qualquer outra categorização discreta em que faça sentido perguntar “os dois grupos ocupam as mesmas categorias, nas mesmas proporções?”.

A intuição central é geométrica: se você desenhar as duas distribuições como barras sobrepostas, o índice mede a área de não sobreposição, dividida por dois. Equivalentemente, é a fração mínima de um dos grupos que precisaria ser realocada entre categorias para que as duas distribuições coincidissem exatamente.

O índice pertence a uma família mais ampla de medidas de segregação (junto com o índice de isolamento, o índice de exposição e variantes mais recentes como o índice de segregação multigrupo), mas segue sendo o mais usado por sua simplicidade de cálculo e interpretação direta.

Formulação matemática

Sejam duas populações, A e B, distribuídas sobre um conjunto de K categorias mutuamente exclusivas. Para cada categoria $i = 1, \dots, K$, defina:

- a_i = proporção da população A que está na categoria i (soma sobre todas as categorias = 1)
- b_i = proporção da população B que está na categoria i (soma sobre todas as categorias = 1)

O índice de dissimilaridade é:

$$D = \frac{1}{2} \sum_{i=1}^K |a_i - b_i|$$

Onde:

- $|a_i - b_i|$ é a diferença absoluta de proporção na categoria i ;
- o somatório acumula essa diferença em todas as K categorias;
- o fator $\frac{1}{2}$ normaliza o índice para o intervalo $[0, 1]$ — sem ele, a soma das diferenças absolutas variaria entre 0 e 2, porque cada ponto de “excesso” de A em uma categoria corresponde a um ponto de “déficit” de A (excesso de B) em outra, contado duas vezes ao longo do somatório.

$D = 0$ ocorre quando $a_i = b_i$ para toda categoria i — as duas distribuições são idênticas. $D = 1$ ocorre quando, para toda categoria em que $a_i > 0$, tem-se $b_i = 0$ e vice-versa — as duas populações nunca ocupam a mesma categoria.

Uma leitura equivalente e útil na prática: D é também o valor máximo, sobre qualquer subconjunto de categorias S , da diferença entre a fração de A e a fração de B contida em S :

$$D = \max_{S \subseteq \{1, \dots, K\}} \left| \sum_{i \in S} a_i - \sum_{i \in S} b_i \right|$$

Essa formulação alternativa esclarece a interpretação de “fração mínima a realocar”: D é exatamente a fração de um dos grupos que está “em excesso” no pior subconjunto de categorias possível.

Suposições

O índice de Duncan não é um teste de hipótese — é uma estatística descritiva — mas seu uso correto depende de algumas condições:

- **Categorias mutuamente exclusivas e coletivamente exaustivas:** cada observação pertence a exatamente uma categoria. Categorias sobrepostas quebram a lógica do índice.
- **Classificação estável entre os grupos comparados:** comparar índices calculados com esquemas de categorização diferentes (por exemplo, uma classificação ocupacional com 6 categorias versus outra com 20) não é válido — o valor de D tende a aumentar com o número de categorias, simplesmente porque há mais oportunidades de diferença.
- **Amostra suficiente em cada categoria dentro de cada grupo:** com poucas observações, as proporções a_i e b_i são estimadas com ruído considerável, e o índice herda essa instabilidade. Um intervalo de confiança por bootstrap (reamostrando indivíduos dentro de cada grupo, recomputando D em cada reamostra) é a forma mais direta de quantificar essa incerteza, já que a distribuição exata de D sob amostragem não tem forma fechada simples.
- **Independência dentro do desenho amostral:** se os dados vierem de um desenho complexo (estratificado, por conglomerados, com pesos amostrais), as proporções a_i e b_i devem ser calculadas usando os pesos corretos — ignorar o desenho amostral produz proporções (e, portanto, um D) enviesados.

Hipóteses

O índice em si não vem acompanhado de um teste de hipótese formal — é possível, no entanto, testar informalmente se D é “maior do que o esperado por acaso” comparando-o à distribuição de D obtida ao embaralhar aleatoriamente a atribuição de categoria entre indivíduos dos dois grupos (um teste de permutação). Nesse caso:

- H_0 : a categoria ocupada por um indivíduo não depende do grupo a que ele pertence (as duas populações seriam, sob H_0 , amostras da mesma distribuição categórica).
- H_1 : existe associação entre grupo e categoria.
- Estatística de teste: o próprio D observado.
- Valor-p: fração das permutações em que o D simulado é maior ou igual ao D observado.

Na prática, com amostras grandes (como pesquisas domiciliares nacionais), o teste de permutação quase sempre rejeita H_0 mesmo para valores de D pequenos — o que reforça que a pergunta relevante não é “existe segregação estatisticamente detectável?”, mas “o quanto de segregação existe, e isso é grande o bastante para importar na prática?”.

Interpretação

D responde a uma pergunta puramente descritiva: **quão desigual é a distribuição de dois grupos entre categorias**. Ele não diz:

- **Por que** essa distribuição existe. Um D alto é compatível com barreiras de acesso, diferenças reais e não observadas de qualificação entre os grupos, preferências voluntárias distintas, discriminação histórica acumulada, ou qualquer combinação dessas causas — o índice não separa uma explicação da outra.

- **Se a segregação está aumentando ou diminuindo em um sentido causal.** Uma queda de D ao longo do tempo é consistente com integração real, mas também pode refletir mudanças na própria classificação de categorias ou na composição da força de trabalho.
- **Qual grupo está em vantagem.** D não tem sinal — ele mede distância, não direção. Para saber qual grupo está concentrado nas categorias mais bem remuneradas ou mais prestigiadas, é preciso olhar a tabela de proporções por categoria diretamente, não só o índice agregado.

Uma prática recomendada é sempre reportar D junto com a tabela de proporções por categoria (ou, no mínimo, destacar as categorias que mais contribuem para a diferença) — o índice sozinho comprime informação demais para sustentar uma narrativa completa.

Limitações

- **Sensibilidade à granularidade das categorias.** Como mencionado, D tende a crescer artificialmente com o número de categorias. Comparações entre estudos ou países só são válidas se a classificação categórica for equivalente.
- **Não incorpora ordenação ou distância entre categorias.** Duas categorias “próximas” (por exemplo, dois níveis salariais adjacentes) contam da mesma forma que duas categorias “distantes” (o nível mais baixo e o mais alto). Quando a ordenação importa, medidas alternativas (como índices de segregação vertical, ou a própria decomposição de Theil aplicada por categoria) podem ser mais informativas.
- **Não é decomponível de forma simples entre subgrupos ou ao longo do tempo** como o índice de Theil é para desigualdade — comparar D entre subpopulações ou anos exige recalculá-lo em cada corte, e não há uma forma direta de atribuir a mudança total a fatores específicos.
- **Estimação com pesos amostrais complexos exige cuidado.** Erros-padrão de D sob desenhos amostrais complexos não têm fórmula fechada simples; bootstrap ou réplicas de peso replicado (jackknife repetido, replicação balanceada) são as abordagens padrão.

Exemplo

Considere um estudo hipotético comparando a distribuição de profissionais de tecnologia em uma empresa de médio porte, divididos por gênero, entre seis níveis de senioridade: Estagiário, Júnior, Pleno, Sênior, Staff e Liderança técnica.

Suponha as seguintes proporções observadas:

Nível	% Grupo A	% Grupo B
Estagiário	8%	14%
Júnior	22%	30%
Pleno	30%	28%
Sênior	24%	18%
Staff	11%	7%
Liderança técnica	5%	3%

Calculando as diferenças absolutas por nível: 6, 8, 2, 6, 4, 2. A soma é 28. Dividindo por dois, $D = 14$, ou 0,14 em escala de 0 a 1.

Interpretação: cerca de 14% de um dos grupos precisaria mudar de nível de senioridade para que as duas distribuições coincidissem. Olhando a tabela, fica claro que a maior parte dessa diferença vem da ponta inicial (Estagiário e Júnior, onde o Grupo B está sobre-representado)

e da ponta superior (Sênior em diante, onde o Grupo A está sobrerrepresentado) — um padrão consistente com uma hipótese de “afunilamento” na progressão de carreira, mas que o índice sozinho não confirma nem explica. Para investigar se esse padrão é causal (por exemplo, ligado a uma barreira específica de promoção), seria necessário um desenho complementar — como uma análise de sobrevivência do tempo até a promoção, controlando por tempo de casa e avaliação de desempenho — que está fora do escopo do índice de dissimilaridade.


Um teste de permutação simples, embaralhando aleatoriamente 500 vezes a atribuição de nível de senioridade entre os funcionários dos dois grupos (mantendo os tamanhos de grupo fixos), nesse exemplo hipotético produziria um valor-p muito baixo — confirmando que essa distribuição observada seria rara sob a hipótese de que gênero e nível são independentes, mas, como sempre, isso não substitui uma investigação das causas.

```
import numpy as np
import pandas as pd

niveis = ["estagiario", "junior", "pleno", "senior", "staff", "lideranca"]
prop_a = np.array([0.08, 0.22, 0.30, 0.24, 0.11, 0.05])
prop_b = np.array([0.14, 0.30, 0.28, 0.18, 0.07, 0.03])

D = 0.5 * np.sum(np.abs(prop_a - prop_b))
print(f"Índice de Duncan: {D:.3f}")

## teste de permutação (esboço): embaralha atribuição de nível
## entre indivíduos simulados dos dois grupos, recomputa D, compara
## com o D observado para obter um valor-p empírico.
```



Dados ilustrativos, não representam nenhum projeto real.

Figura 7: Evolução do índice de dissimilaridade ao longo do tempo

Decomposição de crescimento: total, comparável e preço-volume-mix

Conceito

Decomposição de crescimento é uma técnica contábil-analítica (não um modelo estatístico com incerteza inferencial) que reescreve a variação de uma métrica agregada — tipicamente receita — como a soma de componentes mutuamente exclusivos e exaustivos, cada um respondendo a uma pergunta causal parcial e bem definida: “quanto do crescimento veio de X, mantendo tudo o mais constante?”

A decomposição acontece em dois níveis encadeados:

Nível 1 — Total vs. comparável. Separa unidades de análise (lojas, regiões, linhas de produto, contas de cliente) em duas populações: as que existiam em ambos os períodos comparados (“comparáveis”, *like-for-like*) e as que só existem no período mais recente (novas aberturas, entrada em novo mercado, novos SKUs). O crescimento total é sempre a soma do crescimento das unidades comparáveis com a receita trazida pelas unidades novas.

Nível 2 — Preço, volume e mix, dentro do comparável. Dentro da população comparável, a variação de receita é reescrita como o produto de preço médio por quantidade vendida, agregado por item ou categoria. Variação nesse produto pode vir de três fontes: o preço unitário de cada item mudou (**efeito preço**); a quantidade total vendida mudou, mantida a composição de itens (**efeito volume**); ou a composição de itens vendidos mudou — por exemplo, mais participação de itens de ticket mais alto (**efeito mix**).

A lógica subjacente é a mesma de qualquer decomposição contábil (structural decomposition analysis, análise shift-share): fixar todos os fatores menos um, medir o efeito marginal desse fator, repetir para os demais, e garantir que a soma feche exatamente com o total observado — sem resíduo não explicado, exceto quando a convenção de cálculo escolhida deliberadamente atribui interações ao componente de mix.

Formulação matemática

Seja $R_t = \sum_i p_{i,t} q_{i,t}$ a receita no período t , somada sobre itens ou categorias i , onde $p_{i,t}$ é o preço médio do item i no período t e $q_{i,t}$ é a quantidade vendida.

Separação total vs. comparável. Seja C o conjunto de unidades comparáveis (presentes em ambos os períodos $t-1$ e t) e N o conjunto de unidades novas (presentes só em t). Então:

$$\underbrace{R_t - R_{t-1}}_{\text{crescimento total}} = \underbrace{\left(\sum_{i \in C} p_{i,t} q_{i,t} - \sum_{i \in C} p_{i,t-1} q_{i,t-1} \right)}_{\text{crescimento comparável } \Delta R_C} + \underbrace{\sum_{i \in N} p_{i,t} q_{i,t}}_{\text{receita de unidades novas}}$$

Não há termo de “unidades que saíram” com sinal separado nesta formulação porque, por convenção, elas entram implicitamente em ΔR_C quando $q_{i,t} = 0$ para itens descontinuados dentro do próprio conjunto comparável; em aplicações reais costuma-se tratar descontinuações como uma quarta categoria explícita quando relevante.

Decomposição preço-volume-mix, dentro de ΔR_C . Usando o método de substituição sequencial (uma das convenções mais comuns, equivalente a um índice de Laspeyres modificado):

$$\text{Efeito Volume} = \left(\sum_{i \in C} q_{i,t} \right) - \left(\sum_{i \in C} q_{i,t-1} \right) \times \bar{p}_{t-1}$$

$$\text{Efeito Preço} = (\bar{p}_t - \bar{p}_{t-1}) \times \left(\sum_{i \in C} q_{i,t} \right)$$

$$\text{Efeito Mix} = \Delta R_C - \text{Efeito Volume} - \text{Efeito Preço}$$

onde $\bar{p}_t = R_{C,t} / \sum_{i \in C} q_{i,t}$ é o preço médio ponderado do período t na população comparável. O efeito volume isola o que teria acontecido com a receita se só a quantidade total tivesse mudado, ao preço médio do período anterior. O efeito preço isola o que teria acontecido se só o preço médio tivesse mudado, aplicado à quantidade do período atual. O efeito mix é definido como resíduo: a parte da variação de receita que não é explicada nem por preço médio nem por volume total — ou seja, mudança na composição de itens vendidos, incluindo itens de ticket mais alto ganhando participação.

Essa não é a única convenção possível: métodos alternativos (por exemplo, decomposição simétrica, ou calcular cada efeito no ponto médio entre os dois períodos) distribuem a interação preço×volume de forma diferente entre os três componentes. A soma total, porém, é invariante à convenção escolhida.

Suposições

- **Granularidade consistente.** A decomposição de preço-volume-mix exige dados no nível de item/SKU/categoria — calculá-la sobre receita agregada sem quantidade correspondente não é possível; sem preço unitário e quantidade separados, só é possível calcular o total vs. comparável.
- **Definição estável de “comparável”.** A classificação de uma unidade como comparável depende de uma regra de corte temporal (ex.: loja aberta há 12+ meses completos) aplicada de forma consistente entre períodos — mudar a regra no meio de uma série histórica quebra a comparabilidade entre trimestres.
- **Ausência de mudanças estruturais na unidade de medida.** Se a unidade de quantidade muda (ex.: passa a vender em pacotes maiores), o efeito volume calculado mistura volume real com mudança de embalagem — é preciso normalizar a unidade antes de decompor.
- **Composição estável dentro de cada item.** O efeito mix pressupõe que “item i ” significa a mesma coisa nos dois períodos; se um SKU for redefinido (nova receita, novo tamanho) no meio do caminho, a decomposição vai atribuir a mudança de característica do produto ao componente errado.

Hipóteses

Este método é contábil, não inferencial — não há hipótese nula, estatística de teste ou intervalo de confiança embutido na decomposição em si. Os componentes (preço, volume, mix, novas unidades) são identidades algébricas calculadas a partir de dados observados, não estimativas com erro amostral.

Dito isso, é comum — e recomendado — complementar a decomposição com inferência quando aplicável: por exemplo, testar se o efeito volume é significativamente diferente de zero ao longo de várias unidades (lojas, regiões) usando um teste t ou um modelo de efeitos aleatórios sobre a distribuição de efeitos-volume por unidade, especialmente quando o objetivo é generalizar a conclusão além do conjunto observado de lojas.

Interpretação

A decomposição permite afirmar, com precisão, de onde veio cada real de crescimento — não por que isso aconteceu. Um efeito volume negativo diz que menos unidades foram vendidas às mesmas lojas comparáveis; não diz se isso foi causado por perda de clientes, por um concorrente novo, por ruptura de estoque, ou por uma decisão deliberada de reduzir promoções. A decomposição é diagnóstica, não causal — ela direciona a investigação (por que o volume caiu?), mas não a substitui.

É importante também não confundir crescimento percentual alto com crescimento absoluto relevante: um efeito mix de +2 pontos percentuais em uma base pequena pode representar menos reais que um efeito volume de +0,5 ponto percentual em uma base grande. Sempre reportar os valores absolutos junto dos percentuais.

Limitações

- **Sensibilidade à convenção de cálculo.** Como mostrado na formulação matemática, o valor exato de cada componente (especialmente mix) depende da convenção escolhida para lidar com a interação preço×volume. Comparações entre relatórios que usam convenções diferentes não são diretamente comparáveis componente a componente, mesmo que o total bata.
- **Mix como resíduo “capturador de erro”.** Por ser calculado como resíduo, o efeito mix absorve qualquer erro de mensuração em preço ou quantidade (ex.: descontos não capturados corretamente, devoluções mal classificadas). Um efeito mix anormalmente grande é, com frequência, sinal de problema de qualidade de dados, não de mudança real de composição de vendas.
- **Não captura causalidade nem contrafactual verdadeiro.** “O que teria acontecido se só o preço tivesse mudado” é uma pergunta contábil — assume que a quantidade vendida seria a mesma independentemente da mudança de preço, o que ignora elasticidade-preço da demanda. Numa leitura mais rigorosa, os componentes preço e volume são interdependentes na prática, mesmo sendo calculados como se fossem independentes.
- **Definição de “comparável” é uma escolha, não um fato dado.** Diferentes janelas de comparabilidade produzem números de crescimento comparável diferentes para o mesmo conjunto de dados brutos.

Exemplo

Considere uma rede fictícia de cafeterias com três lojas existentes há mais de um ano (A, B, C) e uma loja nova aberta no período (D), vendendo dois produtos: café (ticket baixo, alto volume) e combo café+bolo (ticket alto, volume menor).


Loja	Comparável	Receita ano anterior	Receita ano atual	Unid. ano anterior	Unid. ano atual
A	Sim	R\$12,0 mi	R\$12,8 mi	2.400	2.280
B	Sim	R\$15,0 mi	R\$14,1 mi	3.000	2.820
C	Sim	R\$18,0 mi	R\$19,7 mi	3.600	3.760
D	Não	—	R\$3,6 mi	—	720

Passo 1 — total vs. comparável. Receita total: R\$45,0 mi → R\$50,2 mi, crescimento de R\$5,2 mi. Receita das lojas novas (D): R\$3,6 mi. Crescimento comparável: R\$5,2 mi – R\$3,6 mi = **R\$1,6 mi**.

Passo 2 — preço médio comparável. Quantidade comparável total: 9.000 unidades (ano anterior) → 8.860 unidades (ano atual). Preço médio: R\$45,0 mi / 9.000 = R\$5.000/unidade (ano anterior) → R\$46,6 mi / 8.860 ≈ R\$5.259/unidade (ano atual).


Passo 3 — efeitos. - Efeito volume: $(8.860 - 9.000) \times R\$5.000 = -R\$0,70$ mi - Efeito preço: $(R\$5.259 - R\$5.000) \times 8.860 \approx +R\$2,29$ mi - Efeito mix: $R\$1,6$ mi - $(-R\$0,70$ mi) - $R\$2,29$ mi ≈ $-R\$0,01$ mi (arredondamento; próximo de zero neste exemplo simplificado)

Leitura: o crescimento comparável de R\$1,6 mi só é positivo por causa de um forte efeito preço (+R\$2,29 mi), que mais que compensa uma queda real de volume (−R\$0,70 mi) nas lojas comparáveis. O efeito mix próximo de zero indica que a composição entre café e combo não mudou de forma relevante. Esse padrão — preço compensando volume — é exatamente o tipo de sinal que a métrica agregada de “+11,6% de crescimento total” esconderia sozinha, e que justifica uma investigação sobre elasticidade de preço e possível perda de tráfego nas lojas existentes.



Dados ilustrativos, não representam nenhum projeto real.

Figura 8: Decomposição em cascata do crescimento de receita



Dados ilustrativos, não representam nenhum projeto real.

Figura 9: Decomposição preço-volume-mix ao longo de seis trimestres

Teste de heterogeneidade de efeito e decaimento de novidade

Conceito

Um resultado experimental resumido numa única estimativa de efeito médio responde apenas “o efeito, em média, é diferente de zero?”. Duas perguntas adicionais, frequentemente relevantes na prática, ficam de fora dessa pergunta única:

- **Heterogeneidade de efeito (interação):** o efeito do tratamento é constante entre subgrupos da população, ou varia sistematicamente conforme alguma característica observável (camada de fidelidade, canal de aquisição, tipo de dispositivo, região)? Essa é uma pergunta sobre variação **entre unidades**, medida num mesmo corte temporal.
- **Decaimento de efeito de novidade:** o efeito de uma mudança se mantém estável ao longo do tempo desde o lançamento, ou parte dele reflete reação transitória de curiosidade (“efeito novidade” ou “efeito Hawthorne” em sentido amplo) que se dissipa conforme a mudança deixa de ser nova? Essa é uma pergunta sobre variação **ao longo do tempo**, medida dentro do mesmo grupo.

As duas perguntas são conceitualmente distintas e devem ser testadas separadamente, ainda que apareçam juntas na prática: um efeito pode ser homogêneo entre subgrupos e ainda assim decair; pode ser heterogêneo e estável; pode ser as duas coisas ao mesmo tempo, ou nenhuma.

Formulação matemática

Teste de interação (heterogeneidade)

Seja Y_i a métrica de interesse da unidade i , $T_i \in \{0, 1\}$ o indicador de tratamento, e S_i um indicador de subgrupo (por simplicidade, binário: $S_i = 1$ para o subgrupo de interesse, $S_i = 0$ para o subgrupo de referência). O modelo de interação é:

$$Y_i = \beta_0 + \beta_1 T_i + \beta_2 S_i + \beta_3 (T_i \times S_i) + \varepsilon_i$$

onde:

- β_1 é o efeito do tratamento no subgrupo de referência ($S_i = 0$);
- β_2 captura a diferença de nível basal entre subgrupos, independente do tratamento;
- β_3 é o **coeficiente de interação** — a diferença no efeito do tratamento entre o subgrupo de interesse e o subgrupo de referência. É o parâmetro central do teste de heterogeneidade;
- ε_i é o erro aleatório, com os cuidados usuais de heterocedasticidade e, quando relevante, correlação intra-cluster (ver o documento sobre erros-padrão robustos a cluster).

O teste de heterogeneidade é o teste de hipótese usual sobre β_3 : $H_0 : \beta_3 = 0$ contra $H_1 : \beta_3 \neq 0$, usando a estatística $t = \hat{\beta}_3 / \widehat{SE}(\hat{\beta}_3)$.

Com mais de dois subgrupos, generaliza-se para uma variável categórica S_i com K categorias, gerando $K - 1$ termos de interação (um por categoria, contra a categoria de referência), e o teste conjunto de heterogeneidade é um teste F sobre todos os $K - 1$ coeficientes de interação simultaneamente:

$$H_0 : \beta_3^{(1)} = \beta_3^{(2)} = \dots = \beta_3^{(K-1)} = 0$$

Decaimento de efeito de novidade

Seja $w = 1, \dots, W$ a janela de tempo (por exemplo, semana) desde o lançamento. Para cada janela, estima-se separadamente o efeito do tratamento $\hat{\tau}_w$ com seu erro-padrão, usando apenas as observações daquela janela:

$$Y_{i,w} = \alpha_w + \tau_w T_i + \varepsilon_{i,w}, \quad w = 1, \dots, W$$

O objeto de interesse passa a ser a sequência $\{\hat{\tau}_1, \hat{\tau}_2, \dots, \hat{\tau}_W\}$. Uma forma direta de testar decaimento é regredir essa sequência de estimativas sobre w :

$$\hat{\tau}_w = \gamma_0 + \gamma_1 w + u_w$$

com $\gamma_1 < 0$ e estatisticamente significativo como evidência de decaimento. Uma alternativa mais robusta, quando o número de janelas permite, é estimar diretamente um modelo único com interação tratamento $\times$ tempo contínuo, análogo ao termo de interação da seção anterior, tratando o tempo desde o lançamento como a variável de subgrupo.

Suposições

- **Definição do subgrupo antes de ver os dados de efeito.** O teste de interação pressupõe que os subgrupos comparados foram definidos por um critério razoável e, idealmente, especificado antes de rodar o experimento — não escolhidos depois de vasculhar quais cortes “parecem” ter efeito maior.
- **Erros bem especificados.** Como em qualquer regressão, inferência válida sobre β_3 depende de erros-padrão adequados à estrutura de dependência dos dados (por exemplo, robustos a heterocedasticidade, ou a cluster quando as observações não são independentes dentro de um grupo).
- **Estabilidade da composição ao longo do tempo (decaimento).** Comparar $\hat{\tau}_w$ entre janelas pressupõe que a composição da população em cada janela é comparável — se usuários muito diferentes entram no experimento em semanas diferentes (por exemplo, por causa de uma campanha de aquisição), parte da variação observada em $\hat{\tau}_w$ pode

refletir mudança de composição, não decaimento genuíno do efeito sobre o mesmo tipo de usuário.

- **Amostra suficiente por subgrupo e por janela.** Cortar os dados em subgrupos ou janelas de tempo reduz o tamanho de amostra em cada célula, inflando os erros-padrão — um teste de heterogeneidade sem poder estatístico suficiente simplesmente não detecta diferenças reais.

Hipóteses

Teste de interação:

- $H_0: \beta_3 = 0$ — o efeito do tratamento é igual entre os subgrupos comparados.
- $H_1: \beta_3 \neq 0$ — o efeito difere entre os subgrupos.
- Estatística de teste: $t = \hat{\beta}_3 / \widehat{SE}(\hat{\beta}_3)$, comparada à distribuição t (ou normal, em amostras grandes) sob H_0 .
- Nível de significância convencional: 5%, mas ver a seção de limitações sobre comparações múltiplas quando vários subgrupos são testados.

Teste de decaimento:

- $H_0: \gamma_1 = 0$ — não há tendência de queda no efeito ao longo das janelas de tempo.
- $H_1: \gamma_1 < 0$ (teste unilateral, se a pergunta é especificamente sobre decaimento) ou $\gamma_1 \neq 0$ (teste bilateral, se qualquer mudança de padrão interessa).
- Intervalo de confiança de 95% para $\hat{\tau}_w$ em cada janela permite visualizar diretamente se a trajetória das estimativas é compatível com efeito constante (todas as faixas se sobrepõem) ou com queda sistemática.

Interpretação

Um coeficiente de interação significativo diz que o efeito **difere** entre os subgrupos testados — não diz automaticamente qual subgrupo é “melhor” em termos absolutos, nem por que a diferença existe. Um efeito maior em um subgrupo pode refletir maior sensibilidade real à mudança, ou simplesmente uma linha de base mais baixa com mais espaço para melhorar.

Decaimento de novidade detectado não significa que o produto “não funciona” — significa que a magnitude do efeito de longo prazo é menor do que a medição inicial sugeria. A decisão de lançamento deve, idealmente, se basear no efeito estabilizado (últimas janelas), não no efeito de pico (primeiras janelas), quando o objetivo é entender o ganho sustentável.

Nenhuma das duas análises, por si só, estabelece causalidade adicional além da já garantida pela randomização do experimento original — elas apenas decompõem um efeito causal médio já identificado em como ele se distribui entre grupos e ao longo do tempo.

Limitações

- **Comparações múltiplas.** Testar heterogeneidade em vários subgrupos simultaneamente (por camada, canal, dispositivo, região, e assim por diante) infla a taxa de falsos positivos. Testando 10 subgrupos independentes a 5% de significância, a probabilidade de pelo menos um resultado “significativo” por puro acaso, mesmo sem heterogeneidade real, ultrapassa 40%. Correções como Bonferroni, ou a exigência de replicação em um experimento subsequente, mitigam esse risco. Um subgrupo definido *a priori*, com justificativa teórica clara, é sempre mais confiável que um subgrupo descoberto explorando os dados depois do fato.
- **Poder estatístico reduzido em subgrupos pequenos.** Cortar a amostra aumenta o erro-padrão de cada estimativa de subgrupo — a ausência de significância num subgrupo pequeno pode simplesmente refletir amostra insuficiente, não ausência de efeito.

- **Confusão entre composição e decaimento genuíno.** Mudanças na composição da população ao longo das semanas (sazonalidade, campanhas de aquisição, efeitos de calendário) podem produzir uma trajetória que parece decaimento sem que o efeito, para um mesmo usuário, tenha realmente caído.
- **Janelas de tempo curtas demais para concluir estabilização.** Observar decaimento nas primeiras semanas não garante que o efeito vá a zero — pode estabilizar num patamar positivo menor. Extrapolar a tendência para além do período observado é especulativo.

Exemplo

Suponha um aplicativo de corretora que testa uma nova tela de resumo de carteira, com o objetivo de aumentar o número de logins semanais. O efeito médio estimado, agregando toda a base, é de +6,0% em relação ao controle, com erro-padrão de 1,2 (estatisticamente significativo).

Heterogeneidade por perfil de investidor. Separando por tempo de conta:

Subgrupo	Efeito estimado	Erro-padrão
Contas com menos de 6 meses	+11,4%	2,0
Contas com 6 meses ou mais	+2,1%	1,4


A diferença entre os dois efeitos é de 9,3 pontos percentuais. O erro-padrão da diferença, combinando os dois erros-padrão sob independência, $\sqrt{2,0^2 + 1,4^2} \approx 2,44$, resulta em uma estatística $t \approx 3,8$ — bem acima do limiar de significância usual. Há evidência sólida de heterogeneidade: contas novas respondem muito mais à mudança do que contas estabelecidas, um padrão plausível, já que usuários novos ainda estão formando hábitos de uso.

Decaimento de novidade. Olhando o efeito agregado semana a semana desde o lançamento:

Semana	Efeito estimado
1	+12,8%
2	+9,4%
4	+6,7%
8	+3,9%
12	+3,5%

A trajetória cai de forma consistente até a semana 8 e depois se estabiliza perto de 3,5%. A leitura correta não é “a mudança não funciona” — é que o efeito de pico inicial (quase 13%) incluía uma parcela de curiosidade temporária, e o ganho sustentável real, relevante para projeções de longo prazo, está mais próximo de 3,5%.

Combinando as duas análises: a decisão de produto mais informada não é “lançar para todos com o efeito médio de +6%”, mas algo como “lançar priorizando contas novas, e projetar o ganho de longo prazo usando o patamar estabilizado de aproximadamente +3,5% a +4%, não o pico inicial”.



Dados ilustrativos, não representam nenhum projeto real.

Figura 10: Efeito ao longo das semanas desde o lançamento, ilustrando o decaimento do efeito de novidade

Decomposição de desigualdade (Theil, Gini, quantis ponderados)

Conceito

Medir desigualdade de renda com um único número (como a média ou a mediana) esconde toda a forma da distribuição. Esta seção cobre três ferramentas complementares para caracterizar desigualdade de forma mais completa: o índice de Theil (com sua propriedade de decomponibilidade exata entre componentes “entre grupos” e “dentro dos grupos”), o índice de Gini (uma medida de concentração amplamente usada, baseada na curva de Lorenz), e quantis ponderados (estimativas de pontos de corte da distribuição — como “o que caracteriza os 10% mais ricos” — que levam em conta o desenho amostral de uma pesquisa).

A pergunta que essas ferramentas respondem, em conjunto, é: de onde vem a desigualdade observada, e como ela se compara entre diferentes recortes da população?

Formulação matemática

Índice de Theil (índice T, baseado em entropia). Para uma variável de renda $y_i > 0$ com média $\bar{y}$, calculada sobre n observações:

$$T = \frac{1}{n} \sum_{i=1}^n \frac{y_i}{\bar{y}} \ln \left(\frac{y_i}{\bar{y}} \right)$$

$T = 0$ corresponde a igualdade perfeita (todo mundo com a mesma renda); valores maiores indicam maior desigualdade. Ao contrário do Gini, o Theil não tem um limite superior fixo de 1.

Decomposição exata entre e dentro de grupos. Dividindo a população em G grupos, cada um com participação s_g na renda total e Theil interno T_g :

$$T = \underbrace{\sum_{g=1}^G s_g \ln \left(\frac{\bar{y}}{\bar{y}_g} \right)}_{T_{\text{entre}}} + \underbrace{\sum_{g=1}^G s_g T_g}_{T_{\text{dentro}}}$$

onde $\bar{y}_g$ é a renda média do grupo g . T_{entre} é o valor que o Theil teria se cada pessoa recebesse a renda média do seu grupo (só capturando a diferença entre médias); T_{dentro} é a média ponderada dos índices de Theil calculados dentro de cada grupo, com peso igual à participação de renda de cada grupo. A soma dos dois é exatamente igual ao Theil total — não há termo residual, o que é a propriedade central que torna o Theil especialmente útil para esse tipo de decomposição (o índice de Gini, por comparação, tem uma decomposição aditiva só sob condições especiais, geralmente com um termo residual extra de sobreposição entre grupos).

Índice de Gini. Para uma amostra ordenada $y_{(1)} \leq y_{(2)} \leq \dots \leq y_{(n)}$:

$$G = \frac{2 \sum_{i=1}^n i \cdot y_{(i)} - (n+1) \sum_{i=1}^n y_{(i)}}{n \sum_{i=1}^n y_{(i)}}$$

Geometricamente, G é duas vezes a área entre a curva de Lorenz (que mostra a parcela acumulada de renda detida pelos $p\%$ mais pobres) e a reta de igualdade perfeita (a diagonal de 45°). $G = 0$ é igualdade perfeita; $G \rightarrow 1$ é concentração extrema.

Quantis ponderados. Dado um conjunto de pesos amostrais w_i (que refletem quantas unidades da população cada observação da amostra representa, por causa do desenho amostral), o quantil de ordem q é o valor Q_q tal que a soma dos pesos das observações com $y_i \leq Q_q$, dividida pela soma total dos pesos, seja igual a q . Ignorar os pesos e calcular um quantil amostral simples produz uma estimativa enviesada sempre que a probabilidade de seleção não for constante entre as observações.

Suposições

1. **Valores estritamente positivos** (Theil): a fórmula do índice T exige $y_i > 0$ para todas as observações — rendas zero ou negativas exigem tratamento especial (por exemplo, exclusão com nota metodológica explícita, ou uso de uma variante do índice de Theil menos sensível a isso, como o índice L / desvio logarítmico médio).
2. **Grupos mutuamente exclusivos e exaustivos**: a decomposição do Theil entre/dentro pressupõe que cada observação pertence a exatamente um grupo — categorizações sobrepostas quebram a decomposição exata.
3. **Representatividade dos pesos amostrais**: quantis ponderados e índices calculados a partir de pesquisas amostrais dependem da qualidade dos pesos de desenho (e, quando aplicável, de pós-estratificação) — pesos mal calibrados produzem estimativas enviesadas independentemente da fórmula usada.
4. **Estabilidade em subgrupos pequenos**: ao decompor por muitos grupos simultaneamente (por exemplo, cruzando região e raça), alguns subgrupos podem ter poucas observações, tornando o T_g daquele subgrupo instável — vale reportar o tamanho de amostra de cada subgrupo.

Hipóteses

Índices de desigualdade como Theil e Gini não têm, tradicionalmente, um teste de hipótese único e universalmente aceito da mesma forma que uma diferença de médias — mas

comparações entre índices (por exemplo, o Gini do Grupo A é maior que o do Grupo B?) podem e devem ser acompanhadas de incerteza:

- Erros-padrão para Gini e Theil são tipicamente obtidos por bootstrap (reamostrando a amostra, com reposição, respeitando o desenho amostral quando aplicável, e recalculando o índice em cada reamostragem).
- H_0 : os dois índices (por exemplo, Gini do Grupo A e Gini do Grupo B) são iguais — testada comparando a diferença observada com a distribuição bootstrap da diferença.
- Para a decomposição de Theil, o componente “entre grupos” pode ter seu próprio intervalo de confiança via bootstrap, mas por construção ele é sempre não negativo — vale reportar tanto o valor em unidades absolutas de Theil quanto sua fração do total.

Interpretação

A decomposição de Theil entre/dentro contextualiza — mas não substitui — a comparação direta de médias entre grupos. É perfeitamente possível, e comum, que uma fração pequena da desigualdade total (digamos, abaixo de 10%) venha da diferença entre grupos amplos como raça ou gênero, mesmo quando essa diferença de médias é grande e estatisticamente muito significativa (ver o teste t de Welch e Oaxaca-Blinder). As duas coisas não competem: a fração “entre grupos” fala sobre a variância total da renda na população; o gap médio entre grupos fala sobre a diferença de posição típica entre eles. Ambas as leituras são válidas e devem ser apresentadas juntas, não uma no lugar da outra.

Sobre o índice de Gini: comparar Gini entre grupos exige cuidado semelhante. Um grupo pode ter Gini mais baixo simplesmente porque sua distribuição de renda está mais comprimida perto da base — ou seja, quase todo mundo naquele grupo ganha pouco, de forma relativamente parecida. Isso não é “mais igualdade no sentido positivo”; é compressão numa faixa de renda baixa. Gini mais baixo não deve ser lido, por si só, como “situação melhor” sem olhar também o nível de renda (a média ou mediana) daquele grupo.

Limitações

- O índice de Theil, apesar de decomponível exatamente entre e dentro de grupos, é sensível à escolha de como os grupos são definidos — recortar a população de formas diferentes (dois grupos amplos vs. dez subgrupos específicos) muda a fração atribuída a “entre grupos”.
- Nenhum dos índices, sozinho, diz por que a desigualdade dentro de um grupo é alta — isso exige investigação adicional (por exemplo, decomposição por outras variáveis, ou decomposição por RIF ao longo da distribuição).
- Comparações de Gini ou Theil ao longo do tempo podem ser afetadas por mudanças na cobertura da pesquisa, na definição da variável de renda, ou em ajustes de inflação — vale garantir comparabilidade metodológica antes de interpretar uma mudança como mudança real de desigualdade.
- Quantis ponderados em subgrupos pequenos (baixa contagem de observações amostrais, mesmo que o peso populacional seja grande) têm maior incerteza — sempre verificar o tamanho de amostra por trás de um quantil reportado.

Exemplo

Considere um cenário hipotético: uma pesquisa domiciliar mede a renda de duas regiões de um país, Região Norte e Região Sul, com os seguintes dados agregados (inventados):

- Região Norte: renda média = 3.200, participação na renda total = 35%, Theil interno = 0,28.

- Região Sul: renda média = 5.100, participação na renda total = 65%, Theil interno = 0,33.

Passo 1 — Theil entre grupos. Usando a fórmula de decomposição, com a renda média geral $\bar{y}$ (uma média ponderada pela participação de renda de cada região, que resulta em aproximadamente 4.430):

$$T_{\text{entre}} = 0,35 \ln \left(\frac{4.430}{3.200} \right) + 0,65 \ln \left(\frac{4.430}{5.100} \right) \approx 0,35 \times 0,325 - 0,65 \times 0,140 \approx 0,022$$

Passo 2 — Theil dentro dos grupos:

$$T_{\text{dentro}} = 0,35 \times 0,28 + 0,65 \times 0,33 = 0,098 + 0,215 = 0,313$$

Passo 3 — Theil total:


$$T = T_{\text{entre}} + T_{\text{dentro}} = 0,022 + 0,313 = 0,335$$

Interpretação: a parcela “entre regiões” representa cerca de $0,022 / 0,335 \approx 6,6\%$ da desigualdade total — mesmo com uma diferença de renda média de quase 60% entre as duas regiões (3.200 vs. 5.100). A grande maioria da desigualdade (93,4%) está dentro de cada região, refletindo que, dentro da Região Norte e da Região Sul separadamente, já existe grande variação entre quem ganha pouco e quem ganha muito. Isso não torna a diferença regional sem importância — ela é substancial e mensurável — mas contextualiza seu peso relativo dentro do quadro geral de desigualdade do país.

A figura abaixo ilustra esse tipo de decomposição, com a parcela “entre grupos” tipicamente pequena em relação à parcela “dentro dos grupos”:

A segunda figura mostra curvas de Lorenz hipotéticas para dois grupos com Ginis diferentes — ilustrando que um Gini mais baixo corresponde a uma curva mais próxima da diagonal de igualdade perfeita, mas isso, por si só, não diz nada sobre o nível de renda de cada grupo:


Decomposição do índice de Theil



Dados ilustrativos, não representam nenhum projeto real.

Figura 11: Barra empilhada mostrando a decomposição do índice de Theil entre parcela entre grupos (pequena) e dentro dos grupos (grande)

Curvas de Lorenz: mesma diferença de médias, concentração diferente



Dados ilustrativos, não representam nenhum projeto real.

Figura 12: Curvas de Lorenz para dois grupos hipotéticos com Gini de 0,32 e 0,47, mostrando diferentes graus de concentração

Teste de não-inferioridade

Pressupõe os fundamentos de teste A/B — veja [Fundamentos de teste A/B](#).

Conceito

Um teste de não-inferioridade avalia se uma métrica de tratamento não é pior que a métrica de controle por mais do que uma margem δ definida previamente — em vez de testar se as duas são iguais. É o teste apropriado para métricas de guardrail: indicadores que não podem se deteriorar além de um limite aceitável, mesmo quando o objetivo principal do experimento é outro (por exemplo, ganhar velocidade, reduzir custo, ou melhorar uma métrica de negócio diferente).

A diferença central em relação a um teste de duas pontas convencional não é de mecânica estatística — é de formulação lógica das hipóteses. Um teste comum divide o espaço de possibilidades em “sem diferença” (nulo) e “alguma diferença, em qualquer direção” (alternativa). O teste de não-inferioridade divide o espaço de forma assimétrica: a hipótese nula passa a ser justamente “houve deterioração maior que a margem”, e a hipótese alternativa é “não houve deterioração maior que a margem”. Essa inversão de qual afirmação carrega o ônus da prova é o que torna o teste de não-inferioridade estruturalmente diferente, não apenas uma reformulação de palavras do mesmo teste.

Formulação matemática

Seja $\Delta = \mu_T - \mu_C$ a diferença real (populacional) entre tratamento e controle numa métrica onde valores maiores são piores (por exemplo, taxa de fraude). Seja $\delta > 0$ a margem de não-inferioridade, definida de forma que uma deterioração de até δ seja considerada aceitável.

As hipóteses são:

$$H_0 : \Delta \geq \delta \quad H_1 : \Delta < \delta$$

Note a assimetria: H_0 afirma que a métrica piorou pelo menos tanto quanto a margem (o cenário “ruim” é o nulo); H_1 afirma que a piora, se houver, é menor que a margem. Isso é o oposto estrutural de um teste de superioridade, onde a hipótese nula é “sem efeito” e a alternativa é “há efeito”.

A estatística de teste segue a mesma lógica de um teste de efeito padrão, mas comparada contra δ em vez de zero:

$$z = \frac{\hat{\Delta} - \delta}{SE(\hat{\Delta})}$$

Rejeita-se H_0 (concluindo não-inferioridade) quando $z < -z_{1-\alpha}$, o que equivale, de forma mais intuitiva, a checar se o limite superior de um intervalo de confiança unilateral de $(1 - \alpha)$ para Δ fica abaixo de δ :

$$\hat{\Delta} + z_{1-\alpha} \cdot SE(\hat{\Delta}) < \delta$$

Na prática, é comum reportar essa checagem usando o limite superior de um intervalo de confiança bilateral de $(1 - 2\alpha)$, que é numericamente equivalente ao limite superior unilateral de $(1 - \alpha)$ — por exemplo, um IC bilateral de 90% produz o mesmo limite superior que um IC unilateral de 95%.

Suposições

- **A margem δ é definida antes de olhar os dados do experimento**, como decisão de negócio — não é estimada nem otimizada a partir dos próprios dados do experimento. Definir a margem depois de ver o resultado invalida a interpretação do teste.
- **A direção de “pior” está claramente definida** para a métrica em questão. Para métricas onde valores maiores são ruins (fraude, erro, latência), a margem limita o quanto a métrica pode subir; para métricas onde valores menores são ruins (satisfação, retenção), a formulação se inverte e a margem limita o quanto pode cair.
- **As mesmas suposições de um teste de efeito padrão se aplicam** — aleatorização válida, independência entre unidades, amostra grande o suficiente para a aproximação normal do erro-padrão ser razoável (ou uso de métodos exatos/bootstrap quando não for).
- **O desenho tem poder estatístico suficiente para o teste ser informativo** — com amostra pequena e margem apertada, o teste pode ser estruturalmente incapaz de concluir não-inferioridade mesmo quando o efeito real é favorável, simplesmente por falta de precisão.

Hipóteses

Como detalhado acima:

$$H_0 : \Delta \geq \delta \quad H_1 : \Delta < \delta$$

O nível de significância α (tipicamente 0,05, unilateral) representa a taxa de erro tolerada de concluir não-inferioridade quando, na verdade, a métrica piorou além da margem. Diferente de um teste de duas pontas, aqui só existe uma direção de erro relevante — não há preocupação simétrica com “falso positivo para melhora”, porque melhora não é o que está sendo testado.

Interpretação

Concluir não-inferioridade é uma afirmação estatística específica: há evidência, com o nível de confiança escolhido, de que a deterioração real não excede δ . Não é uma afirmação de equivalência (isso exigiria um teste de equivalência, com margens nos dois sentidos) nem uma afirmação de que não há custo algum — a estimativa pontual pode indicar uma piora pequena, só que dentro do tolerável.

Um resultado inconclusivo — quando o limite superior do intervalo de confiança cruza δ — não deve ser lido como “a métrica piorou muito”. Ele significa apenas que os dados não trazem evidência suficiente para excluir essa possibilidade. A causa mais comum de inconclusão é poder estatístico insuficiente: amostra pequena, métrica muito variável, ou margem definida de forma muito apertada em relação à precisão que o desenho consegue entregar. Antes de reportar um resultado inconclusivo como definitivo, vale checar se o desenho tinha poder adequado para a margem escolhida — um cálculo que espelha o de tamanho de amostra para testes de efeito padrão, mas usando δ como o “efeito mínimo” de referência.

Limitações

- A margem é uma escolha de negócio, e escolhas diferentes de margem podem levar a conclusões diferentes sobre exatamente os mesmos dados — o teste não valida a margem escolhida, só testa contra ela.

- Não-inferioridade concluída em um único experimento, com uma amostra e um contexto específicos, não garante que a métrica se manterá dentro da margem indefinidamente — mudanças de composição de usuários, de escala, ou de contexto podem alterar o comportamento real da métrica ao longo do tempo.
- Testar múltiplas métricas de guardrail simultaneamente, cada uma com seu próprio teste de não-inferioridade, tem a mesma questão de comparações múltiplas que qualquer bateria de testes — vale considerar isso ao interpretar “todas as guardrails passaram”.
- Um teste de não-inferioridade não substitui um teste de efeito na métrica primária; os dois respondem perguntas diferentes e geralmente são usados em conjunto, um para o ganho pretendido, outro para o risco a monitorar.

Exemplo

Uma empresa de pagamentos testa um novo modelo de detecção de fraude, significativamente mais rápido que o atual, mas com potencial de ser um pouco menos preciso. Antes do experimento, a equipe de risco define a margem de não-inferioridade em 0,5 ponto percentual de aumento na taxa de fraude — um limite acima do qual o ganho de velocidade não compensaria o risco assumido.

O experimento roda com 12.000 transações em cada braço:

	Controle (modelo atual)	Tratamento (modelo novo)
Transações	12.000	12.000
Casos de fraude	252	242
Taxa	2,10%	2,02%

A diferença observada é $\hat{\Delta} = 2,02\% - 2,10\% = -0,08$ ponto percentual (o modelo novo teve fraude ligeiramente menor). O erro-padrão da diferença, calculado da mesma forma que num teste de efeito padrão, resulta num intervalo de confiança de 95% de aproximadamente $[-0,34, +0,18]$ pontos percentuais.

Como o limite superior do intervalo (+0,18 p.p.) está abaixo da margem de 0,5 p.p., conclui-se não-inferioridade com 95% de confiança: há evidência estatística de que o novo modelo não aumenta a fraude além do tolerável.

Para ilustrar como a mesma lógica se aplicaria a outros resultados possíveis do mesmo experimento, considere três cenários hipotéticos para o IC da diferença, todos contra a mesma margem de 0,5 p.p.:

- **Cenário A (superior):** IC de $[-0,70, -0,14]$ — inteiramente abaixo de zero. O novo modelo não só é não-inferior, como mostra evidência de melhora real.
- **Cenário B (não inferior, sem superioridade):** IC de $[-0,20, +0,30]$ — cruza zero, mas o limite superior ainda fica abaixo da margem de 0,5. Não há evidência de melhora, mas há evidência de não-inferioridade.
- **Cenário C (inconclusivo):** IC de $[+0,05, +0,65]$ — o limite superior ultrapassa a margem. Não é possível concluir não-inferioridade com confiança; a piora observada pode, ou não, exceder o tolerável.

Note que só o Cenário C leva a uma decisão de não avançar sem mais investigação — os Cenários A e B, apesar de terem estimativas pontuais e formas de intervalo bem diferentes, levam à mesma decisão prática de aprovar o lançamento do ponto de vista da métrica de guardrail.




Figura 13: Estimativa pontual e IC 95% da diferença de fraude comparados à margem de não-inferioridade de 0,5 p.p.




Figura 14: Três cenários hipotéticos de IC comparados à mesma margem de não-inferioridade

Decomposição de Oaxaca-Blinder

Conceito

A decomposição de Oaxaca-Blinder é uma técnica contábil (accounting), baseada em regressão, que divide a diferença observada nas médias de uma variável de resultado (tipicamente salário ou renda) entre dois grupos em duas partes: uma atribuível a diferenças nas características médias observáveis dos grupos (componente explicado) e outra que permanece mesmo depois de ajustar por essas características (componente não explicado). Foi proposta independentemente por Ronald Oaxaca e Alan Blinder em 1973, no contexto de diferenças salariais entre grupos demográficos.

A intuição central é contrafactual: o método pergunta “qual seria o resultado médio do Grupo B se ele tivesse a distribuição de características do Grupo A, mas continuasse sendo remunerado segundo a própria estrutura de retornos?” A resposta a essa pergunta hipotética é o que permite separar “diferença de composição” de “diferença de retorno às mesmas características”.

Formulação matemática

Para cada grupo $g \in \{A, B\}$, ajusta-se um modelo linear:

$$Y_g = X_g \beta_g + \varepsilon_g$$

onde Y_g é a variável de resultado (salário, por exemplo), X_g é a matriz de características observáveis (incluindo um intercepto), β_g é o vetor de coeficientes estimado separadamente para o grupo g , e ε_g é o termo de erro.

A diferença total de médias é:

$$\bar{Y}_A - \bar{Y}_B = \bar{X}_A \hat{\beta}_A - \bar{X}_B \hat{\beta}_B$$

A decomposição clássica (de dois termos, na forma “threefold”) reescreve isso somando e subtraindo um termo contrafactual $\bar{X}_B \hat{\beta}_A$:

$$\bar{Y}_A - \bar{Y}_B = \underbrace{(\bar{X}_A - \bar{X}_B) \hat{\beta}_A}_{\text{explicado}} + \underbrace{\bar{X}_B (\hat{\beta}_A - \hat{\beta}_B)}_{\text{não explicado}}$$

- O **componente explicado** é a diferença de características médias ($\bar{X}_A - \bar{X}_B$) ponderada pelos retornos do Grupo A ($\hat{\beta}_A$) — quanto do gap viria só da diferença de composição, se ambos os grupos fossem remunerados como o Grupo A.
- O **componente não explicado** é a diferença nos coeficientes ($\hat{\beta}_A - \hat{\beta}_B$) ponderada pela característica média do Grupo B — quanto do gap vem de retornos diferentes às mesmas características.

Essa formulação usa $\hat{\beta}_A$ como estrutura de referência (variante “do ponto de vista do Grupo A”). Existe uma formulação simétrica equivalente usando $\hat{\beta}_B$, e formulações que usam uma combinação ponderada dos dois (por exemplo, a proposta de Reimers ou de Cotton) para evitar a arbitrariedade de escolher um grupo como referência — a escolha pode alterar moderadamente a divisão entre os dois componentes, especialmente quando os dois conjuntos de coeficientes diferem bastante.

Suposições

1. **Especificação correta do modelo de resultado:** o modelo linear em X_g deve capturar razoavelmente a relação entre as características e o resultado dentro de cada grupo. Não linearidades importantes não capturadas (por exemplo, retornos decrescentes à experiência) enviesam a decomposição.
2. **Ausência de viés de variável omitida relevante:** qualquer característica que afete o resultado e que esteja correlacionada tanto com o grupo quanto com as demais variáveis incluídas, mas que não tenha sido medida, é absorvida pelo componente não explicado — inflando-o artificialmente.
3. **Comparabilidade de suporte:** a decomposição pressupõe que existe sobreposição real na distribuição de características entre os grupos. Quando um grupo tem quase nenhuma observação em certas combinações de características presentes no outro grupo, o contrafactual passa a depender de extrapolação do modelo para fora dos dados observados — uma forma de instabilidade que vale verificar (por exemplo, comparando as distribuições de X entre os grupos).
4. **Ausência de causalidade reversa entre a variável de resultado e as características:** se a característica em si é parcialmente determinada pelo resultado (por exemplo, ocupação escolhida em resposta a expectativas de salário), a interpretação de “quanto explicaria X ” fica mais delicada.

Hipóteses

A decomposição em si não é um teste de hipótese único — é uma técnica descritiva. Mas cada componente pode (e deve) ter seu próprio erro-padrão e teste de significância, geralmente obtido por métodos delta ou bootstrap:

- H_0 para o componente explicado: a parcela explicada da diferença é igual a zero.
- H_0 para o componente não explicado: a parcela não explicada é igual a zero.
- Erros-padrão: como a decomposição envolve produtos de quantidades estimadas ($\bar{X}$ e $\hat{\beta}$), o erro-padrão de cada componente não é trivial de derivar analiticamente — bootstrap (reamostrando ambos os grupos e recalculando a decomposição inteira em cada reamostragem) é a abordagem mais robusta e amplamente usada na prática.

Interpretação

O componente explicado tem uma leitura relativamente direta: é a parte do gap que se pode atribuir à diferença de composição observável entre os grupos, dada a estrutura de retornos escolhida como referência.

O componente não explicado exige muito mais cautela. É comum — e problemático — descrevê-lo diretamente como “discriminação”. Essa interpretação só é válida sob a suposição forte de que todas as características relevantes para determinar o resultado foram medidas e incluídas no modelo. Na prática, isso quase nunca é verdade: habilidades não observadas, qualidade da rede de contatos, diferenças em negociação salarial, viés em processos de contratação e promoção, e muitas outras variáveis omitidas podem estar dentro do componente não explicado, ao lado de qualquer efeito de discriminação propriamente dita. O componente não explicado é melhor lido como um limite superior aproximado do que pode ser atribuído a fatores não capturados pelo modelo — incluindo, mas não se limitando a, discriminação.

Além disso, o método não estabelece causalidade nas próprias características: dizer que “escolaridade explica X unidades do gap” não significa que aumentar a escolaridade de um grupo necessariamente fecharia essa parte do gap — presume equilíbrio geral constante e ignora efeitos de composição de mercado que poderiam mudar junto.

Limitações

- **Sensibilidade à especificação:** adicionar ou remover variáveis de controle pode mudar substancialmente a divisão entre explicado e não explicado — é importante reportar como o resultado muda com diferentes especificações (análise de robustez).
- **Só decompõe a média:** para entender se o gap muda ao longo da distribuição (maior nas pontas, por exemplo), a decomposição de médias não é suficiente — ver a decomposição por RIF, que estende essa lógica para outros pontos da distribuição.
- **Ambiguidade na escolha do grupo de referência:** diferentes convenções (referência A, referência B, referência combinada) produzem resultados numericamente diferentes, mesmo usando os mesmos dados — sempre reportar qual convenção foi usada.
- **Não corrige por seleção:** se a composição de quem está presente na amostra (por exemplo, quem está empregado) já é resultado de um processo seletivo relacionado ao grupo, a decomposição herda esse viés de seleção.

Exemplo

Considere um cenário hipotético: uma organização quer entender a diferença de salário médio mensal entre dois departamentos, Departamento A e Departamento B, controlando por anos de experiência.

Dados agregados (inventados):

- Departamento A: salário médio = 5.800, experiência média = 8 anos.
- Departamento B: salário médio = 4.620, experiência média = 5 anos.
- Modelo ajustado para o Departamento A: salário = $3.800 + 250 \times \text{experiência}$.
- Modelo ajustado para o Departamento B: salário = $3.570 + 210 \times \text{experiência}$.

Passo 1 — gap total:

$$5.800 - 4.620 = 1.180$$

Passo 2 — componente explicado (usando a estrutura de retornos do Departamento A como referência):

$$(\bar{X}_A - \bar{X}_B)\hat{\beta}_{\text{exp},A} = (8 - 5) \times 250 = 750$$


Passo 3 — componente não explicado:

$$1.180 - 750 = 430$$

Isso pode ser verificado pela formulação de coeficientes: a diferença de intercepto ($3.800 - 3.570 = 230$) mais a diferença de inclinação aplicada à experiência média do Departamento B ($(250 - 210) \times 5 = 200$) soma 430 — consistente com a decomposição em nível de coeficientes.

Interpretação: aproximadamente 64% do gap salarial (750 de 1.180) pode ser atribuído à diferença de experiência média entre os departamentos, dado que ambos fossem remunerados segundo a estrutura do Departamento A. O restante, 36%, reflete tanto uma diferença no intercepto quanto uma diferença na inclinação (retorno por ano de experiência) entre os dois departamentos — algo que não pode ser atribuído à experiência em si, mas que também não deve ser automaticamente rotulado como discriminação sem investigação adicional sobre outras variáveis potencialmente omitidas (tipo de função dentro do departamento, por exemplo).

A figura abaixo detalha a contribuição de diferentes características hipotéticas para o componente explicado, num cenário com mais de uma variável de controle:



Dados ilustrativos, não representam nenhum projeto real.

Figura 15: Gráfico de barras horizontais mostrando a contribuição de escolaridade, idade/experiência e ocupação para o componente explicado

Análise de transições em painel rotativo

Conceito

Um painel rotativo é um desenho amostral usado em várias pesquisas domiciliares contínuas, no qual uma fração da amostra é substituída a cada rodada de entrevista, enquanto outra fração permanece por um número limitado de rodadas consecutivas antes de também ser substituída. Esse desenho combina duas vantagens: permite estimativas de corte transversal representativas em cada rodada isolada (a amostra completa continua representativa da população em cada momento) e, ao mesmo tempo, permite acompanhar uma fração dos mesmos indivíduos ao longo de algumas rodadas consecutivas, o suficiente para estudar transições individuais entre estados.

A análise de transições explora essa segunda vantagem: em vez de comparar estimativas agregadas de dois momentos diferentes — o que mistura mudança real de estado individual com simples substituição de quem está na amostra — ela pareia registros da mesma pessoa entre entrevistas consecutivas e constrói uma matriz de transição, que descreve diretamente a probabilidade condicional de mudar (ou permanecer) em um determinado estado de um período para o outro.

Formulação matemática

Seja $S = \{s_1, s_2, \dots, s_K\}$ o conjunto de estados possíveis (por exemplo, {empregado formal, empregado informal, desempregado, fora da força de trabalho}). Para um indivíduo i pareado com sucesso entre a entrevista no período t e a entrevista no período $t+h$ (onde h é o intervalo entre entrevistas, tipicamente um trimestre), sejam $S_{i,t}$ e $S_{i,t+h}$ os estados observados em cada momento.

A **matriz de transição** para um grupo g é definida por suas entradas:

$$P_{jk}^{(g)} = \Pr(S_{t+h} = s_k \mid S_t = s_j, \text{ grupo } = g) \approx \frac{\sum_{i \in g} \mathbb{1}[S_{i,t} = s_j] \cdot \mathbb{1}[S_{i,t+h} = s_k]}{\sum_{i \in g} \mathbb{1}[S_{i,t} = s_j]}$$

Onde:

- $P_{jk}^{(g)}$ é a probabilidade estimada de transição do estado s_j para o estado s_k , dentro do grupo g , entre os dois momentos de entrevista;
- o numerador conta quantos indivíduos do grupo g estavam no estado s_j em t e no estado s_k em $t + h$;
- o denominador conta o total de indivíduos do grupo g que estavam no estado s_j em t (e que puderam ser pareados até $t + h$).

Cada linha j da matriz $P^{(g)}$ soma 1, já que todo indivíduo que estava no estado s_j termina em algum estado s_k (incluindo $s_k = s_j$, ou seja, permanecer no mesmo estado).

Quando pesos amostrais estão disponíveis (essencial em pesquisas domiciliares complexas), a estimativa correta pondera cada indivíduo pelo seu peso amostral longitudinal — que, em geral, é diferente do peso transversal de cada rodada individual, e precisa ser calculado ou fornecido especificamente para uso em análises de painel.

A comparação entre grupos foca tipicamente numa entrada específica de interesse, por exemplo $P_{\text{desempregado, empregado}}^{(A)}$ versus $P_{\text{desempregado, empregado}}^{(B)}$, testada como uma diferença de duas proporções:

$$z = \frac{\hat{P}^{(A)} - \hat{P}^{(B)}}{\sqrt{\hat{P}(1 - \hat{P}) \left(\frac{1}{n_A} + \frac{1}{n_B} \right)}}, \quad \hat{P} = \frac{x_A + x_B}{n_A + n_B}$$

onde x_g é o número de transições de interesse no grupo g , n_g é o total de indivíduos do grupo g que partiram do estado inicial, e $\hat{P}$ é a proporção combinada sob a hipótese nula de que as duas taxas são iguais.

Suposições

- **Pareamento correto entre entrevistas.** A validade de toda a análise depende de identificar corretamente que o mesmo indivíduo, e não outra pessoa que passou a morar no mesmo domicílio, está sendo comparado entre os dois momentos. A maioria das pesquisas fornece um identificador de domicílio mais uma posição do morador dentro do domicílio, e o pareamento correto exige confirmar também características demográficas estáveis (sexo, e idade dentro de uma tolerância compatível com o intervalo entre entrevistas).
- **Atrito amostral não sistematicamente diferente entre grupos.** Se a taxa de sucesso de pareamento (ou de permanência na amostra) difere entre os grupos comparados — por exemplo, se um grupo tem maior mobilidade residencial e por isso é sistematicamente mais difícil de acompanhar — a amostra pareada deixa de ser representativa da população de origem de forma diferente para cada grupo, introduzindo viés de seleção na comparação.
- **Estados de destino bem definidos e mutuamente exclusivos.** Ambiguidades na classificação de estado (por exemplo, definir precisamente o que conta como “fora da força de trabalho” versus “desempregado” segundo critérios de busca ativa) precisam ser tratadas de forma consistente nos dois momentos da comparação.

- **Intervalo entre entrevistas comparável entre indivíduos.** Se o intervalo h varia (algumas pessoas pareadas com um trimestre de diferença, outras com dois), taxas de transição não são diretamente comparáveis sem ajuste, já que transições têm mais tempo para acontecer em intervalos maiores.

Hipóteses

Para comparar uma taxa de transição específica entre dois grupos A e B :

- H_0 : $P^{(A)} = P^{(B)}$ — a probabilidade de transição é igual nos dois grupos.
- H_1 : $P^{(A)} \neq P^{(B)}$ (ou unilateral, se houver uma direção esperada a priori).
- Estatística de teste: z , como definida acima (teste de duas proporções).
- Nível de significância convencional: $\alpha = 0,05$.
- Quando há múltiplos estados de destino sendo comparados simultaneamente (a matriz de transição inteira, não só uma célula), um teste de qui-quadrado de homogeneidade entre as duas matrizes é mais apropriado que testes separados célula a célula, que não corrigem para comparações múltiplas.

Interpretação

A matriz de transição descreve mobilidade **observada entre os pareados**, não necessariamente da população inteira. Três pontos de interpretação merecem atenção:

- **Composição versus mobilidade real.** Uma taxa agregada estável ao longo do tempo pode esconder alta rotatividade individual (muita gente saindo e entrando do estado, num fluxo compensado) ou baixa rotatividade (as mesmas pessoas permanecendo). Só a análise de transições distingue esses dois cenários — uma diferença crucial para decisões de política, já que as intervenções adequadas para cada cenário são diferentes.
- **Representatividade da subamostra pareada.** Se o pareamento tiver sucesso em, digamos, 85% dos casos elegíveis, os resultados descrevem diretamente esses 85% — a extrapolação para os 15% não pareados exige a suposição adicional de que o pareamento falha de forma aleatória em relação ao próprio estado sendo estudado, o que raramente é garantido (pessoas que mudam de domicílio, por exemplo, podem ser sistematicamente mais propensas a também estar mudando de situação de emprego).
- **Transições não implicam causalidade.** Uma taxa de saída do desemprego maior num grupo é uma diferença observada de mobilidade, não uma explicação de por que essa mobilidade é maior — fatores de composição (idade, escolaridade, região, tipo de ocupação anterior) podem explicar parte ou toda a diferença, e isolar esses fatores exigiria uma análise adicional (por exemplo, um modelo de risco proporcional ajustando por covariáveis).

Limitações

- **Painel rotativo não é painel longitudinal completo.** A diferença é fundamental: num painel longitudinal, a mesma amostra (ou uma amostra fixa) é seguida por anos. Num painel rotativo, cada indivíduo é observado apenas durante a janela em que está na amostra (tipicamente algumas rodadas consecutivas) antes de ser substituído — análises de transição só são possíveis dentro dessa janela limitada, e a maior parte dos dados de uma pesquisa de painel rotativo, fora dessa janela de sobreposição, é na prática repeated cross-section (corte transversal repetido): cada rodada é representativa da população, mas os indivíduos entrevistados em rodadas não sobrepostas não são os mesmos.
- **Pareamento pode falhar de forma não aleatória.** Além de mudança de domicílio, o pareamento pode falhar por erro de registro, mudança na composição do domicílio (nascimento, morte, separação), ou recusa em entrevistas subsequentes — cada um

desses mecanismos pode estar correlacionado com o próprio estado sendo estudado, criando viés de atrito diferencial entre grupos.

- **Poucas rodadas de sobreposição limitam o horizonte de análise.** Se o desenho do painel permite acompanhar cada indivíduo por, digamos, no máximo cinco entrevistas, só é possível medir transições dentro dessa janela — tendências de mais longo prazo exigem encadear várias coortes de painel, uma abordagem mais complexa e sujeita a mais fontes de ruído.
- **Erros de classificação de estado se acumulam em duas medições.** Como a análise depende da classificação correta do estado em dois momentos (não um), qualquer erro de medição ou ambiguidade de classificação em qualquer um dos dois momentos contamina a transição estimada.

Exemplo

Considere um estudo hipotético de mobilidade no mercado de trabalho de dois grupos de trabalhadores, A e B, usando uma pesquisa domiciliar com desenho de painel rotativo em que cada domicílio é entrevistado por até quatro trimestres consecutivos.

Do total de 500 pessoas desempregadas do Grupo A na primeira entrevista, 420 (84%) puderam ser pareadas com uma entrevista um trimestre depois. Do Grupo B, de 480 pessoas desempregadas, 390 (81%) foram pareadas. As taxas de pareamento são parecidas, o que reduz (mas não elimina) a preocupação com atrito diferencial.

Dentro da amostra pareada, a matriz de transição de um trimestre é:

Grupo A (partindo de desempregado, $n=420$):

Destino	%
Empregado formal	14,0%
Empregado informal	7,9%
Desempregado	55,7%
Fora da força de trabalho	22,4%

Grupo B (partindo de desempregado, $n=390$):

Destino	%
Empregado formal	9,2%
Empregado informal	8,5%
Desempregado	58,7%
Fora da força de trabalho	23,6%

A taxa de transição para emprego formal é de 14,0% no Grupo A contra 9,2% no Grupo B — uma diferença de 4,8 pontos percentuais. O teste de duas proporções para essa diferença específica produz $z \approx 2,17$, correspondente a um valor-p de aproximadamente 0,030 — estatisticamente significativo ao nível convencional de 5%.

Interpretação cuidadosa: essa diferença descreve a experiência dos indivíduos pareados com sucesso em cada grupo — 84% e 81% das amostras originais, respectivamente. Se, por exemplo, pessoas do Grupo B que mudaram de domicílio (e por isso não foram pareadas) tiverem taxas de emprego sistematicamente diferentes das que permaneceram no mesmo domicílio, a taxa estimada de 9,2% pode não representar corretamente o grupo B como um todo. A diferença de 4,8 pontos percentuais também não isola, sozinha, por que a transição

é mais rápida no Grupo A — características observáveis como escolaridade média e tipo de ocupação anterior precisariam ser controladas separadamente para avançar nessa questão.

```
import pandas as pd
import numpy as np
from statsmodels.stats.proportion import proportions_ztest

## base_pareada: uma linha por indivíduo pareado com sucesso
## colunas: grupo, estado_t0, estado_t1


def matriz_transicao(df, grupo):
    sub = df[df["grupo"] == grupo]
    return pd.crosstab(sub["estado_t0"], sub["estado_t1"], normalize="index") * 100

matriz_a = matriz_transicao(base_pareada, "A")
matriz_b = matriz_transicao(base_pareada, "B")

desemp_a = base_pareada[(base_pareada["grupo"] == "A") & (base_pareada["estado_t0"] == "desempregado")]
desemp_b = base_pareada[(base_pareada["grupo"] == "B") & (base_pareada["estado_t0"] == "desempregado")]

x = [(desemp_a["estado_t1"] == "empregado_formal").sum(),
      (desemp_b["estado_t1"] == "empregado_formal").sum()]
n = [len(desemp_a), len(desemp_b)]
estat, p_valor = proportions_ztest(x, n)
print(estat, p_valor)
```

Situação uma entrevista depois, partindo do desemprego



Dados ilustrativos, não representam nenhum projeto real.

Figura 16: Situação uma entrevista depois, partindo do desemprego

Regressão de Poisson com efeitos fixos

Conceito

A regressão de Poisson é um modelo linear generalizado (GLM) desenhado para variáveis de resposta que são contagens de eventos: números inteiros não negativos representando quantas vezes algo aconteceu em um intervalo fixo (uma partida, uma hora, um mês). É o modelo natural quando a variável de interesse viola as duas suposições centrais de uma regressão linear comum: (1) contagens não podem ser negativas, mas uma reta ajustada por mínimos quadrados pode prever valores negativos sem qualquer restrição; e (2) a distribuição de contagens é tipicamente assimétrica à direita, com massa de probabilidade concentrada em valores baixos (0, 1, 2) e uma cauda longa, muito diferente da simetria de uma normal.

A ideia central é modelar o **logaritmo** da taxa esperada de eventos, $\log(\lambda)$, como uma combinação linear das variáveis explicativas — e não a taxa em si. Essa escolha de “link function” logarítmica garante que, ao desfazer a transformação (exponenciando), a previsão λ resultante seja sempre positiva, qualquer que seja o valor dos coeficientes ou das variáveis.

Efeitos fixos por unidade (indivíduo, time, loja, período) adicionam ao modelo uma dummy para cada unidade, permitindo que cada uma tenha seu próprio intercepto — sua própria taxa-base de eventos — antes de estimar o efeito da variável de interesse. Isso é fundamentalmente diferente de simplesmente incluir a unidade como um controle de “nível médio”: o efeito fixo absorve toda característica não observada, mas constante ao longo do tempo, daquela unidade (um time historicamente mais ofensivo, uma loja em um bairro mais movimentado), isolando melhor o efeito da variável de interesse (mandar o jogo em casa, ser sexta-feira) das diferenças estruturais entre unidades.

Formulação matemática

Distribuição de Poisson. Uma variável de contagem Y segue distribuição de Poisson com parâmetro $\lambda > 0$ se

$$P(Y = y) = \frac{e^{-\lambda} \lambda^y}{y!}, \quad y = 0, 1, 2, \dots$$

onde $\lambda = E[Y] = \text{Var}(Y)$ — a média e a variância são iguais (equidispersão), uma propriedade específica dessa distribuição que se torna uma suposição testável do modelo.

Modelo log-linear. Para a observação i (por exemplo, o time t na partida m), a taxa esperada é

$$\lambda_i = \exp(\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki} + \alpha_{u(i)})$$

onde: - $x_{1i}, \dots, x_{ki}$ são as variáveis explicativas (força ofensiva, força defensiva do adversário, indicador de mando de campo); - $\beta_1, \dots, \beta_k$ são os coeficientes a estimar, na escala logarítmica; - $\alpha_{u(i)}$ é o efeito fixo da unidade u à qual a observação i pertence (o time, por exemplo) — funciona como um intercepto específico daquela unidade; - β_0 é o intercepto geral (absorvido, na prática, pelos α_u quando há efeitos fixos completos por unidade).

Equivalentemente, na escala log:

$$\log(\lambda_i) = \beta_0 + \beta_1 x_{1i} + \dots + \beta_k x_{ki} + \alpha_{u(i)}$$

Isso é o que dá nome ao modelo: “log-linear” — linear na escala do log da média, não na escala original.

Interpretação multiplicativa do coeficiente. Considere duas observações idênticas exceto pela variável x_1 (por exemplo, mando de campo: $x_1 = 1$ vs. $x_1 = 0$). A razão entre as taxas esperadas é

$$\frac{\lambda_i | x_1 = 1}{\lambda_i | x_1 = 0} = \frac{\exp(\beta_0 + \beta_1 \cdot 1 + \dots)}{\exp(\beta_0 + \beta_1 \cdot 0 + \dots)} = e^{\beta_1}$$

Todos os outros termos se cancelam porque são idênticos nas duas observações — é por isso que e^{β_1} é interpretado como um **fator multiplicativo**: quantas vezes a taxa esperada muda quando x_1 aumenta em uma unidade, mantendo tudo o mais constante.

Estimação. Os coeficientes são estimados por máxima verossimilhança. A log-verossimilhança do modelo, para n observações, é

$$\ell(\beta, \alpha) = \sum_{i=1}^n \left[y_i \log(\lambda_i) - \lambda_i - \log(y_i!) \right]$$

Não existe forma fechada para o vetor de coeficientes que maximiza ℓ ; a estimação usa métodos numéricos iterativos (tipicamente Newton-Raphson ou variantes de mínimos quadrados ponderados iterativamente, IRLS).

Suposições

- **Equidispersão** ($\text{Var}(Y) = E[Y] = \lambda$): a suposição mais frequentemente violada na prática. Quando a variância observada excede claramente a média — **sobredispersão** — os erros-padrão de máxima verossimilhança da Poisson pura ficam viesados para baixo, produzindo estatísticas de teste infladas e valores-p artificialmente pequenos. Diagnóstico: comparar a estatística de deviance (ou de Pearson qui-quadrado) do modelo pelos graus de liberdade residuais — uma razão muito maior que 1 sugere sobredispersão.
- **Independência condicional dos eventos**: dado o vetor de variáveis explicativas e os efeitos fixos, as contagens devem ser independentes entre observações. Sequências temporais com dependência forte (uma vitória aumentando a probabilidade de gols na partida seguinte por efeito de confiança) violam isso.
- **Forma funcional log-linear correta**: assume-se que o efeito das variáveis é multiplicativo na escala original, não aditivo. Se a relação verdadeira for de outra forma (por exemplo, saturação em altos valores da variável explicativa), o modelo mal especificado pode produzir previsões enviesadas nas extremidades.
- **Efeitos fixos exigem variação suficiente dentro de cada unidade**: se uma unidade (time) nunca joga em casa nem fora dentro da amostra (situação rara, mas ilustrativa), o efeito fixo daquela unidade absorve toda variação e o coeficiente de interesse não pode ser identificado a partir dela.

Hipóteses

Para cada coeficiente β_j , o teste usual é:

- $H_0 : \beta_j = 0$ (a variável x_j não tem efeito sobre a taxa esperada de eventos, controlando pelas demais)
- $H_1 : \beta_j \neq 0$

A estatística de teste (teste de Wald) é $z = \hat{\beta}_j / \text{SE}(\hat{\beta}_j)$, comparada a uma distribuição normal padrão. Um intervalo de confiança de 95% para β_j é $\hat{\beta}_j \pm 1,96 \times \text{SE}(\hat{\beta}_j)$; exponenciando os limites, obtém-se o intervalo de confiança para o fator multiplicativo e^{β_j} . Quando o modelo sofre sobredispersão, é recomendável recalculer os erros-padrão de forma robusta (sandwich estimator) ou reajustar via binomial negativa antes de interpretar esses testes.

Interpretação

O coeficiente exponenciado informa quanto a taxa esperada de eventos muda multiplicativamente por unidade de mudança na variável explicativa, controlando pelas demais variáveis e pelos efeitos fixos incluídos. Isso é uma afirmação sobre associação condicional dentro do modelo especificado — não uma afirmação causal automática. Em um contexto observacional (como estimar o efeito de mando de campo usando dados históricos de partidas já ocorridas, sem experimento controlado), o coeficiente reflete a associação estimada dado o conjunto de controles incluído; se houver fatores relevantes omitidos que se correlacionam tanto com a variável de interesse quanto com a taxa de eventos, a estimativa pode estar enviesada.

Significância estatística (um β_j distinguível de zero) não equivale a relevância prática: um fator multiplicativo de 1,02 (2% de aumento) pode ser estatisticamente significativo em uma amostra grande sem ser operacionalmente importante.

Limitações

- **Sobredispersão é comum e não é automaticamente diagnosticada pelo ajuste do modelo** — é preciso verificar explicitamente. Ignorá-la leva a intervalos de confiança artificialmente estreitos e conclusões de significância que não se sustentam.
- **Excesso de zeros** (mais observações com contagem zero do que a Poisson prevê) é outra forma comum de má especificação, distinta de sobredispersão geral, que pode exigir modelos específicos (zero-inflated Poisson).
- **Efeitos fixos por unidade com muitas categorias e poucas observações por categoria** (problema de parâmetros incidentais) podem gerar estimativas instáveis, especialmente combinados com contagens baixas.
- **A interpretação multiplicativa assume que o efeito de x_j é constante na escala log em toda a faixa de valores observada** — extrapolar previsões para combinações de variáveis muito fora do intervalo observado nos dados de treino é arriscado.

Exemplo

Considere um exemplo fictício de um campeonato de um esporte genérico com cinco equipes (A a E), em que se quer estimar o efeito de mandar o jogo em casa sobre o número de gols marcados, controlando por efeitos fixos de time.


Um modelo simplificado, ajustado sobre dados sintéticos de uma temporada hipotética, estima:

- Coeficiente de mando de campo: $\hat{\beta}_{\text{casa}} = 0,300$, erro-padrão = 0,085
- Estatística de Wald: $z = 0,300/0,085 \approx 3,53$, valor-p < 0,001
- Intervalo de confiança 95% para β_{casa} : [0,133; 0,467]

Exponenciando o coeficiente e os limites do intervalo: fator multiplicativo estimado $e^{0,300} \approx 1,35$, com IC 95% aproximado $[e^{0,133}, e^{0,467}] \approx [1,14, 1,60]$.


Leitura: controlando pela força relativa de cada equipe (via efeito fixo por time), jogar em casa está associado a um aumento estimado de 35% no número esperado de gols marcados

(IC 95%: aumento entre 14% e 60%), efeito estatisticamente significativo ($p < 0,001$). Essa é uma leitura sobre a associação dentro dos dados observados dessa temporada hipotética — generalizar para outras temporadas ou competições exigiria reestimar o modelo com dados daquele contexto, e checar se a suposição de equidispersão se sustenta antes de confiar nos intervalos de confiança reportados.



Dados ilustrativos, não representam nenhum projeto real.

Figura 17: Distribuição de contagem de gols comparada a uma curva normal



Dados ilustrativos, não representam nenhum projeto real.

Figura 18: Gols esperados por força defensiva do adversário, jogando em casa e fora

Poder estatístico e efeito mínimo detectável (MDE)

Conceito

Poder estatístico e efeito mínimo detectável (MDE, do inglês *minimum detectable effect*) são duas faces da mesma relação matemática entre quatro grandezas de um teste de hipótese: tamanho de amostra, variância da métrica, nível de significância e poder. Dadas três delas, a quarta fica determinada.

O **poder** de um teste é a probabilidade de rejeitar corretamente a hipótese nula quando ela é de fato falsa — ou seja, a probabilidade de detectar um efeito real de um tamanho específico, dado o desenho do experimento. É o complemento do erro tipo II (β): $\text{poder} = 1 - \beta$.

O **MDE** inverte a pergunta: em vez de fixar um efeito hipotético e perguntar qual é o poder, fixa-se o poder desejado (convencionalmente 80%) e pergunta-se qual é o menor efeito real que o desenho consegue detectar com essa probabilidade. Na prática, calcular o MDE antes de rodar um experimento é a forma mais direta de responder à pergunta “esse desenho tem alguma chance de funcionar?” antes de gastar tempo e recursos nele.

A utilidade central do conceito é evitar dois erros simétricos: (1) rodar um experimento subdimensionado, que nunca teria força para detectar o efeito que realmente importa para a decisão de negócio, produzindo um resultado “sem significância” que não significa “sem efeito” — apenas “sem poder para ver”; e (2) superdimensionar um experimento além do necessário, consumindo tráfego e tempo que poderiam ir para outros testes.

Formulação matemática

Para uma comparação de duas proporções (o caso mais comum em testes de produto), com tamanhos de amostra iguais em cada braço, a relação entre as quatro grandezas pode ser escrita, numa aproximação normal, como:

$$MDE = (z_{(1-\alpha/2)} + z_{(1-\beta)}) \cdot \sqrt{2 \cdot p \cdot (1 - p) / n}$$

onde:

- MDE é o efeito mínimo detectável, em pontos percentuais (a versão relativa é MDE / p).
- $z_{(1-\alpha/2)}$ é o quantil da distribuição normal padrão correspondente ao nível de significância bicaudal escolhido — por exemplo, 1,96 para $\alpha = 0,05$.
- $z_{(1-\beta)}$ é o quantil da normal padrão correspondente ao poder desejado — por exemplo, 0,84 para poder = 80%.
- p é a taxa de conversão (ou proporção) de base esperada no grupo controle.
- n é o tamanho de amostra por grupo.


Para uma métrica contínua (por exemplo, tempo de uso, valor de compra), a forma equivalente usa o desvio-padrão da métrica (σ) no lugar do termo $p(1-p)$:

$$MDE = (z_{(1-\alpha/2)} + z_{(1-\beta)}) \cdot \sigma \cdot \sqrt{2 / n}$$

Isolando n , obtém-se o tamanho de amostra necessário para um MDE-alvo:

$$n = 2 \cdot \sigma^2 \cdot (z_{(1-\alpha/2)} + z_{(1-\beta)})^2 / MDE^2$$

O ponto estrutural importante nessas equações é a dependência de n em $1/MDE^2$: para reduzir o MDE pela metade, a amostra precisa quadruplicar — daí o efeito de retornos decrescentes ao aumentar o tráfego de um experimento.



Dados ilustrativos, não representam nenhum projeto real.

Figura 19: Curvas de poder para diferentes tamanhos de amostra

Suposições

- **Aproximação normal para a distribuição da diferença de médias/proporções:** válida em amostras razoavelmente grandes pelo teorema central do limite; em amostras muito pequenas ou métricas muito assimétricas, a aproximação normal se degrada e formas exatas (por exemplo, baseadas na distribuição binomial) são preferíveis.
- **Variância corretamente estimada:** o cálculo do MDE depende de uma estimativa prévia da variância (ou da taxa de conversão de base) da métrica. Se essa estimativa vier de um período atípico ou de uma amostra pequena, o MDE calculado herda esse erro.
- **Observações independentes:** o cálculo padrão assume que cada unidade experimental contribui de forma independente. Quando há estrutura de cluster (por exemplo, a mesma loja gerando múltiplas observações ao longo do tempo), a variância efetiva é maior do que a fórmula simples sugere, e o MDE real é maior do que o calculado sem esse ajuste.
- **Alocação e nível de significância fixados de antemão:** o cálculo assume uma única checagem de significância, no fim do experimento, com α fixo. Se o experimento for monitorado repetidamente e encerrado assim que um resultado “significativo” aparece, a taxa de falso positivo efetiva sobe acima do α nominal — um problema separado, mas relacionado, tratado por métodos de checagem sequencial.

Hipóteses

O poder e o MDE não são, em si, um teste de hipótese — são propriedades de um teste de hipótese planejado. O teste subjacente, tipicamente, é:

- **H0:** não há diferença entre o grupo tratamento e o grupo controle na métrica de interesse (diferença de médias, ou de proporções, igual a zero).
- **H1:** existe uma diferença diferente de zero.
- **Nível de significância (α):** probabilidade aceita de rejeitar H0 incorretamente (erro tipo I), tipicamente 5%.
- **Poder-alvo ($1 - \beta$):** probabilidade desejada de rejeitar H0 corretamente, dado que um efeito de tamanho igual ao MDE exista de fato, tipicamente 80%.

O MDE é o menor efeito verdadeiro para o qual essa probabilidade de rejeição correta atinge o poder-alvo, dado o n , α e a variância assumidos.

Interpretação

O MDE calculado antes do experimento é uma propriedade do **desenho**, não uma previsão do efeito real. Interpretações incorretas comuns incluem tratar um MDE de 3% como “esperamos um efeito de 3%” (errado — é o piso de detecção, não uma previsão) ou concluir, ao final de um experimento sem significância estatística, que “não há efeito” sem verificar se o desenho sequer tinha poder para detectar um efeito do tamanho que seria relevante para a decisão.

Recalcular o poder no meio de um experimento é útil e legítimo quando o tamanho de amostra disponível muda por razões externas ao resultado do teste em si — por exemplo, um prazo de negócio reduz a janela do experimento, ou o tráfego observado ficou abaixo do planejado. Nesse caso, recalcula-se o MDE (ou o poder para um efeito específico) usando o n efetivamente alcançado, e comunica-se essa mudança de forma transparente: “o desenho original previa detectar efeitos de X%; com a amostra reduzida disponível, o piso de detecção subiu para Y%”. Isso é diferente — e válido — de olhar repetidamente para o p-valor do próprio experimento e decidir parar assim que ele cruza 0,05, o que infla a taxa de falso positivo.

Limitações

- O cálculo depende de uma estimativa de variância que só é conhecida com precisão depois que dados são coletados — antes disso, usa-se uma aproximação (de um histórico similar, um piloto, ou uma faixa conservadora), que carrega sua própria incerteza.
- MDE e poder assumem um teste bicaudal único no fim do experimento; testes com múltiplas métricas secundárias, múltiplos cortes de subgrupo, ou monitoramento contínuo do p-valor não são cobertos pelo cálculo simples sem ajuste adicional (correção para múltiplas comparações, ou métodos sequenciais).
- Um desenho com poder adequado para a métrica primária pode não ter poder nenhum para métricas secundárias com variância muito maior ou taxa de base muito menor — vale calcular o MDE separadamente para cada métrica que importa na decisão.
- Poder alto não implica que o efeito, se detectado, será relevante para o negócio — um MDE muito pequeno pode detectar efeitos estatisticamente significativos mas irrelevantes na prática. O MDE deve ser comparado contra um efeito mínimo que faria sentido agir, não apenas calculado e esquecido.

Exemplo

Um serviço de streaming fictício quer testar se recomendar conteúdo por meio de um novo algoritmo de personalização aumenta o tempo médio diário de uso, hoje em 42 minutos, com desvio-padrão histórico de 35 minutos (a métrica é bastante variável, pois inclui tanto usuários esporádicos quanto usuários muito engajados).

A equipe de produto estima, com base em testes anteriores de mudanças de recomendação, que um ganho realista estaria entre 2 e 4 minutos por dia. Antes de comprometer o experimento a quatro semanas de tráfego, calcula-se o MDE para diferentes durações:

Duração	n por grupo (aprox.)	MDE (minutos)
1 semana	8.000	2,2
2 semanas	16.000	1,5
4 semanas	32.000	1,1

Com apenas uma semana, o MDE de 2,2 minutos já cobriria a extremidade inferior do efeito esperado (2 minutos) — mas com margem pequena, o que tornaria o resultado sensível a ruído. A equipe opta por duas semanas, com MDE de 1,5 minuto, confortavelmente abaixo do menor efeito que consideram relevante.

No meio do experimento, um problema técnico reduz o tráfego elegível em 40% durante três dias. Ao final das duas semanas planejadas, o n efetivo por grupo ficou em 11.200, não 16.000. Recalculando o MDE com o n real:

$$\text{MDE}_{\text{efetivo}} = (1,96 + 0,84) \cdot 35 \cdot \sqrt{2 / 11.200} \approx 1,85 \text{ minutos}$$

O MDE efetivo (1,85 min) ainda está abaixo do efeito mínimo relevante (2 minutos), então o experimento, mesmo reduzido, mantém poder suficiente para a decisão que importa — mas a equipe registra essa mudança na documentação do experimento, em vez de assumir silenciosamente que o desenho original (com n=16.000) ainda estava valendo.

Exemplo de código

```
import numpy as np
from statsmodels.stats.power import TTestIndPower
```

```

analise = TTestIndPower()

sigma = 35.0          # desvio-padrão histórico da métrica, em minutos
alpha = 0.05
poder_alvo = 0.80

## MDE (em minutos) para diferentes tamanhos de amostra por grupo
for n in [8_000, 16_000, 32_000, 11_200]:
    effect_size = analise.solve_power(nobs1=n, alpha=alpha, power=poder_alvo)
    mde_minutos = effect_size * sigma
    print(f"n={n:>6}: MDE ≈ {mde_minutos:.2f} min")

```

O `effect_size` retornado pelo `statsmodels` é padronizado (unidades de desvio-padrão); multiplicar por `sigma` converte de volta para a unidade original da métrica — minutos, neste exemplo.

Inferência por randomização (teste de permutação)

Conceito

A inferência por randomização (também chamada de teste de permutação, ou “Fisher randomization test”, em referência a Ronald Fisher) constrói a distribuição de referência de um teste de hipótese diretamente a partir da aleatoriedade real do desenho experimental, em vez de recorrer a uma aproximação teórica (como a distribuição normal ou t) que só é válida assintoticamente, em amostras grandes.

A ideia central é a hipótese nula “forte” ou “nítida” (*sharp null*): sob H_0 , o resultado de cada unidade seria exatamente o mesmo, independentemente de ela ter sido designada para tratamento ou controle. Se isso for verdade, a única fonte de variação na estatística observada é a própria aleatoriedade de quem foi sorteado para cada grupo — e essa fonte de variação pode ser enumerada exatamente, porque o pesquisador conhece o mecanismo de sorteio usado.

Formulação matemática

Sejam N unidades experimentais, das quais N_1 são designadas para tratamento e $N_0 = N - N_1$ para controle, segundo um mecanismo de sorteio conhecido. Seja Y_i o resultado observado da unidade i e $W_i \in \{0, 1\}$ o indicador de tratamento efetivamente sorteado.

A estatística de teste observada é tipicamente a diferença de médias:

$$\hat{\tau}_{\text{obs}} = \frac{1}{N_1} \sum_{i:W_i=1} Y_i - \frac{1}{N_0} \sum_{i:W_i=0} Y_i$$

Sob a hipótese nula nítida $H_0 : Y_i(1) = Y_i(0)$ para toda unidade i (o resultado de cada unidade seria idêntico em qualquer dos dois grupos), os valores observados Y_i não dependem de W_i . Isso permite calcular a mesma estatística sob **qualquer** outra atribuição possível W' , mantendo os valores Y_i fixos:

$$\hat{\tau}(W') = \frac{1}{N_1} \sum_{i:W'_i=1} Y_i - \frac{1}{N_0} \sum_{i:W'_i=0} Y_i$$

O conjunto de todas as atribuições possíveis, dado o mecanismo de sorteio (por exemplo, todas as formas de escolher N_1 entre N unidades, sem reposição), tem $\binom{N}{N_1}$ elementos quando o desenho é uma randomização completa simples. O valor-p bilateral é:

$$p = \frac{1}{\binom{N}{N_1}} \sum_{W'} \mathbb{1} [|\hat{\tau}(W')| \geq |\hat{\tau}_{\text{obs}}|]$$

onde $\mathbb{1}[\cdot]$ é a função indicadora (1 se a condição é verdadeira, 0 caso contrário). Quando $\binom{N}{N_1}$ é grande demais para enumerar exaustivamente, aproxima-se essa soma por Monte Carlo: sorteia-se um número grande M (tipicamente 10.000 ou mais) de reatribuições aleatórias W' e calcula-se a mesma proporção sobre essa amostra, o que converge para o valor-p exato conforme M cresce.

Suposições

- **Aleatoriedade real da atribuição ao tratamento.** É a única suposição fundamental do método — sem ela, a distribuição de referência construída não corresponde a nenhum processo real que gerou os dados.
- **Hipótese nula nítida.** A forma clássica do teste (a de Fisher) testa a hipótese de que o tratamento não teve efeito absolutamente nenhum sobre nenhuma unidade — mais forte do que a hipótese usual de “efeito médio igual a zero” (a de Neyman). Rejeitar H_0 sob esse desenho é evidência de que o tratamento afetou pelo menos alguma unidade, não necessariamente todas igualmente.
- **Exclusão de interferência entre unidades (SUTVA).** O resultado de uma unidade não pode depender de qual tratamento outras unidades receberam (sem efeitos de transbordamento ou equilíbrio geral) — do contrário, a reatribuição hipotética de W' deixa de corresponder a um cenário contrafactual coerente.

Hipóteses

- H_0 : efeito nulo nítido — o resultado de cada unidade seria idêntico independentemente do grupo ao qual foi designada.
- H_1 : o tratamento afeta o resultado de pelo menos algumas unidades.
- Estatística de teste: geralmente a diferença de médias entre grupos, mas o método aceita qualquer estatística de interesse (diferença de medianas, coeficiente de um modelo, razão de proporções) — a lógica de reatribuição é a mesma, qualquer que seja a estatística escolhida.
- Valor-p: proporção das reatribuições possíveis (ou amostradas) que produz uma estatística tão extrema quanto, ou mais extrema que, a observada.
- Nível de significância: convencional, 5%, mas sujeito à granularidade discreta do número de reatribuições possíveis (ver limitações).

Interpretação

Um valor-p baixo obtido por randomização é evidência de que a atribuição real produziu um resultado incomum entre todas as formas possíveis do sorteio — uma leitura causal diretamente ligada à aleatorização do próprio experimento, sem depender de suposições sobre a distribuição populacional dos dados. Essa é uma vantagem importante sobre testes paramétricos: a validade não depende de normalidade, nem de amostra grande, nem de uma forma funcional específica para os erros.

O que o método não faz é generalizar automaticamente o efeito estimado para além das unidades observadas — a inferência é sobre a atribuição observada versus as demais atribuições possíveis dentro do experimento, não sobre uma população maior da qual as unidades foram amostradas (essa seria uma questão de inferência amostral, separada da inferência sobre a atribuição).

Limitações

- **Granularidade do valor-p em amostras pequenas.** Com poucas unidades, o número de reatribuições possíveis é pequeno, limitando o menor valor-p alcançável — com $\binom{4}{2} = 6$ reatribuições, o menor valor-p possível é $1/6 \approx 0,167$, mesmo diante de um efeito grande. Isso é uma limitação estrutural, não uma falha de cálculo.
- **Depende de randomização genuína.** Se a atribuição ao tratamento não foi realmente aleatória (por exemplo, unidades “voluntárias” se auto-selecionaram para o tratamento), a distribuição de referência construída não representa nenhum mecanismo real — o método perde validade.

- **Custo computacional em desenhos grandes.** Com muitas unidades, a enumeração exaustiva se torna inviável (o número de combinações cresce rapidamente), exigindo aproximação por Monte Carlo — que, por sua vez, introduz uma pequena margem de erro amostral no próprio cálculo do valor-p, controlável aumentando o número de reatribuições sorteadas.

Comparação com outros métodos de inferência com poucos clusters

Inferência por randomização, erros-padrão robustos a cluster e bootstrap wild-cluster respondem ao mesmo problema geral: inferência confiável quando as observações não são independentes, frequentemente por causa de poucos clusters ou poucas unidades de aleatorização.

- **Erros-padrão robustos a cluster** são o ponto de partida padrão, mas se tornam pouco confiáveis justamente no cenário de poucos clusters, porque dependem de uma aproximação assintótica.
- **Inferência por randomização** é a alternativa mais direta quando o próprio mecanismo de sorteio do experimento é conhecido e o número de reatribuições possíveis é enumerável (ou amostrável) — não depende de nenhuma suposição distribucional, apenas da aleatoriedade real da atribuição. É especialmente atraente quando o desenho experimental é simples (por exemplo, sorteio completo entre um pequeno número de unidades).
- **Bootstrap wild-cluster** é preferível quando o efeito de interesse vem de um modelo de regressão mais complexo (com controles, por exemplo), ou quando não há um mecanismo de sorteio simples e conhecido para reproduzir exatamente via reatribuição — o bootstrap wild-cluster reamostra os resíduos do modelo ajustado, em vez de reatribuir tratamento diretamente.


Na prática, quando ambos são aplicáveis, é comum rodar os dois como checagem cruzada: conclusões que concordam entre inferência por randomização e bootstrap wild-cluster dão mais confiança na robustez do resultado do que qualquer um dos dois isoladamente.

Exemplo

Uma rede de restaurantes testa um novo cardápio sazonal em 6 unidades (sorteio simples: 3 tratamento, 3 controle), medindo o gasto médio por mesa na semana do teste, em reais: unidades tratadas registram 12, 15 e 9; as de controle registram 22, 18 e 11.

A diferença de médias observada é $12,0 - 17,0 = -5,0$. Existem $\binom{6}{3} = 20$ formas possíveis de escolher as 3 unidades tratadas. Calculando a diferença de médias para cada uma dessas 20 combinações, obtém-se a distribuição de referência completa — sem qualquer suposição sobre a forma da distribuição do gasto por mesa.

Das 20 combinações, 6 produzem uma diferença tão extrema quanto (ou mais extrema que) $-5,0$ em valor absoluto, dando um valor-p bilateral de $6/20 = 0,30$. Com apenas 6 unidades no experimento, esse resultado não é incomum o suficiente para ser evidência de que o novo cardápio de fato mudou o gasto médio por mesa — mesmo que a diferença observada, isoladamente, pareça grande em termos percentuais. O exemplo ilustra bem a limitação de granularidade: com poucas unidades, é preciso um efeito muito grande para que a atribuição observada seja de fato incomum entre as poucas reatribuições possíveis.



Dados ilustrativos, não representam nenhum projeto real.

Figura 20: Distribuição de referência formada pelas 20 reatribuições possíveis, com a diferença observada de $-5,0$ destacada

Decomposição por RIF (Recentered Influence Function)

Conceito

A decomposição por RIF, proposta por Firpo, Fortin e Lemieux (2009), generaliza a decomposição de Oaxaca-Blinder para estatísticas distribucionais além da média — quantis, o índice de Gini, a variância, ou qualquer outra funcional da distribuição que possa ser escrita como uma expectativa de sua função de influência recentrada.

Antes de formalizar, vale entender o que é uma função de influência. Em estatística robusta, a função de influência de um estimador $\nu(F)$ (uma funcional aplicada à distribuição F da variável) mede, de forma matemática precisa, quanto o valor de ν mudaria se a distribuição F fosse levemente perturbada por uma massa de probabilidade extra concentrada num único ponto y . Formalmente:

$$IF(y; \nu, F) = \lim_{\epsilon \rightarrow 0} \frac{\nu((1 - \epsilon)F + \epsilon\delta_y) - \nu(F)}{\epsilon}$$

onde δ_y é uma distribuição degenerada que concentra toda a massa em y . Intuitivamente, a função de influência diz “se eu adicionasse uma observação a mais no valor y , com peso infinitesimal, o quanto isso puxaria ν para cima ou para baixo?” — pontos com influência alta são aqueles cuja presença ou ausência mais afeta a estatística.

A função de influência **recentrada** (RIF) é definida como:

$$RIF(y; \nu, F) = \nu(F) + IF(y; \nu, F)$$

A propriedade chave — e o motivo de o método funcionar — é que a expectativa da RIF sobre a distribuição recupera exatamente a funcional original:

$$\mathbb{E}[RIF(Y; \nu, F)] = \nu(F)$$

Isso significa que $\nu(F)$ (a mediana, um percentil, o Gini) pode ser tratado, para fins de regressão, como se fosse a média de uma variável transformada — a RIF avaliada em cada observação. É essa equivalência que permite reaproveitar toda a maquinaria de regressão e decomposição de Oaxaca-Blinder, agora aplicada sobre $RIF(y)$ em vez de sobre y diretamente.

É importante deixar claro: a decomposição por RIF **não é o mesmo método** que Oaxaca-Blinder — é uma extensão que usa Oaxaca-Blinder como uma etapa interna, depois de transformar os dados via RIF. Oaxaca-Blinder decompõe médias diretamente; RIF decompõe qualquer estatística distribucional expressável como expectativa de uma função de influência, usando a mesma lógica contrafactual por baixo dos panos.

Formulação matemática

RIF para um quantil. Para o quantil de ordem q (por exemplo, $q = 0,5$ para a mediana), com valor Q_q e densidade $f_Y(Q_q)$ da variável Y avaliada em Q_q :

$$RIF(y; Q_q) = Q_q + \frac{q - \mathbb{1}\{y \leq Q_q\}}{f_Y(Q_q)}$$

Aqui, $\mathbb{1}\{y \leq Q_q\}$ é um indicador que vale 1 se a observação está abaixo do quantil e 0 caso contrário. Observações logo abaixo do quantil recebem um valor de RIF ligeiramente acima de Q_q ; observações logo acima recebem um valor ligeiramente abaixo — a densidade no denominador controla a magnitude desse ajuste (quanto menor a densidade ali, mais sensível o quantil é a mudanças, e maior a magnitude da RIF).

Regressão e decomposição. Uma vez calculada $RIF_i = RIF(y_i; \nu)$ para cada observação i de cada grupo, ajusta-se:

$$RIF_i = X_i \gamma_g + u_i, \quad g \in \{A, B\}$$

e aplica-se a decomposição de Oaxaca-Blinder exatamente como na versão para médias, mas usando γ_g no lugar de β_g :

$$\nu_A - \nu_B \approx \underbrace{(\bar{X}_A - \bar{X}_B) \hat{\gamma}_A}_{\text{explicado, no ponto } \nu} + \underbrace{\bar{X}_B (\hat{\gamma}_A - \hat{\gamma}_B)}_{\text{não explicado, no ponto } \nu}$$

O til de aproximação existe porque essa é uma aproximação de primeira ordem (via função de influência) — válida localmente, não uma decomposição exata como no caso da média.

Suposições

1. **Estimação consistente da densidade:** para quantis, o denominador da RIF depende da densidade f_Y avaliada no quantil, que precisa ser estimada (tipicamente via kernel). A escolha da largura de banda do kernel afeta a estimativa, especialmente em regiões com poucos dados.
2. **Todas as suposições de Oaxaca-Blinder se aplicam** à etapa de regressão e decomposição sobre a variável transformada: especificação correta, ausência de vies de variável omitida relevante, e sobreposição real de características entre os grupos.
3. **Validade da aproximação linear:** a decomposição por RIF é fundamentalmente uma aproximação de primeira ordem — ela é exata para mudanças pequenas na distribuição, mas pode perder precisão para comparações com diferenças muito grandes entre os grupos. Isso é particularmente relevante ao interpretar mudanças ao longo de períodos longos de tempo, não só entre dois grupos num único momento.

Hipóteses

Como em Oaxaca-Blinder, cada componente da decomposição (explicado e não explicado, em cada ponto da distribuição escolhido) pode ser testado individualmente:

- H_0 : o componente é igual a zero naquele ponto específico da distribuição.
- Erros-padrão: o processo de duas etapas (estimar a RIF, depois estimar a regressão) introduz incerteza adicional que precisa ser propagada corretamente — bootstrap (reamostrando os dados originais e refazendo as duas etapas em cada reamostragem, incluindo a reestimação da densidade) é a abordagem padrão, já que fórmulas analíticas fechadas para o erro-padrão são complexas.
- Ao reportar vários pontos da distribuição simultaneamente (um perfil de gap por percentil, por exemplo), a comparação múltipla entre pontos merece a mesma cautela que qualquer teste múltiplo — um único ponto isolado “significativo” em meio a vários outros não significativos pede interpretação cuidadosa.

Interpretação

A decomposição por RIF permite uma leitura muito mais rica do que a média: ela mostra se um gap entre grupos é uniforme ao longo da distribuição ou se se concentra em certas regiões — um padrão de “ piso pegajoso ” (gap maior na base) indica que, mesmo entre quem ganha pouco em ambos os grupos, a disparidade é grande; um padrão de “ teto de vidro ” (gap maior no topo) indica que a disparidade cresce justamente entre quem está no topo da distribuição de renda, típico de barreiras ao acesso a posições mais altas.

As mesmas ressalvas de Oaxaca-Blinder sobre causalidade e viés de variável omitida se aplicam, ponto a ponto: o componente não explicado em qualquer percentil não pode ser automaticamente atribuído a discriminação. Além disso, cada ponto tem sua própria margem de erro, geralmente maior nas pontas da distribuição — um perfil de gap que parece dramaticamente diferente entre dois percentis adjacentes pode, na verdade, estar dentro da margem de erro combinada.

Limitações

- **Estimativas menos precisas nas pontas:** a densidade f_Y tende a ser menor nos extremos da distribuição (há menos observações ali), o que amplia o denominador na fórmula da RIF e, por consequência, a variância da estimativa.
- **Aproximação de primeira ordem:** para diferenças muito grandes entre os grupos, ou para reponderações muito distantes da distribuição observada, a aproximação linear da RIF pode não capturar bem mudanças não lineares na estatística de interesse. Métodos de reponderação completa (como o de DiNardo-Fortin-Lemieux) são alternativas que evitam essa aproximação, ao custo de maior complexidade computacional.
- **Escolha da grade de percentis:** reportar um número limitado de pontos (P10, P25, P50, P75, P90, por exemplo) pode não capturar comportamento ainda mais extremo (P1, P99) — a escolha da grade deve refletir a pergunta de pesquisa, não conveniência.
- **Herda todas as limitações causais de Oaxaca-Blinder,** ponto a ponto: é uma decomposição contábil, não um método de inferência causal.


Exemplo

Considere um cenário hipotético: uma pesquisa salarial anual coleta dados de renda de duas regiões, Região Norte e Região Sul, junto com anos de escolaridade. Uma decomposição de Oaxaca-Blinder na média mostra um gap não explicado de 15%. A decomposição por RIF é aplicada em cinco percentis para investigar se esse gap é uniforme:

Percentil	Gap total	Gap explicado	Gap não explicado
P10	34%	6 p.p.	28%
P25	27%	8 p.p.	19%
P50	22%	7 p.p.	15%
P75	25%	7 p.p.	18%
P90	33%	7 p.p.	26%

O componente explicado (atribuível à diferença de escolaridade entre as regiões) fica relativamente estável, entre 6 e 8 pontos percentuais, ao longo da distribuição. O componente não explicado, porém, segue um padrão em “U”: 28% no P10, cai para 15% no P50, e sobe de novo para 26% no P90. Isso sugere que a diferença de escolaridade explica uma fatia parecida do gap em todos os níveis de renda, mas o que sobra — a parte não explicada — é consideravelmente maior tanto entre quem ganha menos quanto entre quem ganha mais, e menor no meio da distribuição.


Um resultado como esse é editorialmente relevante: contar só o número da média (15%) esconderia que a experiência de quem está na base ou no topo da distribuição de renda é bem diferente da experiência de quem está no meio.



Dados ilustrativos, não representam nenhum projeto real.

Figura 21: Gráfico de linha mostrando o gap não explicado estimado em cada percentil, com intervalo de confiança de 95% mais largo nas pontas

A figura seguinte ilustra a forma da própria função de influência recentrada para a mediana — o “degrau” característico em torno do valor mediano, que justifica por que observações logo abaixo e logo acima da mediana recebem pesos opostos na regressão:



Dados ilustrativos, não representam nenhum projeto real.

Figura 22: Forma em degrau da função de influência recentrada em torno do valor da mediana

Análise de transbordamento espacial e canibalização

Conceito

Em experimentos com unidades geograficamente localizadas — lojas, zonas de entrega, praças de atendimento — um dos pressupostos mais frequentemente violados, e menos verificados, é o de **isolamento entre unidades** (SUTVA, *stable unit treatment value assumption*): a ideia de que o resultado de uma unidade de controle depende apenas de ela mesma não ter sido tratada, e não do que acontece nas unidades tratadas próximas a ela.

Quando unidades tratadas e de controle competem pelo mesmo público — o mesmo raio de entrega, a mesma vizinhança comercial — essa suposição falha por um mecanismo específico chamado **transbordamento espacial** (*spatial spillover*), do qual a **canibalização** é o caso mais comum em contextos de negócio: parte da atividade que aparece como “ganho” na unidade tratada é, na verdade, atividade deslocada de uma unidade de controle vizinha, não atividade nova. Quando isso acontece e não é detectado, o efeito estimado do experimento superestima sistematicamente o ganho líquido real, porque a unidade de controle usada como referência também foi afetada pelo tratamento — só que na direção oposta.

A análise de transbordamento espacial usa a própria geografia do desenho experimental como instrumento de diagnóstico: comparando o efeito estimado contra controles a diferentes distâncias da unidade tratada mais próxima, é possível separar, ainda que de forma aproximada, quanto do efeito aparente é deslocamento versus criação líquida.

Formulação matemática

Seja Y_i a métrica de interesse (vendas, pedidos, receita) da unidade i , medida antes (Y_i^{pre}) e depois (Y_i^{post}) do início do tratamento, e seja d_i a distância entre a unidade de controle i e a unidade tratada mais próxima.

Define-se dois subgrupos de controle a partir de um limiar de distância τ :

Controle próximo: $C_{\text{perto}} = \{ i : \text{tratada}_i = 0, d_i \leq \tau \}$

Controle distante: $C_{\text{longe}} = \{ i : \text{tratada}_i = 0, d_i > \tau \}$

O efeito estimado contra cada grupo, numa forma de diferença-em-diferenças simples, é:

$$\delta_{\text{perto}} = (\bar{y}_T^{\text{post}} - \bar{y}_T^{\text{pre}}) - (\bar{y}_{\text{perto}}^{\text{post}} - \bar{y}_{\text{perto}}^{\text{pre}})$$

$$\delta_{\text{longe}} = (\bar{y}_T^{\text{post}} - \bar{y}_T^{\text{pre}}) - (\bar{y}_{\text{longe}}^{\text{post}} - \bar{y}_{\text{longe}}^{\text{pre}})$$

onde $\bar{y}_T$, $\bar{y}_{\text{perto}}$ e $\bar{y}_{\text{longe}}$ são as médias da métrica no grupo tratado, no controle próximo e no controle distante, respectivamente.

A diferença entre os dois efeitos estimados é um indicador direto de contaminação por transbordamento:

$$\text{Indicador de canibalização} = \delta_{\text{perto}} - \delta_{\text{longe}}$$

Um valor positivo e relevante indica que o controle próximo está, em média, performando pior do que o controle distante durante o período de tratamento — consistente com a hipótese de que ele está perdendo atividade para as unidades tratadas. Formalmente, sob o pressuposto de que o controle distante está livre de contaminação, δ_{longe} é o estimador do **efeito líquido real** do tratamento, e $\delta_{\text{perto}} - \delta_{\text{longe}}$ estima o tamanho do efeito de deslocamento absorvido pelo controle próximo.


Uma extensão contínua do mesmo raciocínio modela o efeito sobre o controle como uma função da distância d_i até a unidade tratada mais próxima — tipicamente com um decaimento suave, por exemplo por meio de uma regressão local (kernel) ou de uma especificação paramétrica simples como:

$$\Delta y_i = \beta_0 + \beta_1 \cdot \exp(-d_i / \lambda) + \varepsilon_i$$

onde Δy_i é a variação percentual da métrica na unidade de controle i , λ é um parâmetro de escala que captura a velocidade de decaimento do efeito com a distância, e β_1 mede a magnitude do efeito de transbordamento no limite $d_i \rightarrow 0$.

Suposições

- **O controle distante está de fato livre de contaminação:** essa é a suposição central de identificação. Se o raio real de competição for maior do que o limiar τ assumido para “distante”, mesmo esse grupo carrega algum viés, e o indicador de canibalização subestima a contaminação verdadeira.
- **A alocação de quais unidades foram tratadas não foi correlacionada com características locais que também afetam a tendência da métrica** (por exemplo, tratar preferencialmente lojas em bairros já em crescimento) — caso contrário, a comparação com qualquer controle, próximo ou distante, fica confundida por essa característica local, não só por transbordamento.
- **Estabilidade da fronteira de mercado durante o experimento:** a análise assume que o padrão espacial de competição (quem compete com quem) não muda substancialmente durante a janela do experimento.
- **Distância como proxy razoável de competição:** distância geográfica em linha reta (ou em tempo de deslocamento) precisa ser uma proxy razoável do overlap real de clientela — em contextos digitais, “distância” pode precisar ser redefinida (por



Dados ilustrativos, não representam nenhum projeto real.

Figura 23: Impacto sobre unidades de controle em função da distância até a unidade tratada mais próxima

exemplo, sobreposição de área de cobertura, ou similaridade de base de usuários), não necessariamente geográfica.

Hipóteses

Quando formalizado como teste de hipótese sobre o indicador de canibalização:

- **H0:** $\delta_{\text{perto}} = \delta_{\text{longe}}$ (não há diferença sistemática entre o efeito medido contra controle próximo e contra controle distante — sem evidência de transbordamento).
- **H1:** $\delta_{\text{perto}} \neq \delta_{\text{longe}}$ (existe uma diferença sistemática, consistente com contaminação espacial).

O teste pode ser conduzido via um modelo de diferença-em-diferenças com um termo de interação entre tratamento, período e uma indicadora de “controle próximo”, ou via inferência por permutação quando o número de unidades tratadas e de controle for pequeno — comum neste tipo de desenho, já que experimentos geográficos raramente têm dezenas de unidades tratadas.

Interpretação

O resultado central da análise não é “há ou não canibalização” no sentido binário, mas **quanto** do efeito aparente é deslocamento. Um indicador de canibalização de, digamos, 4 pontos percentuais sobre um efeito total aparente de 17% significa que aproximadamente um quarto do “ganho” medido contra o controle próximo é, na verdade, perda desse controle — o efeito líquido real está mais próximo de 13%.

É importante não interpretar um efeito líquido menor como “a mudança não funcionou”. Deslocamento de demanda entre unidades do mesmo negócio pode ser um resultado desejável (por exemplo, migrar clientes para um canal mais lucrativo) ou indesejável (uma expansão que na prática só realoca receita existente), dependendo inteiramente do objetivo estratégico por trás da mudança testada. A análise de transbordamento não decide isso — ela apenas separa as duas componentes para que a decisão seja tomada com essa informação.

Limitações

- A escolha do limiar de distância τ é arbitrária até certo ponto, e resultados podem ser sensíveis a essa escolha — vale reportar o indicador de canibalização para mais de um limiar, ou usar a versão contínua (decaimento com a distância) quando os dados permitirem.
- Com poucas unidades tratadas e de controle, as estimativas de δ_{perto} e δ_{longe} têm incerteza considerável, e a diferença entre elas herda essa incerteza — um indicador de canibalização “positivo” em cima de amostras pequenas pode não ser distinguível de zero.
- O método assume que a única forma de contaminação relevante é geográfica. Outras formas de transbordamento (por exemplo, o mesmo cliente comprando em canais diferentes de uma mesma empresa, ou efeitos de rede social entre clientes) não são capturadas por distância física e exigem desenhos diferentes.
- Mesmo quando o controle distante está bem escolhido, ele estima o efeito líquido **agregado na região observada** — não diz nada sobre se o crescimento é sustentável fora dessa região, o que é uma limitação de qualquer extrapolação de resultado de piloto local para rollout nacional.

Exemplo

Uma rede fictícia de academias testa um novo plano promocional de matrícula em 10 unidades de uma capital, medindo o número de novas matrículas mensais.

Definição dos grupos de controle: 18 unidades a até 4 km de alguma unidade tratada (controle próximo) e 22 unidades a mais de 15 km de qualquer unidade tratada (controle distante), todas na mesma cidade.

Dados agregados (matrículas mensais médias por unidade):

Grupo	Antes	Depois	Variação
Tratadas	42	58	+38,1%
Controle próximo	40	36	-10,0%
Controle distante	41	43	+4,9%

Efeito estimado contra o controle próximo: $38,1\% - (-10,0\%) = \mathbf{48,1 \text{ pontos percentuais}}$.

Efeito estimado contra o controle distante: $38,1\% - 4,9\% = \mathbf{33,2 \text{ pontos percentuais}}$.

Indicador de canibalização: $48,1 - 33,2 = \mathbf{14,9 \text{ pontos percentuais}}$.

A interpretação: das cerca de 48 pontos percentuais de “vantagem” aparente da promoção quando comparada às unidades vizinhas, aproximadamente 15 pontos refletem alunos que migraram de academias próximas, não crescimento líquido do mercado. O efeito líquido real, mais próximo de 33 pontos percentuais, é o número relevante para decidir se a promoção, aplicada em toda a rede (onde não haveria mais “unidades vizinhas não tratadas” para canibalizar), geraria crescimento comparável — hipótese que precisaria ser testada separadamente, já que a canibalização desaparece quando todas as unidades são tratadas ao mesmo tempo, mas o crescimento de mercado real pode ou não se manter na mesma magnitude.

Exemplo de código

```
import numpy as np
import pandas as pd
from scipy import stats

rng = np.random.default_rng(11)

## dados ilustrativos: 10 unidades tratadas, 18 controle próximo, 22 controle distante
n_tratadas, n_perto, n_longe = 10, 18, 22

matriculas = pd.concat([
    pd.DataFrame({
        "grupo": "tratada",
        "antes": rng.normal(42, 4, n_tratadas),
        "depois": rng.normal(58, 5, n_tratadas),
    }),
    pd.DataFrame({
        "grupo": "controle_perto",
        "antes": rng.normal(40, 4, n_perto),
        "depois": rng.normal(36, 4, n_perto),
    }),
    pd.DataFrame({
```

```

        "grupo": "controle_longe",
        "antes": rng.normal(41, 4, n_longe),
        "depois": rng.normal(43, 4, n_longe),
    }),
])

def variacao_pct(df):
    return (df["depois"].mean() / df["antes"].mean() - 1) * 100

var_tratada = variacao_pct(matriculas[matriculas.grupo == "tratada"])
var_perto = variacao_pct(matriculas[matriculas.grupo == "controle_perto"])
var_longe = variacao_pct(matriculas[matriculas.grupo == "controle_longe"])

efeito_perto = var_tratada - var_perto
efeito_longe = var_tratada - var_longe
indicador_canibalizacao = efeito_perto - efeito_longe

print(f"Efeito vs. controle próximo: {efeito_perto:.1f} pp")
print(f"Efeito vs. controle distante: {efeito_longe:.1f} pp")
print(f"Indicador de canibalização: {indicador_canibalizacao:.1f} pp")

## teste de permutação simples para o indicador, dado o número pequeno de unidades
def diff_efeitos(dados_perto, dados_longe, dados_tratada):
    return (
        (dados_tratada["depois"].mean() / dados_tratada["antes"].mean() - 1)
        - (dados_perto["depois"].mean() / dados_perto["antes"].mean() - 1)
    ) - (
        (dados_tratada["depois"].mean() / dados_tratada["antes"].mean() - 1)
        - (dados_longe["depois"].mean() / dados_longe["antes"].mean() - 1)
    )

```

Teste de Sample Ratio Mismatch (SRM)

Pressupõe os fundamentos de teste A/B (aleatorização, grupos, métrica primária, teste de hipótese) — veja [Fundamentos de teste A/B](#). Este documento cobre especificamente a checagem de integridade da alocação, que deve preceder qualquer leitura de efeito.

Conceito

Um teste de Sample Ratio Mismatch (SRM) verifica se a proporção observada de unidades em cada braço de um experimento é compatível com a proporção planejada na atribuição. Na essência, é um teste de aderência (goodness-of-fit): comparam-se contagens observadas contra contagens esperadas sob a proporção nominal do desenho experimental (50/50, 90/10, ou qualquer outra), usando um teste qui-quadrado — ou, de forma equivalente para dois grupos, um teste binomial exato.

A razão de ele existir como checagem separada, e não apenas como parte do teste de efeito, é que ele responde a uma pergunta lógica anterior: “a comparação entre os grupos que estou prestes a fazer é sequer válida?” Um teste de efeito bem-sucedido não tem significado nenhum se os próprios grupos comparados não foram formados da maneira que a análise assume.

Formulação matemática

Sejam k braços do experimento, com proporções planejadas $\pi_1, \pi_2, \dots, \pi_k$ (somando 1) e contagens observadas $o_1, o_2, \dots, o_k$, com total $N = \sum_i o_i$. A contagem esperada em cada braço sob a proporção planejada é:

$$e_i = \pi_i \cdot N$$

A estatística de teste qui-quadrado de aderência é:

$$\chi^2 = \sum_{i=1}^k \frac{(o_i - e_i)^2}{e_i}$$

Sob H_0 (a proporção real é a planejada), χ^2 segue aproximadamente uma distribuição qui-quadrado com $k - 1$ graus de liberdade. Para dois braços ($k = 2$), isso se reduz a 1 grau de liberdade, e o teste é equivalente a um teste binomial de duas pontas comparando o_1/N contra π_1 :

$$z = \frac{\hat{p}_1 - \pi_1}{\sqrt{\pi_1(1 - \pi_1)/N}}, \quad z^2 = \chi^2 \text{ (com 1 g.l.)}$$

onde $\hat{p}_1 = o_1/N$ é a proporção observada no primeiro braço.

Suposições

- **A proporção planejada é conhecida e fixa** — precisa ser definida explicitamente antes do experimento, não inferida a posteriori.
- **As contagens são independentes entre si** — cada unidade contribui para exatamente um braço, sem dupla contagem nem unidades compartilhadas entre braços.

- **O teste qui-quadrado assume contagens esperadas razoavelmente grandes** (regra prática comum: esperado mínimo de 5 por célula) para a aproximação assintótica ser confiável; com contagens muito pequenas, um teste binomial exato é preferível.
- **A checagem deve cobrir a população elegível completa**, não uma amostra filtrada depois da atribuição — filtrar antes de checar pode mascarar exatamente o tipo de perda diferencial que o teste deveria detectar.

Hipóteses

$$H_0 : \pi_i = \pi_i^{\text{planejado}} \text{ para todo } i \quad H_1 : \pi_i \neq \pi_i^{\text{planejado}} \text{ para pelo menos um } i$$

O nível de significância usado na prática é tipicamente mais rígido que o padrão de 0,05 usado em testes de efeito — valores como $\alpha = 0,001$ são comuns, refletindo uma assimetria de custos: um falso positivo aqui (declarar SRM quando não há) custa uma investigação; um falso negativo (não detectar um SRM real) contamina toda a leitura subsequente do experimento.

Interpretação

Um SRM significativo é evidência de que o mecanismo de atribuição, ou o processo de contagem, não está produzindo a proporção pretendida — não é, por si só, um diagnóstico da causa. As causas mais comuns incluem:

- diferenças de latência entre as versões testadas, fazendo com que uma delas descarte mais eventos por timeout antes do registro;
- filtros de bot, fraude ou qualidade de tráfego aplicados de forma assimétrica entre os braços;
- bugs no próprio código de hashing/atribuição de usuários a grupos;
- problemas de instrumentação que registram um braço de forma incompleta.

A implicação prática de um SRM detectado é direta: qualquer efeito estimado no experimento não é interpretável até a causa ser identificada e corrigida (ou até o experimento ser refeito). Isso vale mesmo que o efeito pareça “razoável” ou alinhado com a expectativa prévia da equipe — um SRM compromete a premissa fundamental de comparabilidade entre os grupos, que é justamente o que dá ao teste de efeito sua interpretação causal.

Limitações

- O teste detecta desvio na proporção agregada; ele não garante ausência de SRM em subgrupos específicos (por plataforma, por região, por canal de aquisição) — um SRM pode estar “escondido” na agregação total quando desvios em direções opostas se cancelam entre segmentos.
- Não localiza a causa — apenas sinaliza que existe um problema. A investigação subsequente (comparar logs de atribuição, taxas de perda por segmento, timing de carregamento) é um passo manual separado.
- Um SRM pode ser intermitente, presente só em parte do período do experimento; olhar a proporção observada ao longo do tempo, e não só o total acumulado ao final, ajuda a identificar isso.
- Com poucos braços e amostra muito pequena, a aproximação qui-quadrado pode não ser confiável — nesses casos, um teste binomial exato (ou exato de Fisher, para mais de dois braços) é mais apropriado.

Exemplo

Um aplicativo de assinatura planeja testar uma nova tela de onboarding em 50% dos novos usuários, mantendo os demais 50% na tela atual. Ao final de duas semanas, o time registra as seguintes contagens:

Braço	Planejado	Observado
Controle (tela atual)	50%	10.432
Tratamento (tela nova)	50%	9.568
Total	100%	20.000

Sob H_0 , o esperado em cada braço é $e = 0,5 \times 20.000 = 10.000$. A estatística qui-quadrado:

$$\chi^2 = \frac{(10.432 - 10.000)^2}{10.000} + \frac{(9.568 - 10.000)^2}{10.000} = \frac{186.624}{10.000} + \frac{186.624}{10.000} \approx 37,3$$



Dados ilustrativos, não representam nenhum projeto real.

Figura 24: Distribuição qui-quadrado de referência com 1 grau de liberdade, mostrando o valor crítico e a estatística observada

Com 1 grau de liberdade e $\chi^2 \approx 37,3$, o valor-p é extremamente pequeno — muitas ordens de grandeza abaixo do limiar de 0,001 comumente usado. A equipe pausa a leitura de qualquer efeito e investiga. Na investigação, descobre que a tela nova carrega um componente visual mais pesado, e usuários com conexão lenta estão sendo contados como “não elegíveis” com mais frequência no braço de tratamento por timeout no carregamento do experimento — uma perda diferencial de amostra que gera exatamente o padrão observado. Depois de corrigir o timeout, o experimento é reiniciado do zero, e só então a leitura de efeito é considerada confiável.

Teste de quebra estrutural (tipo Chow)

Conceito

O teste de Chow (Chow, 1960) verifica se um modelo estatístico — tipicamente uma regressão linear — tem coeficientes estáveis ao longo de toda uma série temporal, ou se esses coeficientes mudam num ponto específico, conhecido a priori. É a ferramenta canônica para responder “algo estruturalmente diferente aconteceu a partir desta data conhecida?”, em contraste com métodos de detecção de múltiplas quebras em datas desconhecidas (como Bai-Perron), que resolvem um problema mais amplo e mais exigente em termos de dados.

A lógica é a de um teste F aninhado: um modelo “restrito”, que impõe os mesmos coeficientes antes e depois da data de corte, é comparado a um modelo “irrestrito”, que permite coeficientes diferentes em cada um dos dois períodos. Se o modelo irrestrito reduz o erro de ajuste mais do que se esperaria apenas pelo ganho mecânico de ter mais parâmetros livres, isso é evidência contra a hipótese de estabilidade.

Formulação matemática

Considere o modelo de regressão linear:

$$y_t = \beta_0 + \beta_1 x_t + \varepsilon_t, \quad t = 1, \dots, n$$

Onde y_t é a variável de interesse no período t , x_t são as variáveis explicativas, β_0 e β_1 são os coeficientes a estimar, e ε_t é o erro aleatório.

Seja t^* o ponto de quebra conhecido a priori, dividindo a amostra em dois subperíodos de tamanhos n_1 (antes de t^*) e n_2 (a partir de t^*), com $n_1 + n_2 = n$.

Defina:

- RSS_p — soma dos quadrados dos resíduos (“residual sum of squares”) do modelo ajustado ao conjunto **completo** (o modelo restrito, que assume coeficientes iguais nos dois períodos).
- RSS_1 — soma dos quadrados dos resíduos do modelo ajustado apenas ao primeiro subperíodo.
- RSS_2 — soma dos quadrados dos resíduos do modelo ajustado apenas ao segundo subperíodo.
- k — número de parâmetros estimados em cada regressão (aqui, $k = 2$: intercepto e inclinação).

A estatística do teste de Chow é:

$$F = \frac{(RSS_p - (RSS_1 + RSS_2)) / k}{(RSS_1 + RSS_2) / (n - 2k)}$$

Onde:

- o numerador mede quanto o erro caiu ao permitir coeficientes diferentes nos dois períodos, ajustado pelo número de graus de liberdade adicionais usados (k);
- o denominador é o erro residual médio do modelo irrestrito, ajustado pelos graus de liberdade restantes ($n - 2k$).

Sob a hipótese nula de estabilidade dos coeficientes, F segue aproximadamente uma distribuição $F(k, n - 2k)$.

Suposições

- **A data de quebra é conhecida antes de olhar os dados.** Esta é a suposição mais importante e mais frequentemente violada na prática. Se a data for escolhida por inspeção visual da série (procurando onde ela “parece” ter mudado), o valor-p resultante não tem mais a interpretação padrão — o procedimento correto nesse caso é outro (testes de quebra desconhecida, como o supF de Andrews, ou métodos de múltiplas quebras).
- **Erros homocedásticos e não autocorrelacionados dentro de cada subperíodo,** condição padrão de regressão linear por mínimos quadrados. Quando essa suposição falha — comum em séries temporais econômicas — os erros-padrão subjacentes ao teste F podem estar incorretos; formas robustas do teste (usando erros-padrão robustos a heterocedasticidade e autocorrelação, como Newey-West) são preferíveis nesses casos.
- **Amostra mínima em cada subperíodo.** Com n_1 ou n_2 pequenos em relação a k , a estimativa em cada segmento fica instável e o teste perde poder — a capacidade de detectar uma quebra real que de fato exista cai proporcionalmente.
- **Forma funcional correta do modelo em cada período.** O teste compara a estabilidade dos coeficientes de um modelo específico (por exemplo, linear); se a relação verdadeira mudar de forma não linear que o modelo linear não capture, o teste pode não detectar uma mudança real, ou detectar uma mudança que na verdade é só um problema de especificação.

Hipóteses

- H_0 : os coeficientes β_0 e β_1 são os mesmos antes e depois de t^* — não há quebra estrutural na data testada.
- H_1 : pelo menos um dos coeficientes difere entre os dois períodos.
- Estatística de teste: F , como definida acima.
- Distribuição de referência sob H_0 : $F(k, n - 2k)$.
- Nível de significância convencional: $\alpha = 0,05$, embora o contexto (tamanho de amostra, número de testes realizados) deva informar essa escolha.
- Regra de decisão: rejeita-se H_0 (evidência de quebra) quando o valor-p associado a F é menor que α .

Interpretação

Rejeitar H_0 é evidência de que o processo gerador dos dados mudou de padrão na data testada — não necessariamente de que a data testada **causou** a mudança. O teste de Chow avalia coincidência temporal com precisão estatística, mas atribuição causal exige mais:

- **Isolamento de eventos concorrentes.** Se outro evento relevante ocorreu próximo à mesma data (uma crise cambial simultânea a uma mudança regulatória, por exemplo), o teste não distingue qual dos dois — ou se ambos, combinados — geraram a mudança observada.
- **Distinção entre mudança de nível e mudança de inclinação.** Uma quebra pode se manifestar como um salto discreto no nível da série (o intercepto muda, a inclinação permanece igual), como uma mudança na taxa de crescimento (a inclinação muda), ou como ambas simultaneamente. A especificação do teste (quais coeficientes são deixados livres antes/ depois) determina que tipo de mudança pode ser detectado — vale sempre reportar não só a significância, mas a magnitude e a direção da mudança em cada coeficiente.
- **Significância estatística não é o mesmo que magnitude relevante.** Com amostras grandes, mudanças pequenas e sem relevância prática podem gerar valores-p muito baixos. Reportar o tamanho estimado da mudança — não só o valor-p — é essencial para

uma interpretação honesta.

Limitações

- **Não é um método de detecção de quebras desconhecidas.** O teste de Chow pressupõe que t^* é dado externamente. Aplicá-lo repetidamente, testando várias datas candidatas e reportando só a mais significativa, infla seriamente a taxa de falso positivo (é, na prática, um problema de comparações múltiplas não corrigido) — para isso, o procedimento correto é um método desenhado para busca de ponto de quebra desconhecido.
- **Não controla por eventos concorrentes na mesma janela de tempo.** Um resultado significativo é compatível com múltiplas explicações causais simultâneas; o teste sozinho não separa uma da outra.
- **Sensível à especificação do modelo.** Uma forma funcional mal especificada pode gerar uma quebra “espúria” (o modelo linear se ajusta mal em ambos os períodos de forma diferente, mesmo sem mudança real no processo) ou mascarar uma quebra real.
- **Poder limitado com poucos dados em algum dos subperíodos.** Uma quebra perto do início ou do fim da série é particularmente difícil de detectar com confiança.

Exemplo

Suponha um estudo hipotético sobre a taxa de participação de um grupo demográfico específico em um programa de capacitação profissional, medida mensalmente ao longo de 40 meses. Uma nova política de incentivo, com data de início conhecida, entrou em vigor no mês 25.

Antes da política (meses 1 a 24), a taxa de participação cresce a um ritmo médio estimado de 0,15 pontos percentuais por mês. Depois da política (meses 25 a 40), o ritmo estimado sobe para 0,55 pontos percentuais por mês, e o nível médio da série também sobe de forma perceptível.

Ajustando os três modelos:

- Modelo restrito (toda a série, um único coeficiente de tendência): $RSS_p = 210,4$
- Modelo do primeiro subperíodo: $RSS_1 = 62,1$
- Modelo do segundo subperíodo: $RSS_2 = 58,7$

Com $k = 2$ e $n = 40$:

$$F = \frac{(210,4 - (62,1 + 58,7))/2}{(62,1 + 58,7)/(40 - 4)} = \frac{44,8}{3,36} \approx 4,35$$

Comparando com a distribuição $F(2, 36)$, essa estatística corresponde a um valor-p de aproximadamente 0,021 — abaixo de 0,05. Rejeita-se H_0 : há evidência estatística de que o padrão da série mudou no mês 25.


Interpretação cuidadosa: esse resultado é consistente com a política de incentivo tendo alterado o padrão da série, mas não a prova sozinho. Se, por exemplo, uma campanha de divulgação em mídia de massa também começou por volta do mês 25, por coincidência ou não, o teste de Chow, por si só, não consegue separar o efeito de uma da outra — essa separação exigiria um desenho adicional, como comparar a mesma série entre regiões que receberam a política mas não a campanha, e vice-versa.

```
import numpy as np
import statsmodels.api as sm
from scipy import stats
```

```
def teste_chow(y, x, indice_quebra):
    X = sm.add_constant(x)
    rss_p = sm.OLS(y, X).fit().ssr

    X1 = sm.add_constant(x[:indice_quebra])
    X2 = sm.add_constant(x[indice_quebra:])
    rss1 = sm.OLS(y[:indice_quebra], X1).fit().ssr
    rss2 = sm.OLS(y[indice_quebra:], X2).fit().ssr

    k = X.shape[1]
    n = len(y)
    f_stat = ((rss_p - (rss1 + rss2)) / k) / ((rss1 + rss2) / (n - 2 * k))
    p_valor = 1 - stats.f.cdf(f_stat, k, n - 2 * k)
    return f_stat, p_valor
```



Dados ilustrativos, não representam nenhum projeto real.

Figura 25: Distribuição de referência da estatística de Chow sob H0, com o valor observado

Teste t de Welch

Conceito

O teste t de Welch avalia se as médias de duas populações independentes são estatisticamente diferentes, com base em duas amostras aleatórias, sem assumir que as duas populações têm a mesma variância. É uma generalização do teste t de duas amostras de Student, que resolve a chamada questão de Behrens-Fisher: como testar diferença de médias entre duas populações normais com variâncias possivelmente diferentes e desconhecidas.

A intuição estatística central é a seguinte: a incerteza sobre uma média amostral depende de dois fatores — quanta variabilidade existe dentro do grupo, e quantas observações foram usadas para estimar essa média. Quando os dois grupos têm variâncias e tamanhos de amostra diferentes, o jeito correto de combinar essa incerteza para testar a diferença das médias não é simétrico entre os grupos, e é exatamente isso que Welch modela — sem forçar uma suposição de igualdade de variância que raramente é justificável a priori.

Formulação matemática

Sejam duas amostras independentes:

- Grupo 1: n_1 observações, média amostral $\bar{x}_1$, variância amostral s_1^2 .
- Grupo 2: n_2 observações, média amostral $\bar{x}_2$, variância amostral s_2^2 .

A estatística de teste de Welch é:

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

O numerador é a diferença observada entre as médias amostrais. O denominador é o erro-padrão dessa diferença, calculado somando a variância de cada média amostral (s_i^2/n_i) separadamente — sem combinar as duas variâncias numa única variância “conjunta” (pooled), como faz o teste de Student.

Os graus de liberdade não são $n_1 + n_2 - 2$, como no teste de Student. Em vez disso, usa-se a aproximação de Welch-Satterthwaite:

$$\nu \approx \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_2^2/n_2)^2}{n_2 - 1}}$$

O importante aqui não é decorar a fórmula, mas entender a ideia: ν é um número de graus de liberdade *efetivo*, tipicamente não inteiro, que pondera o quanto cada grupo contribui para a incerteza total do erro-padrão. Um grupo pequeno com variância alta “puxa” ν para baixo — reduzindo a confiança do teste — de um jeito mais fiel à realidade do que a contagem simples de graus de liberdade do teste de Student.

Suposições

1. **Independência:** as observações dentro de cada grupo, e entre os dois grupos, são independentes entre si. Quando há estrutura de dependência (por exemplo, várias

observações vindas da mesma unidade amostral, ou medições repetidas na mesma pessoa), a suposição é violada e o erro-padrão calculado subestima a incerteza real — nesse caso, técnicas de erro-padrão robusto a cluster são mais apropriadas.

2. **Normalidade aproximada, ou amostra grande:** o teste assume que as médias amostrais são aproximadamente normalmente distribuídas. Isso vale exatamente se os dados originais forem normais, e aproximadamente para amostras grandes, pelo Teorema Central do Limite, mesmo que os dados originais não sejam normais. Com amostras pequenas e dados muito assimétricos, a aproximação pode falhar — vale inspecionar a distribuição dos dados ou considerar alternativas não paramétricas (como o teste de Mann-Whitney) nesses casos.
3. **Não exige variâncias iguais** — essa é justamente a suposição que Welch relaxa em relação ao teste t de Student. Não há necessidade de testar igualdade de variâncias antes de escolher Welch: como Welch se reduz ao teste de Student quando as variâncias realmente são iguais (a perda de eficiência nesse caso é pequena), é seguro usar Welch como padrão, mesmo quando não se sabe se as variâncias são iguais.

Hipóteses

- H_0 : $\mu_1 = \mu_2$ (as médias populacionais são iguais).
- H_1 : $\mu_1 \neq \mu_2$ (teste bicaudal, o mais comum), ou $\mu_1 > \mu_2$ / $\mu_1 < \mu_2$ para testes unicaudais, quando há uma direção específica de interesse definida antes de olhar os dados.
- Nível de significância (α): tipicamente 0,05, mas deve ser escolhido de acordo com o contexto — em decisões de maior risco ou com múltiplas comparações simultâneas, um α mais conservador (por exemplo, 0,01) é mais apropriado.
- Estatística de teste: t , calculado como acima, comparado a uma distribuição t de Student com ν graus de liberdade.
- Valor-p: a probabilidade de observar uma estatística t tão ou mais extrema quanto a observada, assumindo que H_0 é verdadeira.
- Intervalo de confiança: um IC de 95% para a diferença $\mu_1 - \mu_2$ é dado por $(\bar{x}_1 - \bar{x}_2) \pm t_{\nu,0.975} \cdot \text{EP}$, onde EP é o erro-padrão da diferença (o denominador da estatística t) e $t_{\nu,0.975}$ é o quantil apropriado da distribuição de referência.

Interpretação

Rejeitar H_0 com um valor-p baixo é evidência estatística de que as médias populacionais diferem — não é prova, e não diz nada sobre a causa da diferença. Um teste t (de Welch ou de Student) mede associação entre pertencer a um grupo e o valor médio de uma variável; ele não isola por que essa associação existe, a menos que os grupos tenham sido definidos por uma atribuição aleatória controlada (como num experimento).

É essencial distinguir significância estatística de relevância prática. Com amostras muito grandes, diferenças de médias irrelevantes no mundo real podem ser estatisticamente significativas. Com amostras pequenas, diferenças grandes podem não atingir significância simplesmente por falta de poder estatístico. Sempre reportar o tamanho do efeito (a diferença de médias em si, na unidade original, e idealmente também um IC) ao lado do valor-p.

Limitações

- O teste compara apenas médias — duas distribuições podem ter médias iguais e formatos completamente diferentes (variância, assimetria). Se a pergunta for sobre a distribuição inteira, não só a média, métodos que olham outros pontos da distribuição (como decomposições por quantil) são mais informativos.

- Testes múltiplos: rodar Welch repetidamente sobre muitos subgrupos ou muitos períodos de tempo sem correção aumenta a chance de encontrar uma diferença “significativa” só por acaso. Em análises com muitas comparações simultâneas, vale considerar correção (por exemplo, Bonferroni ou controle de taxa de descoberta falsa).
- Amostras extremamente pequenas (por exemplo, menos de 10 observações por grupo) tornam a aproximação de Welch-Satterthwaite menos confiável — nesse regime, métodos exatos ou de permutação são preferíveis.
- O teste não lida, por si só, com dados de painel ou séries temporais correlacionadas — cada aplicação do teste assume amostras novas e independentes.

Exemplo

Considere um cenário hipotético: uma equipe de operações quer saber se o tempo médio de atendimento (em minutos) difere entre duas filiais de uma rede de atendimento, filial A e filial B, que têm volumes de chamados e processos internos diferentes.

Dados (inventados):

- Filial A: $n_1 = 40$, $\bar{x}_1 = 8,1$ min, $s_1 = 1,3$ min.
- Filial B: $n_2 = 95$, $\bar{x}_2 = 9,6$ min, $s_2 = 3,4$ min.

Passo 1 — erro-padrão da diferença:

$$EP = \sqrt{\frac{1,3^2}{40} + \frac{3,4^2}{95}} = \sqrt{0,0423 + 0,1217} \approx 0,405$$

Passo 2 — estatística t:


$$t = \frac{9,6 - 8,1}{0,405} \approx \frac{1,5}{0,405} \approx 3,10$$

Passo 3 — graus de liberdade efetivos (aplicando Welch-Satterthwaite aos mesmos números): resulta em $\nu \approx 61,4$ — um número não inteiro, puxado para baixo em relação a $n_1 + n_2 - 2 = 133$ porque a Filial B, apesar de ter mais observações, também tem muito mais variabilidade, o que reduz a confiança efetiva na comparação.

Passo 4 — valor-p: comparando $t \approx 3,10$ com $\nu \approx 61,4$ graus de liberdade produz um valor-p bicaudal bem abaixo de 0,01 — evidência forte de que a diferença observada não é apenas ruído amostral.

Passo 5 — intervalo de confiança: o IC de 95% para a diferença de médias fica aproximadamente entre 0,7 e 2,3 minutos — a Filial B provavelmente tem tempo médio de atendimento maior, e o intervalo dá uma ideia de quão grande essa diferença provavelmente é, não só de que ela existe.

A figura abaixo ilustra a distribuição de referência (a distribuição t com os graus de liberdade de Welch) e onde a estatística observada cai em relação à região crítica de 5%:



Dados ilustrativos, não representam nenhum projeto real.

Figura 26: Distribuição de referência t de Welch com a estatística observada marcada e a região crítica de 5% destacada

Bootstrap wild-cluster

Conceito

O bootstrap wild-cluster é um método de reamostragem desenvolvido especificamente para inferência em modelos de regressão com dados agrupados quando o número de clusters é pequeno — situação em que o estimador de erro-padrão robusto a cluster (CRVE) perde suas garantias assintóticas e, sistematicamente, subestima a incerteza real.

A ideia central se apoia em duas escolhas de desenho:

1. **Reamostrar resíduos, não observações ou clusters inteiros.** Um bootstrap de cluster convencional sorteia clusters inteiros com reposição — o que, com poucos clusters, produz réplicas com repetições grosseiras (por exemplo, um cluster aparecendo três vezes e outro nenhuma) e um espaço amostral efetivamente pequeno demais para formar uma boa distribuição de referência.
2. **Perturbar por sinal aleatório, preservando a estrutura de dependência dentro do cluster.** Em vez de reamostrar, o método mantém todas as observações originais e multiplica os resíduos de cada cluster por um único valor aleatório sorteado para aquele cluster (tipicamente $+1$ ou -1 , a “distribuição de Rademacher”) — preservando exatamente o padrão de correlação dentro de cada cluster, porque todas as observações daquele cluster são perturbadas em bloco, na mesma direção.

Formulação matemática

Considere o modelo linear com G clusters:

$$Y_{ig} = X'_{ig}\beta + \varepsilon_{ig}, \quad g = 1, \dots, G$$

O interesse é testar $H_0 : \beta_j = \beta_j^0$ (frequentemente $\beta_j^0 = 0$) para um coeficiente específico β_j .

Passo 1 — ajuste restrito. Estima-se o modelo impondo H_0 (o modelo “restrito”), obtendo resíduos $\tilde{u}_{ig}$ e valores ajustados $\tilde{Y}_{ig}$ sob a restrição.

Passo 2 — perturbação por sinal. Para cada réplica $b = 1, \dots, B$, sorteia-se um sinal $v_g^{(b)} \in \{-1, +1\}$ **por cluster** (não por observação), geralmente com probabilidade 1/2 para cada valor:

$$v_g^{(b)} \sim \text{Rademacher}(0,5)$$

Passo 3 — dados sintéticos. Constrói-se uma variável dependente sintética:

$$Y_{ig}^{*(b)} = \tilde{Y}_{ig} + v_g^{(b)} \tilde{u}_{ig}$$

Note que $v_g^{(b)}$ não varia dentro do cluster g — todas as observações daquele cluster recebem o mesmo sinal naquela réplica, preservando a correlação intra-cluster.

Passo 4 — reajuste e estatística. Reajusta-se o modelo (irrestrito) aos dados sintéticos $Y^{*(b)}$, obtendo $\hat{\beta}_j^{*(b)}$ e seu erro-padrão robusto a cluster $\widehat{SE}^{*(b)}(\hat{\beta}_j)$, formando a estatística bootstrap:

$$t^{*(b)} = \frac{\hat{\beta}_j^{*(b)} - \beta_j^0}{\widehat{SE}^{*(b)}(\hat{\beta}_j)}$$

Passo 5 — valor-p. Repetindo os passos 2 a 4 para B réplicas (tipicamente $B = 999$), o valor-p bootstrap é:

$$p^* = \frac{1}{B} \sum_{b=1}^B \mathbb{1} [|t^{*(b)}| \geq |t_{\text{obs}}|]$$

com t_{obs} a estatística t calculada nos dados reais (sob o modelo irrestrito), usando erro-padrão robusto a cluster convencional.

Com G clusters, existem no máximo 2^G combinações distintas de sinais — em $G = 6$, por exemplo, 64 combinações, o que ainda deixa um valor-p com granularidade razoável mesmo enumerando exaustivamente em vez de sortear.

Suposições

- **Modelo corretamente especificado sob H_0 .** O ajuste restrito, usado para gerar os resíduos perturbados, precisa refletir razoavelmente a relação real entre as variáveis — um modelo mal especificado produz resíduos que não representam bem a verdadeira estrutura de erro.
- **Independência entre clusters.** Como no CRVE, a validade do método depende de os clusters serem independentes entre si — dependência residual entre clusters não é corrigida pelo bootstrap wild-cluster.
- **Simetria da distribuição dos sinais.** A escolha padrão de sinais Rademacher (+1/−1 com igual probabilidade) funciona bem na maioria dos casos; distribuições alternativas de sinal existem na literatura, mas a Rademacher é a mais usada por robustez e simplicidade.
- **Número mínimo de clusters.** Com clusters extremamente poucos (2 ou 3), mesmo o espaço de 2^G sinais possíveis fica pequeno demais para formar uma distribuição de referência útil — o método continua superior ao CRVE assintótico nesse extremo, mas com garantias mais fracas.

Hipóteses

- H_0 : $\beta_j = \beta_j^0$ (comumente $\beta_j^0 = 0$, “o coeficiente é nulo”).
- H_1 : $\beta_j \neq \beta_j^0$.
- Estatística de teste: $t = (\hat{\beta}_j - \beta_j^0) / \widehat{SE}_{\text{cluster}}(\hat{\beta}_j)$, calculada nos dados reais e comparada à distribuição empírica de $t^{*(b)}$ gerada pelo bootstrap, em vez de a uma distribuição t teórica.
- Intervalo de confiança: pode ser obtido invertendo o teste (buscando o intervalo de valores de β_j^0 que não são rejeitados pelo teste bootstrap), abordagem mais trabalhosa computacionalmente, mas mais precisa que aproximar o intervalo a partir dos percentis diretos da distribuição de $\hat{\beta}_j^{*(b)}$.

Interpretação

Um valor-p bootstrap wild-cluster baixo é evidência de que a estatística observada seria incomum mesmo sob a variação simulada consistente com a hipótese nula e com a estrutura de dependência real dos dados — uma leitura mais confiável que a do CRVE assintótico justamente na faixa de poucos clusters em que este último costuma falhar.

Como em qualquer método de correção de inferência, o bootstrap wild-cluster não resolve problemas de identificação causal do desenho original (variável omitida, seleção não aleatória) — ele apenas produz uma distribuição de referência mais fiel para testar hipóteses sobre o coeficiente estimado, dado que o modelo e o desenho já são válidos por outros motivos.

Limitações

- **Ainda depende de um número mínimo de clusters úteis.** Com G muito pequeno (2 ou 3), o espaço de 2^G sinais possíveis é pequeno demais para formar uma boa distribuição — nesse extremo, inferência por randomização, quando aplicável ao desenho, costuma ser preferível.
- **Sensibilidade à escolha do modelo restrito.** Resíduos de um modelo mal ajustado sob H_0 propagam esse erro de especificação para toda a distribuição bootstrap.
- **Custo computacional.** Cada réplica exige reajustar o modelo — com B na casa dos milhares e modelos complexos, o custo total pode ser significativo, embora seja tipicamente viável em problemas de escala aplicada usual.

Comparação com outros métodos de inferência com poucos clusters

Bootstrap wild-cluster, erros-padrão robustos a cluster e inferência por randomização respondem ao mesmo problema: inferência confiável quando observações dentro de um cluster não são independentes e há poucos clusters disponíveis.

- **Erros-padrão robustos a cluster (CRVE)** são a opção padrão, simples e rápida, mas perdem confiabilidade justamente quando há poucos clusters — o cenário em que o bootstrap wild-cluster e a inferência por randomização se tornam relevantes.
- **Inferência por randomização** é preferível quando o próprio mecanismo de sorteio do experimento é conhecido e simples o suficiente para enumerar (ou amostrar) diretamente as reatribuições possíveis — não exige ajustar nenhum modelo de regressão, apenas recalcular uma estatística sob reatribuições do tratamento. Funciona melhor quando o efeito de interesse vem de uma comparação direta entre grupos, sem controles adicionais.
- **Bootstrap wild-cluster** é a escolha mais natural quando o efeito de interesse vem de um modelo de regressão com controles ou estrutura mais rica (efeitos fixos, covariáveis), onde não há um mecanismo de sorteio simples para reatribuir diretamente — o bootstrap perturba os resíduos do modelo já ajustado, em vez de reatribuir tratamento a unidades.


Quando os dois métodos são aplicáveis ao mesmo problema, rodar ambos e comparar as conclusões é uma checagem de robustez valiosa: concordância entre inferência por randomização e bootstrap wild-cluster reforça a confiança no resultado; discordância é um sinal de que vale a pena investigar mais a fundo antes de reportar uma conclusão.

Exemplo

Uma rede de clínicas testa um novo protocolo de agendamento em 8 unidades (4 tratamento, 4 controle), medindo tempo médio de espera do paciente, com controles adicionais no modelo

(dia da semana, horário). O coeficiente estimado do tratamento é $-6,5$ minutos, com erro-padrão robusto a cluster convencional de $2,1$, dando $t \approx -3,1$ e um valor-p assintótico de aproximadamente $0,003$ (aparentemente muito significativo).

Rodando o bootstrap wild-cluster com $B = 999$ réplicas sobre os 8 clusters (sorteando sinais Rademacher por clínica em cada réplica, reajustando o modelo restrito e recalculando a estatística t a cada vez), a estatística observada de $-3,1$ cai no percentil correspondente a um valor-p bootstrap de aproximadamente $0,04$ — ainda significativo a 5%, mas com margem bem mais apertada do que o valor-p assintótico de $0,003$ sugeria.



Dados ilustrativos, não representam nenhum projeto real.

Figura 27: Distribuição wild-cluster bootstrap de 999 réplicas comparada à referência t assintótica, para um desenho com poucos clusters

A diferença entre os dois valores-p ($0,003$ vs. $0,04$) ilustra por que o CRVE assintótico tende a ser excessivamente otimista com poucos clusters — a conclusão qualitativa (efeito significativo) se mantém neste exemplo, mas a margem de confiança real é bem mais estreita do que a primeira leitura sugeria, e um resultado ligeiramente mais fraco poderia facilmente deixar de ser significativo sob a correção wild-cluster.

Tendência por mínimos quadrados ponderados com classificação por intervalo de confiança

Conceito

Mínimos quadrados ponderados (*Weighted Least Squares*, WLS) é uma extensão da regressão linear comum (OLS, *Ordinary Least Squares*) que permite atribuir pesos diferentes a cada observação ao ajustar uma reta. No contexto de análise de tendência ao longo do tempo, o uso mais comum é ponderar cada período pelo número de observações (tamanho de amostra) que sustentam a métrica medida naquele período — reconhecendo explicitamente que um ponto calculado a partir de 400 casos é uma estimativa mais precisa (tem menor variância) do que um ponto calculado a partir de 20 casos, e portanto deve ter mais influência sobre a reta ajustada.

A motivação estatística é a de heterocedasticidade conhecida: quando a variância do erro de medição de cada ponto não é constante, mas é aproximadamente proporcional ao inverso do tamanho de amostra daquele ponto (um resultado direto da lei dos grandes números — a variância de uma média amostral é σ^2/n), OLS ainda produz estimativas não-viesadas do coeficiente angular, mas deixa de ser o estimador de menor variância possível (deixa de ser BLUE — *Best Linear Unbiased Estimator*, segundo o teorema de Gauss-Markov generalizado). WLS, usando pesos proporcionais a n , restaura essa propriedade de eficiência.

A segunda parte do método — a **classificação da tendência** — converte a inclinação estimada e seu intervalo de confiança em um rótulo categórico (subindo / caindo / estável) usando uma regra simples e determinística: a posição do intervalo de confiança em relação a zero. Essa regra é equivalente, em termos formais, a um teste de hipótese bilateral sobre o coeficiente angular a um nível de significância correspondente ao IC escolhido.

Formulação matemática

Modelo. Para uma unidade (loja, jogador, região) com observações em T períodos, o modelo de tendência linear ponderada é

$$y_t = \alpha + \beta t + \varepsilon_t, \quad t = 1, \dots, T$$

onde y_t é a métrica observada no período t , α é o intercepto, β é a inclinação (a quantidade de interesse — a tendência), e ε_t é o erro, com $\text{Var}(\varepsilon_t) = \sigma^2/w_t$, sendo w_t o peso do período t — tipicamente $w_t = n_t$, o número de observações que compõem y_t .

Estimador WLS. Os coeficientes que minimizam a soma ponderada dos quadrados dos resíduos,

$$\hat{\alpha}, \hat{\beta} = \arg \min_{\alpha, \beta} \sum_{t=1}^T w_t (y_t - \alpha - \beta t)^2$$

têm solução fechada análoga à de OLS, mas com as médias e produtos ponderados pelos pesos:

$$\hat{\beta} = \frac{\sum_t w_t (t - \bar{t}_w)(y_t - \bar{y}_w)}{\sum_t w_t (t - \bar{t}_w)^2}, \quad \hat{\alpha} = \bar{y}_w - \hat{\beta} \bar{t}_w$$

onde $\bar{t}_w = \frac{\sum_t w_t t}{\sum_t w_t}$ e $\bar{y}_w = \frac{\sum_t w_t y_t}{\sum_t w_t}$ são as médias ponderadas de t e y .

Erro-padrão da inclinação. Sob a suposição de que os pesos capturam corretamente a estrutura de variância, o erro-padrão de $\hat{\beta}$ é

$$SE(\hat{\beta}) = \sqrt{\frac{\hat{\sigma}^2}{\sum_t w_t (t - \bar{t}_w)^2}}, \quad \hat{\sigma}^2 = \frac{\sum_t w_t (y_t - \hat{\alpha} - \hat{\beta}t)^2}{T - 2}$$

com $T - 2$ graus de liberdade (dois parâmetros estimados: α e β).

Intervalo de confiança e classificação. O intervalo de confiança de $(1 - \alpha_{\text{sig}}) \times 100\%$ para β é

$$\hat{\beta} \pm t_{T-2, 1-\alpha_{\text{sig}}/2}^* \times SE(\hat{\beta})$$

onde t^* é o valor crítico da distribuição t de Student com $T - 2$ graus de liberdade. A regra de classificação é:

$$\text{Tendência} = \begin{cases} \text{subindo} & \text{se o limite inferior do IC} > 0 \\ \text{caindo} & \text{se o limite superior do IC} < 0 \\ \text{estável} & \text{se o IC contém zero} \end{cases}$$

Essa regra é matematicamente equivalente a rejeitar (ou não) $H_0 : \beta = 0$ em favor de $H_1 : \beta \neq 0$ ao nível de significância α_{sig} , e depois usar o sinal de $\hat{\beta}$ quando H_0 é rejeitada para decidir entre “subindo” e “caindo”.

Suposições

- **Os pesos refletem corretamente a precisão relativa de cada ponto.** Usar n_t (número de observações) como peso pressupõe que a variância de y_t é aproximadamente proporcional a $1/n_t$ — válido quando y_t é, ela mesma, uma média ou proporção calculada sobre n_t casos com variância individual razoavelmente constante entre períodos. Se a variabilidade individual dentro de cada período também mudar ao longo do tempo, os pesos ideais não são simplesmente n_t .
- **Linearidade.** A tendência subjacente é modelada como uma reta; tendências com curvatura relevante (aceleração, desaceleração, sazonalidade não removida) são mal capturadas por esse modelo simples, e a classificação subindo/caindo/estável pode não refletir o comportamento real da série.
- **Erros não correlacionados entre períodos, condicional aos pesos.** Se houver autocorrelação temporal residual (por exemplo, um trimestre bom tende a ser seguido por outro trimestre bom, além do que a tendência linear já captura), os erros-padrão calculados por WLS padrão subestimam a incerteza real — nesse caso, erros-padrão robustos a autocorrelação (Newey-West) são mais apropriados.
- **Ausência de outliers estruturais não relacionados à tendência.** Um único período com valor extremo (mesmo que baseado em muitas observações, e portanto com peso alto) pode distorcer a inclinação estimada mais do que seria razoável; vale inspecionar visualmente antes de confiar cegamente na classificação automática.

Hipóteses

- $H_0 : \beta = 0$ — não há tendência linear (a métrica não varia sistematicamente ao longo do tempo, dada a precisão ponderada dos dados disponíveis).

- $H_1 : \beta \neq 0$ — existe tendência linear (positiva ou negativa).

Nível de significância tipicamente usado: 5% (correspondente a IC de 95%), embora a escolha do nível seja uma decisão editorial/operacional — um nível mais permissivo (10%) classifica mais séries como tendência definida (menos “estável”), ao custo de mais falsos positivos; um nível mais rígido (1%) faz o oposto.

Interpretação

A inclinação $\hat{\beta}$ quantifica a mudança média estimada na métrica por unidade de tempo (por trimestre, por exemplo), sob a suposição de linearidade. A classificação subindo/caindo/estável é uma tradução operacional simplificada dessa inclinação e de sua incerteza — não uma afirmação sobre a causa da tendência. Uma tendência de alta estatisticamente confirmada não diz por que a métrica está subindo (mudança de mix, sazonalidade, ação deliberada, fator externo); apenas que a evidência estatística é suficiente para distinguir a inclinação de zero, dado o volume de dados disponível.

É importante comunicar “estável” corretamente: significa ausência de evidência suficiente para uma tendência definida, não prova de que a métrica realmente não mudou. Séries curtas (poucos períodos) ou com poucos dados por período tendem a produzir mais classificações “estável” simplesmente por falta de poder estatístico, mesmo quando existe uma tendência real subjacente.

Limitações

- **Sensibilidade ao nível de confiança escolhido.** Diferentes escolhas de IC (90%, 95%, 99%) produzem diferentes classificações para os mesmos dados, especialmente em séries com inclinação próxima da fronteira de significância — vale relatar a inclinação e seu IC completo, não só o rótulo categórico.
- **Poder estatístico limitado com poucos períodos.** Com T pequeno (três, quatro pontos), o intervalo de confiança tende a ser largo mesmo com pesos altos, dificultando distinguir uma tendência real e pequena de ruído.
- **Modelo linear pode ser inadequado para padrões não lineares.** Uma métrica que sobe e depois estabiliza (curva em S) pode ser classificada como “subindo” globalmente mesmo já tendo se estabilizado nos períodos mais recentes — vale complementar com inspeção visual ou um modelo de tendência local (ex.: regressão local, splines) quando o padrão for suspeito.
- **Multiplicidade de testes.** Classificar a tendência de muitas unidades simultaneamente (centenas de lojas, por exemplo) ao nível de significância de 5% cada gera, por acaso, um número esperado de classificações “subindo” ou “caindo” espúrias — se o objetivo for identificar as unidades verdadeiramente atípicas, vale considerar correção para comparações múltiplas.

Exemplo

Considere duas lojas fictícias de uma rede de varejo, cada uma com doze trimestres de dados de ticket médio, com número de transações (peso) variando substancialmente entre trimestres — uma situação comum quando alguns trimestres coincidem com datas promocionais de alto volume e outros são períodos de baixa.


Loja A — ticket médio subindo de forma consistente, com peso amostral alto na maioria dos trimestres. Ajuste WLS: $-\hat{\beta} = 2,40$ (reais por trimestre) - $SE(\hat{\beta}) = 0,58$ - $t_{10,0.975}^* \approx 2,23$ - IC 95%: $2,40 \pm 2,23 \times 0,58 = [1,11; 3,69]$

Como o limite inferior (1,11) é maior que zero, a Loja A é classificada como **subindo**.

Loja B — ticket médio oscilando sem padrão claro, com vários trimestres de baixo peso amostral. Ajuste WLS: $\hat{\beta} = 0,05$ - $SE(\hat{\beta}) = 0,56$ - IC 95%: $0,05 \pm 2,23 \times 0,56 = [-1,20; 1,30]$


Como o intervalo contém zero, a Loja B é classificada como **estável** — apesar de a inclinação pontual ser tecnicamente positiva, não há evidência estatística suficiente, dado o padrão de precisão amostral observado, para distingui-la de zero.

Contraste com OLS não ponderado. Se os mesmos dados da Loja B fossem ajustados sem ponderação (OLS simples), os poucos trimestres de baixo volume — que por acaso apresentam valores mais extremos — teriam peso igual aos trimestres de alto volume, potencialmente produzindo uma inclinação estimada bem diferente (e um erro-padrão que não reflete corretamente a precisão desigual dos pontos). É exatamente esse tipo de distorção que a ponderação por tamanho de amostra existe para corrigir.



Dados ilustrativos, não representam nenhum projeto real.

Figura 28: Classificação de tendência ponderada para duas lojas



Dados ilustrativos, não representam nenhum projeto real.

Figura 29: OLS vs. WLS quando o tamanho de amostra varia fortemente entre períodos