

Visão Geral — Todas as Metodologias

Sumário

Visão geral — todas as metodologias, em linguagem simples

Este documento explica, sem fórmulas e sem jargão desnecessário, cada metodologia estatística usada no portfólio. A ideia é simples: você não precisa saber estatística para entender **que pergunta cada método responde** e **o que ele te permite concluir** — e, tão importante quanto isso, **o que ele não te permite concluir**.

Cada seção segue o mesmo roteiro: uma pergunta concreta, a ideia por trás do método, o que o resultado quer dizer, e um limite importante.

Para uma explicação mais detalhada de qualquer um destes métodos, veja a pasta [metodologias/](#) (nível intermediário) ou [completo/](#) (nível técnico completo).

1. Teste t de Welch

A pergunta: dois grupos têm médias diferentes numa amostra. Essa diferença é provavelmente real, ou pode ter surgido só por acaso, por causa da variação natural de quem calhou de estar em cada amostra?

A ideia: se você sorteasse repetidamente pequenas amostras de duas populações que na verdade têm a mesma média, ainda assim as médias amostrais quase nunca saíam idênticas. O teste mede o quão incomum é a diferença que você observou, dado o tamanho das amostras e a variabilidade dentro de cada grupo — sem exigir que os dois grupos tenham a mesma variabilidade interna, o que o torna mais seguro que a versão clássica (Student) quando os grupos são desiguais em tamanho ou dispersão.

O que o resultado significa: um valor-p baixo diz que uma diferença desse tamanho seria rara se, na população, as médias fossem realmente iguais. Isso é evidência a favor de uma diferença real — não prova de que ela seja grande ou importante na prática.

O que ele não diz: por que a diferença existe, nem se ela é causada por alguma coisa específica.

2. Decomposição de Oaxaca-Blinder

A pergunta: dois grupos ganham salários diferentes, em média. Quanto dessa diferença vem do fato de os grupos terem, em média, características diferentes (mais ou menos anos de estudo, por exemplo), e quanto sobra mesmo depois de levar essas características em conta?

A ideia: o método ajusta um modelo estatístico que relaciona salário a características observáveis para cada grupo separadamente, depois pergunta: “se o Grupo B tivesse as

mesmas características do Grupo A, mas continuasse sendo pago do seu próprio jeito, qual seria a diferença esperada?” Isso separa o gap em uma parte **explicada** (diferença de características) e uma parte **não explicada** (o que sobra).

O que o resultado significa: a parte não explicada é o que não pode ser atribuído às características medidas. Ela é, com frequência, interpretada como um sinal possível de discriminação — mas essa conclusão exige suposições muito mais fortes do que o método sozinho garante: pode haver características relevantes que simplesmente não foram medidas.

O que ele não diz: o método não prova causalidade nem isola discriminação — ele decompõe uma diferença observada, não explica sua origem causal.

3. Decomposição por RIF (Recentered Influence Function)

A pergunta: o Oaxaca-Blinder decompõe a diferença nas **médias**. E se a diferença entre grupos não for igual em todos os pontos da distribuição — se for maior entre quem ganha pouco, ou entre quem ganha muito?

A ideia: em vez de olhar só a média, o método permite decompor a diferença em qualquer ponto da distribuição — por exemplo, na mediana, ou no percentil 90. Ele faz isso transformando cada observação numa medida de “quanto ela contribui” para aquele ponto específico da distribuição, e depois aplica a mesma lógica do Oaxaca-Blinder sobre essa medida transformada.

O que o resultado significa: permite enxergar padrões que a média esconde — por exemplo, um gap pequeno no meio da distribuição mas grande nas pontas.

O que ele não diz: cada ponto da distribuição é estimado com sua própria margem de erro, geralmente maior nas pontas (onde há menos dados) — resultados ali merecem mais cautela.

4. Decomposição de desigualdade (Theil, Gini, quantis ponderados)

A pergunta: quanto da desigualdade total de uma variável (renda, por exemplo) vem de diferenças **entre** grupos, e quanto vem de diferenças **dentro** de cada grupo?

A ideia: o índice de Theil tem uma propriedade matemática útil chamada decomponibilidade exata: a desigualdade total pode ser separada, sem sobras, em uma parcela “entre grupos” e uma parcela “dentro dos grupos”. O Gini mede concentração dentro de um grupo (quão distante aquele grupo está de uma distribuição perfeitamente igual). Quantis ponderados estimam, dentro de cada grupo, valores de corte como “o que caracteriza os 10% mais ricos daquele grupo”.

O que o resultado significa: é comum, em recortes demográficos amplos como raça ou gênero, que a maior parte da desigualdade total esteja dentro de cada grupo — isso não diminui a importância de um gap entre grupos que seja grande e estatisticamente significativo; apenas mostra que a desigualdade tem várias fontes ao mesmo tempo.

O que ele não diz: um Gini mais baixo num grupo não significa necessariamente “situação melhor” — pode só refletir uma distribuição mais comprimida perto da base.

5. Índice de dissimilaridade de Duncan

A pergunta: dois grupos estão distribuídos de forma parecida entre diferentes categorias (ocupações, por exemplo), ou um grupo está concentrado em certas categorias enquanto o outro está em outras?

A ideia: o índice mede, essencialmente, qual fração de um dos grupos precisaria “trocar de categoria” para que as duas distribuições ficassem idênticas. Um valor de zero significa distribuições idênticas; um valor de um (ou 100%) significa segregação completa.

O que o resultado significa: um índice alto indica que os grupos raramente ocupam as mesmas categorias — um sinal de segregação ocupacional, por exemplo.

O que ele não diz: o índice não diz por que a segregação existe, nem distingue entre concentração voluntária, barreiras de acesso, ou diferenças de qualificação.

6. Teste de quebra estrutural

A pergunta: uma série ao longo do tempo mudou de padrão num momento específico e conhecido — um evento, uma lei, uma crise?

A ideia: o método compara o comportamento da série antes e depois de uma data pré-definida, testando se os dois pedaços parecem vir do mesmo processo ou de processos diferentes.

O que o resultado significa: uma quebra significativa é evidência de que algo mudou naquele momento — mas, se vários eventos aconteceram perto um do outro (uma pandemia perto de uma reforma, por exemplo), o teste não consegue sozinho dizer qual dos dois causou a mudança.

O que ele não diz: isso é evidência de correlação temporal, não de causalidade — e um teste que olha só uma data pré-definida não é uma busca por quebras desconhecidas em qualquer ponto da série.

7. Diferenças-em-diferenças

A pergunta: uma política ou evento teve efeito causal sobre um grupo afetado, comparado a um grupo não afetado?

A ideia: compara a mudança ao longo do tempo no grupo afetado com a mudança ao longo do tempo no grupo não afetado. Se os dois grupos já vinham seguindo trajetórias parecidas antes do evento (as chamadas “tendências paralelas”), a diferença nas mudanças pode ser atribuída ao evento. Testes de placebo aplicam o mesmo raciocínio a datas falsas — se aparecer um “efeito” mesmo numa data sem mudança real de política, isso é sinal de alerta.

O que o resultado significa: quando as tendências paralelas se sustentam e o desenho é bem executado, o método tem uma leitura causal — mais forte que uma simples comparação antes/depois.

O que ele não diz: “não encontramos efeito” não é o mesmo que “não há efeito” — um desenho com poucos pontos de dado, ou amostra pequena, pode simplesmente não ter força estatística para detectar um efeito real.

8. Análise de transições em painel

A pergunta: as pessoas de um grupo saem do desemprego, ou entram na formalidade, mais rápido ou mais devagar que as de outro grupo?

A ideia: algumas pesquisas domiciliares entrevistam a mesma pessoa mais de uma vez ao longo do tempo. Isso permite acompanhar transições individuais reais (desempregado → empregado, por exemplo), em vez de só comparar retratos isolados de momentos diferentes.

O que o resultado significa: taxas de transição diferentes entre grupos mostram diferenças de mobilidade real, não só de composição num único momento.

O que ele não diz: o pareamento entre entrevistas de uma mesma pessoa pode falhar (troca de morador no domicílio, por exemplo) — a taxa de sucesso do pareamento importa para a confiabilidade do resultado.

9. Testes A/B

A pergunta: uma mudança específica (num produto, num processo) realmente melhora o resultado que importa, ou o que parece melhora é só ruído?

A ideia: divide-se aleatoriamente um grupo de pessoas em dois — metade vê a versão nova, metade continua na versão antiga — e compara-se o resultado médio entre os dois grupos, com um teste de significância e um intervalo de confiança em volta do efeito estimado.

O que o resultado significa: como a divisão é aleatória, uma diferença significativa entre os grupos pode ser atribuída à mudança testada, não a outras diferenças entre as pessoas.

O que ele não diz: só vale se a randomização realmente funcionou — daí a importância de sempre checar isso antes de confiar no resultado (ver o próximo item).

10. Teste de Sample Ratio Mismatch (SRM)

A pergunta: a divisão entre os grupos do experimento realmente saiu como planejada?

A ideia: se você planejou 50/50 mas o sistema, por algum bug, colocou 55% das pessoas num grupo e 45% no outro, isso é sinal de que algo quebrou na randomização — e qualquer efeito medido a partir daí não é confiável.

O que o resultado significa: um SRM significativo é um alarme: pare e investigue antes de interpretar qualquer resultado do experimento.

O que ele não diz: o teste detecta que a proporção está errada, não diz automaticamente por quê — isso exige investigação separada.

11. Checagem de balanceamento e ajuste por covariáveis

A pergunta: os dois grupos do experimento eram realmente parecidos antes de a mudança ser aplicada?

A ideia: compara-se características que já existiam antes do experimento (idade, histórico de uso, por exemplo) entre os dois grupos. Se estiverem parecidas, a randomização funcionou. Essas mesmas características também podem ser usadas para “limpar” um pouco do ruído da estimativa de efeito, deixando-a mais precisa.

O que o resultado significa: grupos balanceados dão mais confiança de que qualquer diferença de resultado veio da mudança testada, não de uma diferença prévia entre os grupos.

O que ele não diz: balanceamento nas características medidas não garante balanceamento em características não medidas.

12. Teste de não-inferioridade

A pergunta: uma métrica de segurança ou risco (por exemplo, taxa de fraude) não piorou além de um limite aceitável?

A ideia: ao contrário de um teste comum, que pergunta “há alguma diferença?”, este pergunta apenas “essa métrica não piorou mais do que X?” — numa única direção.

O que o resultado significa: quando o teste passa, há evidência de que a métrica se manteve dentro do aceitável. Quando não passa, não significa necessariamente que a métrica piorou muito — significa que não há evidência suficiente de que ficou dentro da margem combinada.

O que ele não diz: a escolha da margem aceitável é uma decisão de negócio, não estatística — o teste não diz qual margem é “certa”.

13. Teste de heterogeneidade (interação) e efeito de novidade

A pergunta: o efeito de uma mudança é igual para todo mundo, ou maior para alguns subgrupos? E o efeito se mantém ao longo do tempo, ou é só um “efeito novidade” que passa?

A ideia: um teste formal de interação verifica se a diferença de efeito entre subgrupos é grande o suficiente para não ser só ruído amostral. Olhar o efeito ao longo das semanas depois do lançamento mostra se ele decai.

O que o resultado significa: encontrar um efeito concentrado num subgrupo específico muda a decisão prática — pode-se lançar só para aquele subgrupo, em vez de para todos.

O que ele não diz: testar muitos subgrupos aumenta a chance de encontrar uma diferença “significativa” por acaso — um resultado de heterogeneidade isolado merece mais cautela do que um confirmado por várias fontes de evidência.

14. Erros-padrão robustos a cluster

A pergunta: e se as observações dentro de um mesmo grupo (uma loja, uma região, uma unidade de pesquisa) não forem realmente independentes entre si?

A ideia: o cálculo comum de erro-padrão assume que cada observação é independente. Quando várias observações vêm do mesmo cluster e se parecem entre si, tratar todas como independentes faz o erro-padrão parecer menor do que realmente é. O ajuste por cluster corrige isso.

O que o resultado significa: com o ajuste, o intervalo de confiança fica mais largo (e mais honesto) do que seria sem ele.

O que ele não diz: com poucos clusters, mesmo o erro-padrão ajustado pode não ser confiável — aí entram métodos alternativos (itens 15 e 16).

15. Inferência por randomização

A pergunta: com poucos grupos no experimento (poucas lojas, poucas regiões), como confiar num valor-p calculado da forma tradicional?

A ideia: em vez de assumir uma fórmula teórica, o método reembaralha as atribuições de tratamento/controle entre os grupos de todas as formas possíveis (ou muitas delas), calculando o efeito em cada reembaralhamento. O valor-p vem de comparar o efeito observado com essa distribuição de efeitos “se a atribuição tivesse sido outra”.

O que o resultado significa: é uma forma de inferência que não depende de suposições sobre a distribuição dos dados — só da aleatoriedade da própria atribuição.

O que ele não diz: exige que a atribuição ao tratamento tenha sido de fato aleatória.

16. Bootstrap wild-cluster

A pergunta: outra forma de fazer inferência confiável com poucos clusters.

A ideia: em vez de reamostrar clusters inteiros (o que funciona mal quando há poucos), o método reamostra os resíduos do modelo, multiplicando-os por sinais aleatórios (+1 ou -1) por cluster, e reconstrói a estatística de teste muitas vezes para formar uma distribuição de referência.

O que o resultado significa: costuma concordar com a inferência por randomização quando ambos são aplicáveis — usar mais de um método e ver se concordam é uma forma de checar a robustez da conclusão.

O que ele não diz: ainda depende de algumas suposições sobre o modelo ajustado, mesmo sendo mais robusto que a fórmula clássica.

17. Poder estatístico e Efeito Mínimo Detectável (MDE)

A pergunta: antes de rodar um experimento, qual é o menor efeito que ele tem chance real de detectar?

A ideia: depende do tamanho da amostra, da variabilidade da métrica e do nível de confiança desejado. Calcular isso antes evita rodar um experimento caro que nunca teria conseguido enxergar um efeito do tamanho que interessa.

O que o resultado significa: um MDE alto (comparado ao efeito que você esperaria de forma realista) é um sinal de que o experimento, do jeito que está desenhado, provavelmente não vai dar uma resposta útil.

O que ele não diz: não detectar efeito num experimento com MDE alto não significa que não há efeito — só que o desenho não tinha força para ver.

18. Transbordamento espacial (canibalização)

A pergunta: o efeito positivo medido numa área tratada é ganho real, ou é atividade “roubada” de áreas vizinhas de controle?

A ideia: compara áreas de controle que ficam perto de áreas tratadas com áreas de controle mais distantes — se as próximas tiverem resultado pior, isso sugere que parte do “efeito” positivo é só deslocamento, não criação líquida.

O que o resultado significa: ajuda a estimar o efeito líquido real de uma intervenção, não só o efeito local aparente.

O que ele não diz: isolar completamente o transbordamento é difícil — o método dá uma estimativa aproximada, não uma medição exata.

19. Decomposição de coorte / retenção

A pergunta: por que uma métrica agregada mudou de repente — o que especificamente está causando isso?

A ideia: em vez de olhar só o número agregado, separa-se a base em subgrupos (coortes de entrada, segmentos, canais) e compara-se como cada um contribuiu para a mudança — muitas vezes revelando que várias causas sobrepostas, não uma só, explicam o total.

O que o resultado significa: permite agir sobre a causa específica, em vez de reagir ao sintoma agregado.

O que ele não diz: a decomposição é descritiva — dizer que um subgrupo “contribuiu mais” não prova que ele foi a causa raiz sem investigação adicional.

20. Decomposição de crescimento

A pergunta: o crescimento de um negócio veio de expansão para novos lugares/produtos, ou de melhora real no que já existia?

A ideia: separa o crescimento total em uma parte de expansão (novos mercados, novas lojas) e uma parte “comparável” (crescimento no que já existia há tempo suficiente para comparação justa) — e depois, dentro do comparável, separa quanto veio de preço, quanto veio de volume e quanto veio de mudança no mix de produtos vendidos.

O que o resultado significa: um crescimento total impressionante pode esconder uma base madura estagnada ou até encolhendo.

O que ele não diz: a decomposição não diz se a estratégia de expansão foi uma boa escolha — só separa de onde o número total veio.

21. Regressão de Poisson (contagens, com efeitos fixos)

A pergunta: o que explica quantos gols um time marca — força do próprio ataque, força da defesa adversária, e o fato de jogar em casa ou fora?

A ideia: para variáveis de contagem (número de eventos, como gols), a regressão de Poisson modela essa contagem em função de fatores explicativos. Efeitos fixos por time capturam a força específica de cada equipe, isolando o efeito de interesse (jogar em casa, por exemplo).

O que o resultado significa: o coeficiente do fator de interesse, transformado adequadamente, vira um fator multiplicativo — “jogar em casa multiplica o número esperado de gols por X”, já descontada a força dos times envolvidos.

O que ele não diz: o modelo assume uma relação específica entre os fatores e a contagem esperada — vale checar se essa suposição é razoável para os dados em questão.

22. Tendência por mínimos quadrados ponderados

A pergunta: uma métrica está subindo, caindo, ou estável ao longo do tempo, para cada unidade que estou comparando (um time, um clube, uma região)?

A ideia: ajusta-se uma linha reta aos dados ao longo do tempo, dando mais peso aos períodos com mais observações (mais confiáveis). Em vez de decidir “subindo ou caindo” só olhando se a inclinação é positiva ou negativa, olha-se o intervalo de confiança dessa inclinação: se o intervalo inteiro for positivo, a tendência é de alta; se for inteiro negativo, é de queda; se cruzar o zero, é considerada estável (não há evidência suficiente de tendência).

O que o resultado significa: essa classificação evita declarar “tendência” em cima de ruído — exige que a evidência seja forte o bastante para excluir a hipótese de estabilidade.

O que ele não diz: com poucos períodos de dados, o intervalo de confiança tende a ser largo, e a maioria das unidades acaba classificada como “estável” simplesmente por falta de dados suficientes para decidir — isso não é o mesmo que dizer que elas de fato não mudam.